纠正之前，先说清楚为什么失败

机器人长程任务失败后，只看终态或把整段日志平铺给 LLM，容易漏掉早于失败时刻的**致因**。把多感官执行历史整理成**分层摘要**、先定位哪个子目标没达成、再回溯原因，纠正计划会不会明显更有效？

一次执行失败如何被定位与追因

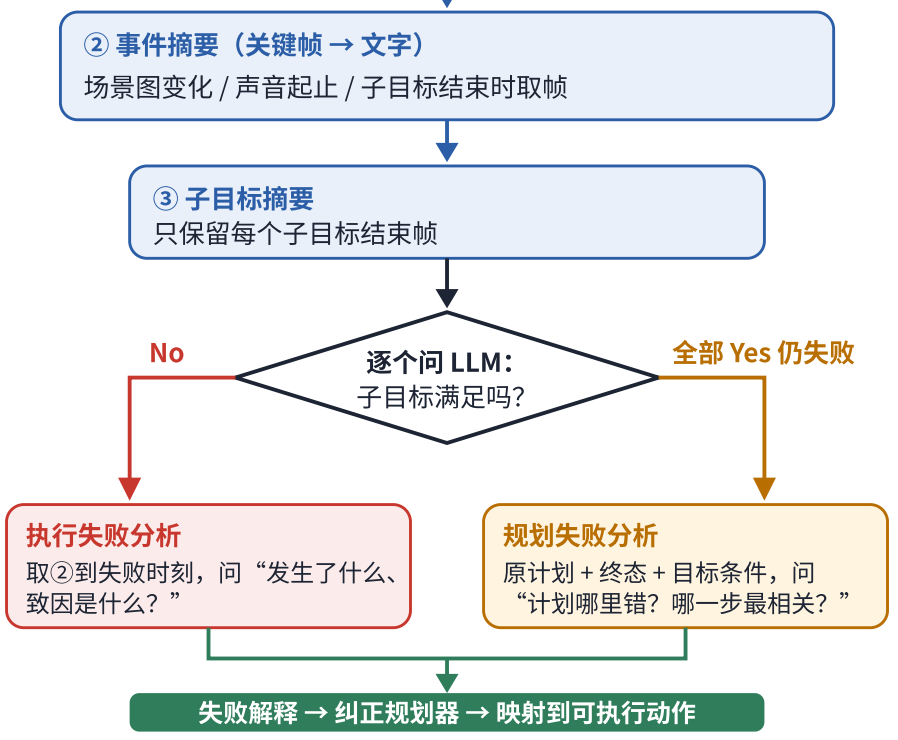
示意：按附录 A.3.2“烧水”提示词例重绘

子目标级摘要先判断“哪一步没达成”；事件级摘要（含声音）再说明“为什么”。终态里只看得到“锅不在灶上”。

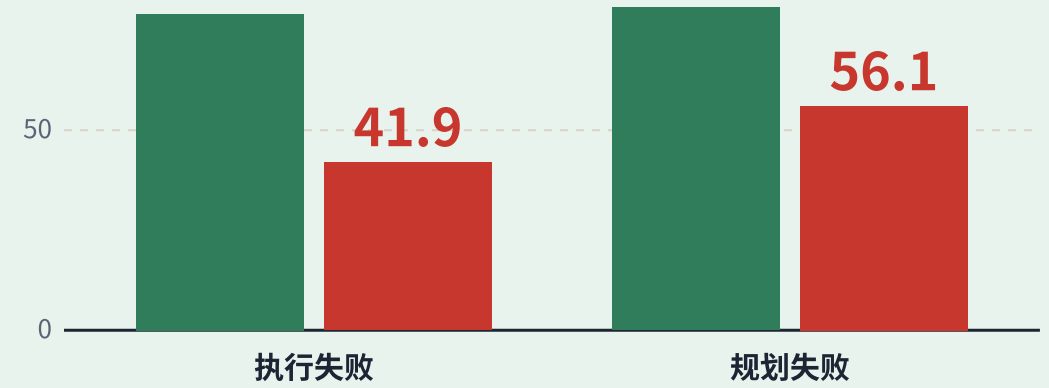


机制：三层摘要 + 渐进式提问

示意，据 §3



同一 GPT-4、同一批失败：给不给“失败解释”



纠正成功率 Co-plan（%）：执行纠正计划后终态是否满足目标 · 模拟 · Table 1

差距 **37.2 / 24.6** 个百分点（我们按 Table 1 相减）。论文 Fig. 8 的例子：杯子挡在咖啡机里，带解释时先把杯子移开再放马克杯；不给解释时 LLM 只是重复原计划，没有处理致因。

同表中，只去掉“渐进式提问”时纠正为 60.5 / 64.9，介于两者之间；只用子目标摘要时执行失败纠正仅 51.2（我们的读法：解释越接近真实致因，纠正越有效）。

完整对照：模拟 RoboFail，GPT-4（Table 1，%）

方法	执行失败			规划失败		
	Exp	Loc	Co-plan	Exp	Loc	Co-plan
w/o progressive	46.5	62.8	60.5	61.4	70.2	64.9
Subgoal only	76.7	74.4	51.2	71.9	73.7	75.4
LLM summary	55.8	67.4	65.1	57.9	54.4	66.7
w/o explanation	–	–	41.9	–	–	56.1
REFLECT（完整）	**88.4**	**96.0**	**79.1**	**84.2**	**80.7**	**80.7**

w/o progressive＝不先逐个查子目标、直接开放式问；Subgoal only＝只用子目标摘要；LLM summary＝让 LLM 自行压缩感官摘要；w/o explanation＝不给解释直接要纠正计划。Exp＝解释正确且有信息量（人工评审，2 组 × 3 人，多数票）；Loc＝预测失败时刻落入标注区间。原文未列执行/规划两类各自的失败数。

真实 UR5e：只测解释与定位（Table 2，%）

方法	执行 Exp / Loc	规划 Exp / Loc
BLIP2 caption	6.25 / 25.0	35.7 / 57.1
w/o sound	50.0 / 68.8	78.6 / 78.6
w/o progressive	43.8 / 81.3	71.4 / 78.6
REFLECT	**68.8 / 93.8**	**78.6 / 78.6**

30 段失败、11 个任务，MDETR / CLIP / AudioCLIP 感知。去掉声音后执行失败的解释、定位约降 20 个点（原文表述）。**真实场景没有报告纠正成功率。**

关键动作

不改 LLM，只改喂给它的历史：把多感官执行记录压成“感官 → 事件 → 子目标”三层摘要，先用子目标层判断哪一步没达成，再到事件层取该时刻之前的观测问致因；全部子目标都达成时转为检查计划本身。解释再作为纠正规划的输入。

可测的瓶颈：同一 LLM 下，**纠正效果受“是否定位到致因”约束**，而不只是“是否判出失败”。

边界：纠正结果只在模拟里成立

- 模拟 100 个失败为**人工注入**（10 任务 × 10），物体检测与状态用**模拟真值**；纠正成功按终态与目标条件比对。
- 真实 30 段由人遥操作 UR5e 模仿策略失败，只报解释与定位，**没有闭环纠正分母**。
- 只用 GPT-4（附录：换 GPT-3.5 后定位与纠正明显下降）；场景图依赖启发式与预设状态词表，假设环境静态，对低层控制失败作用有限（作者自述）。

数字均出自原文 v4：§3 方法；§4 RoboFail 数据集；§5 Table 1（模拟）、Table 2（真实）、Fig. 8 与局限；附录 A.3（提示词例）、B.2（GPT-3.5）、B.4（人工评审）。时间轴与机制图为本画报自绘示意，不是论文实验图；差值由我们按 Table 1 计算。逐项映射见 SOURCE.md。本画报未复现实验。