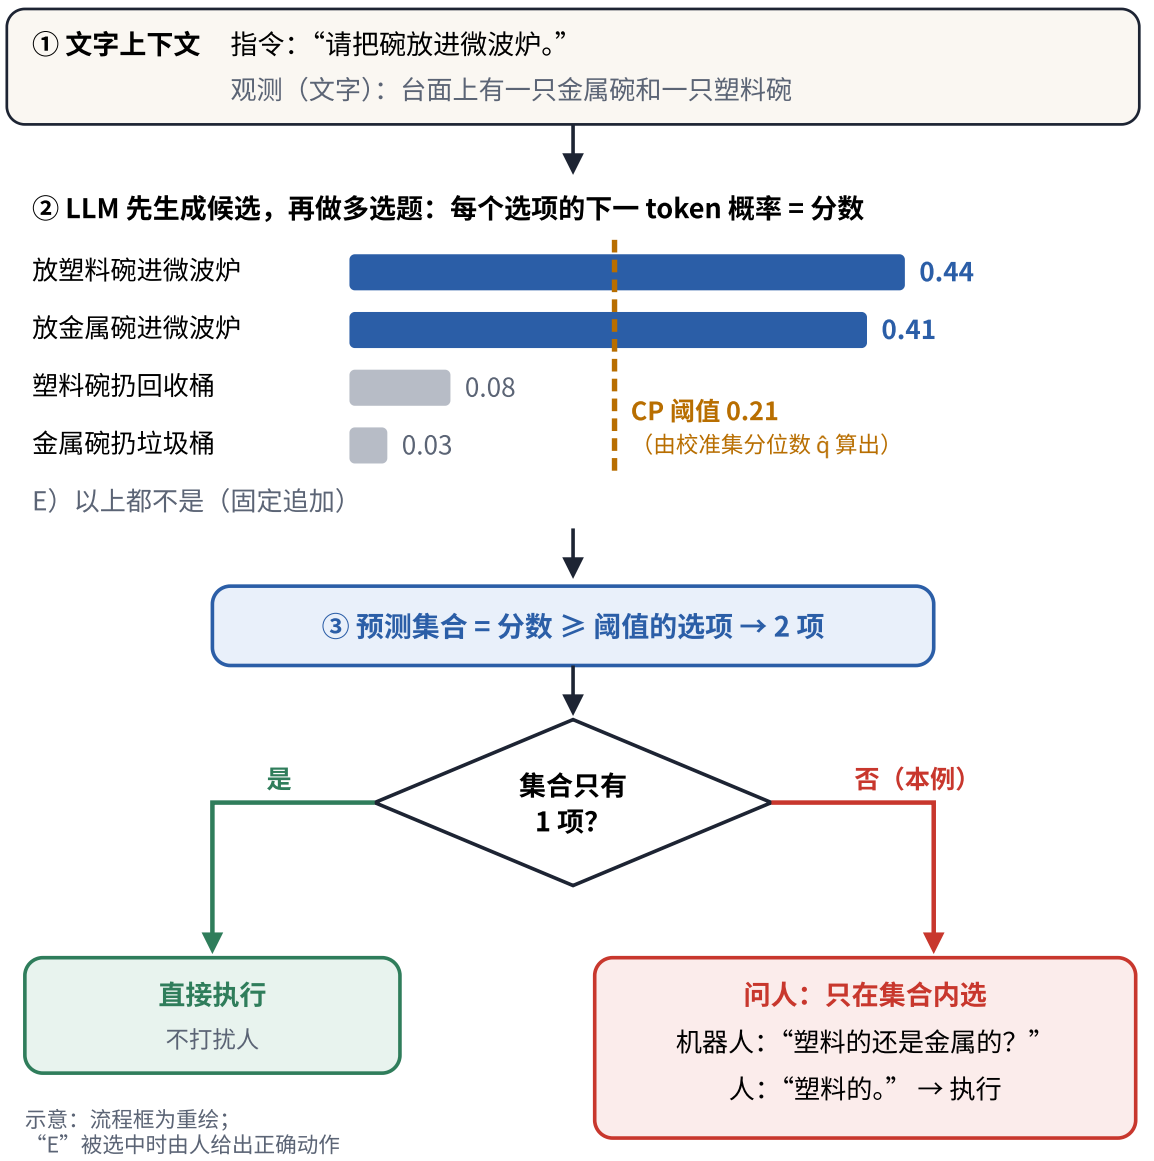
让 LLM 规划器只在拿不准时开口，而且“拿不准”可以按用户要的成功率校准

“把碗放进微波炉”——台面上有金属碗和塑料碗，指令有歧义，放错还可能危险。LLM 往往自信地挑一个。KnowNo 用**共形预测（CP）**把 LLM 的原始置信度变成一个候选集合：集合只剩一项就执行，多于一项就问人，并对“规划正确率 ≥ 1−ε”给出统计保证。

一次决策怎么走

分数与阈值取自原文 Fig. 1 的示例；流程框为本画报依据 §2–§3 重绘



示意：流程框为重绘；“E”被选中时由人给出正确动作

离线校准：阈值从哪来（§3.1–3.3）

1. 从任务分布 i.i.d. 抽 **N = 400** 个场景，人工标出正确选项（单步约 1.5 小时，多步约 4 小时）。
2. 每个场景算不符合分数 $\kappa = 1 - \hat{f}(\text{正确项})$。
3. 按用户要的 ε 取 κ 的分位数 $\hat{q}$；测试时保留 $\hat{f} \geq 1 - \hat{q}$ 的选项。
4. 以 1−δ（δ = 0.01）的概率对这份校准集成立；多步任务取各步最低分做**序列级校准**，再逐步因果地构造集合。

保证一路传到哪里

集合覆盖正确选项 ≥ 1−ε

需要：校准与测试场景同分布；正确选项在候选里或由“E”兜底

↓

规划正确 ≥ 1−ε

需要：人如实回答；物体已在文字中正确给出

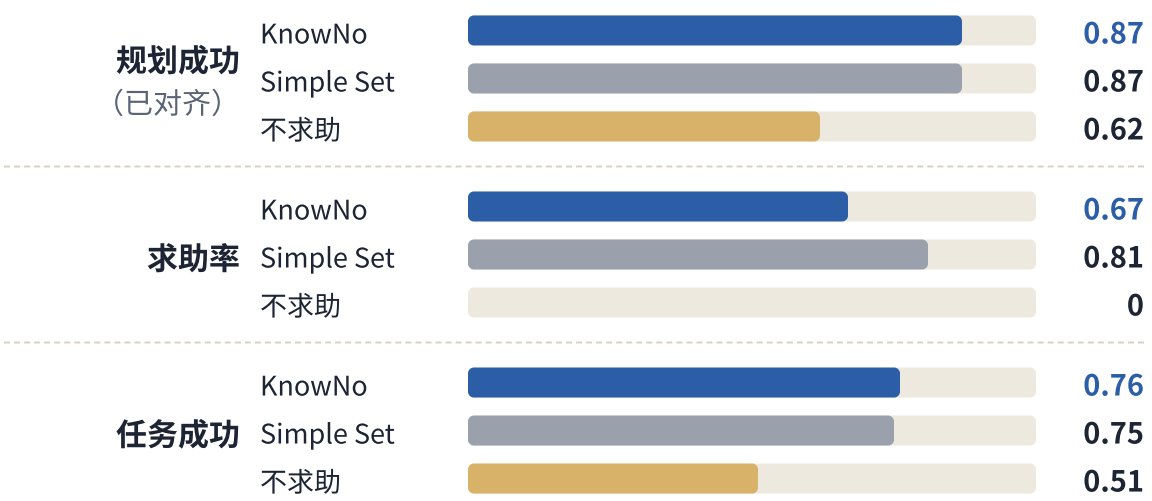
↓ 不传到

任务真的完成：还取决于低层动作。移动操作中低层成功率约 86%，任务成功 0.76 低于目标 0.85

主对照：把规划成功率对齐到同一水平，再比谁问得少

真机移动操作（办公室厨房，PaLM-2L，单步、可有多个正确选项）· 原文 Table 2。Simple Set 用同一 LLM 分数做累积阈值、无保证；其 ε 在仿真中调到 0.24 以匹配 KnowNo（ε = 0.15）的规划成功率。真机试验次数正文未给出。

0.67 vs **0.81** 求助率（KnowNo vs Simple Set）



平均集合大小 **2.22** vs 2.38。注意求助率仍有 0.67：这组场景本身歧义多，KnowNo 是“少问一些”，不是“几乎不问”。

换 LLM 仍守住目标：GPT-3.5 对选项 D/E 有偏，KnowNo 用更多求助（**0.86**）补偿，规划成功仍 0.87；指令微调版 PaLM-2L 集合更小（1.86）、求助 0.67。二者未上真机。

多步真机桌面分拣（UR5，各 50 次，原文 Table 1）

	1−ε	规划	任务	集合	每步求助	每次试验求助
KnowNo	**0.75**	**0.76**	**0.74**	**1.72**	**0.58**	**0.92**
Simple Set	0.58	0.76	0.72	2.04	0.72	1.00
不求助	—	0.41	0.38	—	0	0

Simple Set 若直接用 ε = 0.25，每步求助率达 87%（过度保守）。仿真三类歧义中较 Simple Set 最多少求助 24%（Fig. A10）。

边界

- 保证的是**规划**正确率，不是物理任务成功或安全；低层失败不在保证内。
- 假设人总能如实、正确回答；人答错的情形未建模，人机对话形式也很简单（§5、§6）。
- 需要校准与部署同分布（实验中的场景分布由作者设计并均匀抽样），分布漂移时保证失效。
- 需要能读出选项概率的 LLM 和每个分布约 400 条人工标注；求助率在歧义场景中仍很高。

来源：Robots That Ask For Help: Uncertainty Alignment for Large Language Model Planners，arXiv 2307.01928v2（PDF 版含附录 A1–A9）。数字取自原文 Fig. 1、§3、§4、Table 1、Table 2、附录 A5/A9；流程框与保证链为本画报依据原文文字绘制的示意。我们未运行代码、未复现实验。