RL / 教师引导 · arXiv 2311.13373v6 · LLM4Teach（Zhou 等）

会犯错的教师，能让小 RL 学生少走弯路，再被学生反超吗？

训练期用 LLM 教师带路，测试期只部署小学生策略（MiniGrid 学生 24K 参数 vs 教师 ChatGLM-turbo 130B）

问题 两条路都卡住

从零 RL：稀疏奖励下几乎学不会——MiniGrid 四任务中 PPO 成功率仅 1.9–10.1%。

直接用 LLM：部署贵，且会犯错。例：看到“红钥匙、蓝钥匙、蓝门”，LLM 建议**拿红钥匙**，正确应拿与门同色的蓝钥匙。

§1、§4.1.2；成功率见附录 Table 3

关键动作 边模仿边自学，按日程退出教师

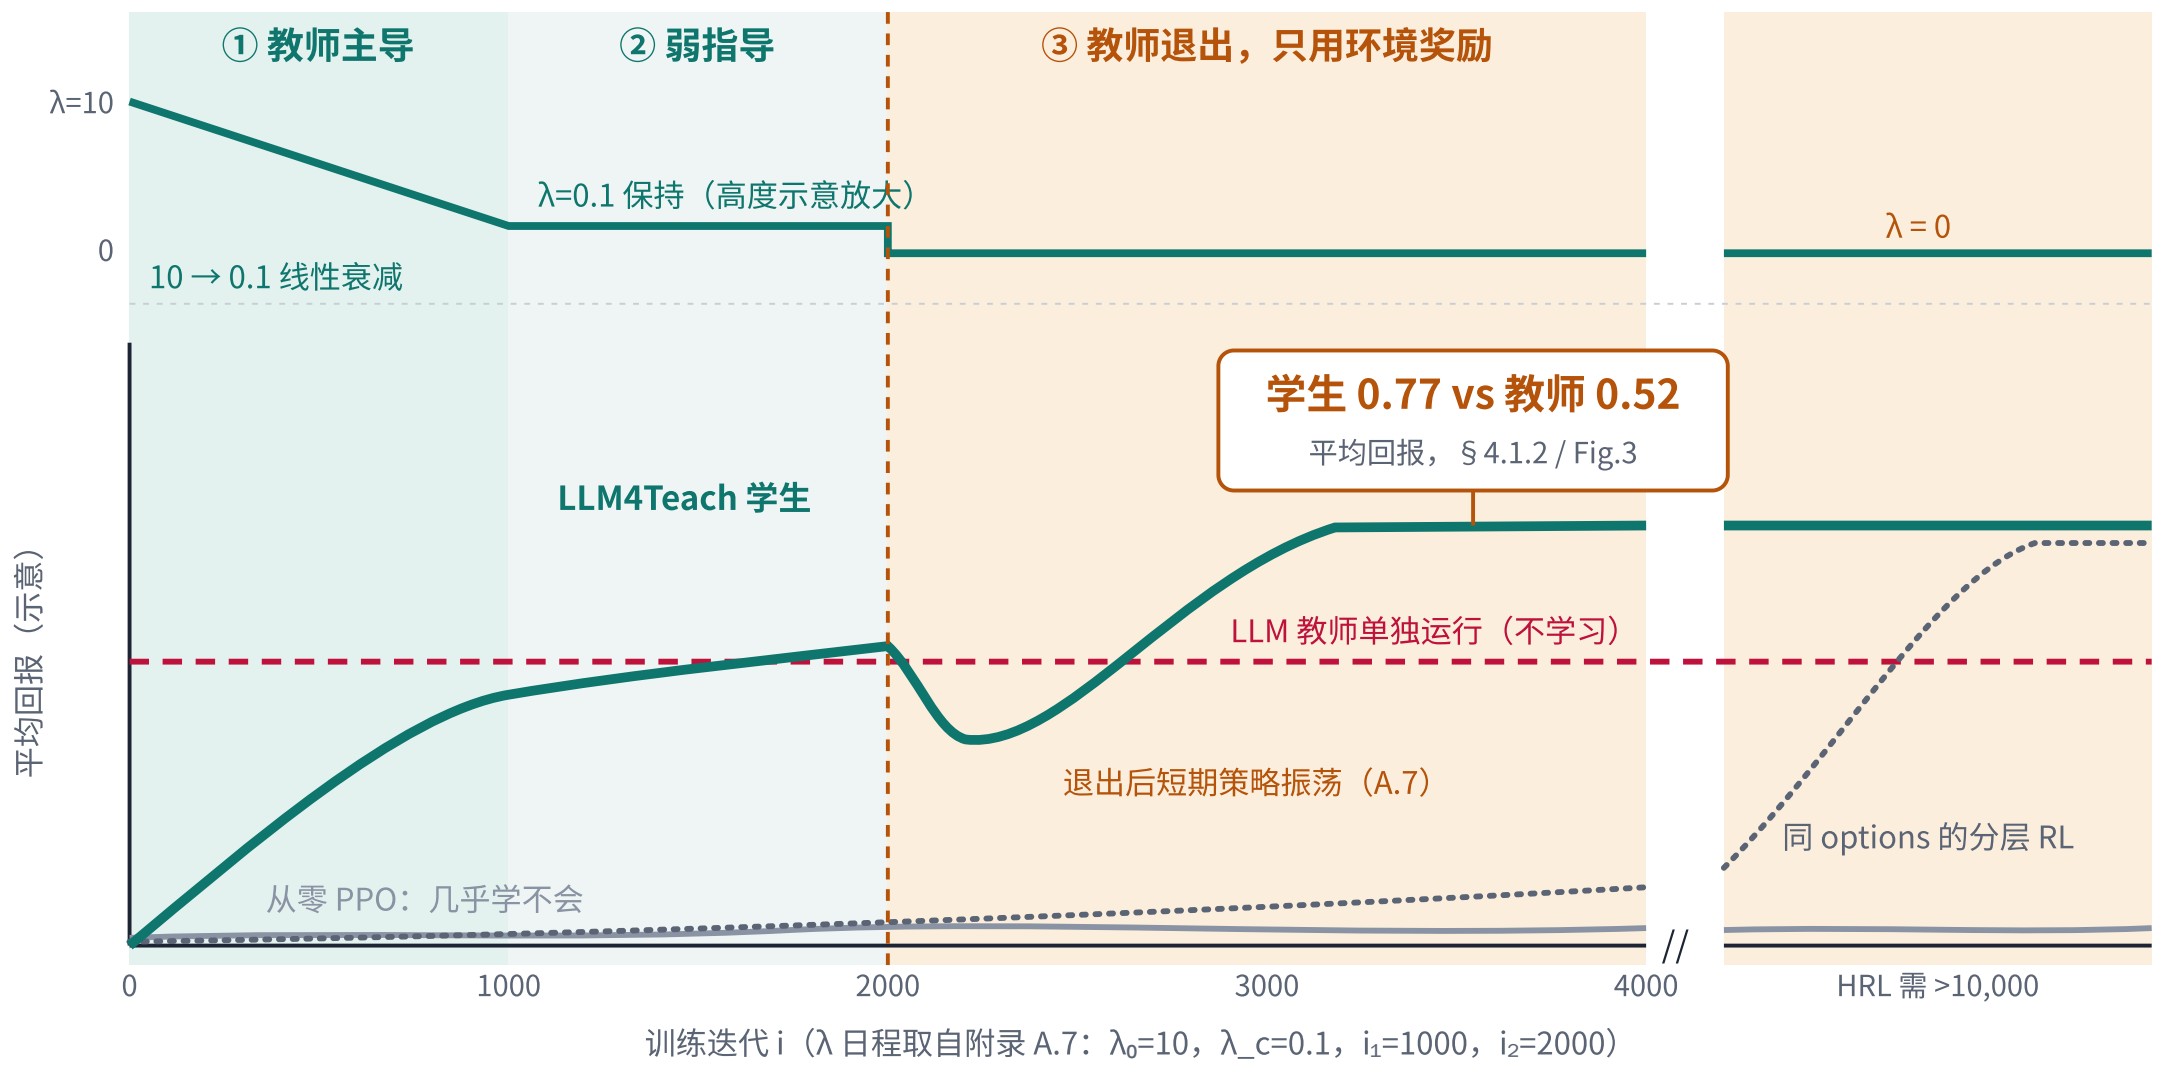
$$L(\theta) = L_{RL}(\theta) + \lambda_i \cdot H(\pi_T \,\|\, \pi_\theta)$$

教师给**软指令**：同一提示多次查询，估计选项分布 π_T，再经预训练 option 落到动作。

λ 逐步退火到 0：此后学生只靠环境奖励，可纠正教师错误。

§3.2–3.3，Eq.(1)–(3)，Algorithm 1

训练阶段：教师带路 → 弱指导 → 教师退出 → 学生反超（ColoredDoorKey）



示意图：曲线形状为自行绘制，**不是原文 Fig.3 数据**；只有 λ 日程参数与框内数值来自原文。A.7：仅“衰减→保持 0.1→归零”的阶梯日程成功，常数或直接线性衰减到 0 的日程均未成功（Fig.7）。

结果 收敛后表现：回报 / 成功率

任务	教师单独	分层 RL	从零 PPO	学生
SimpleDoorKey	0.87 / 100%	0.70 / 96.0%	0.05 / 10.1%	0.81 / 96.4%
LavaDoorKey	0.48 / 54.6%	0.63 / 85.1%	0.00 / 5.0%	0.75 / 90.9%
ColoredDoorKey	**0.40 / 46.8%**	**0.74 / 95.8%**	**0.03 / 6.6%**	**0.78 / 94.0%**
DivergedDoorKey	0.19 / 37.2%	0.59 / 98.0%	0.01 / 1.9%	0.53 / 93.1%
Habitat Nav&Pick	2.18 / 62%	−1.51 / 12%	−6.72 / 0%	2.39 / 69%

附录 Table 3；MiniGrid 1000 次测试，Habitat 100 次。同一学生网络与损失设置，分层 RL 共享预训练 options。**注意：**正文 Fig.3 给 ColoredDoorKey 教师 0.52，附录表为 0.40，原文两处不一致。

限制 反超的是教师，不是天花板

- 分层 RL 用同样 options 最终也接近或超过学生（DivergedDoorKey 0.59 vs 0.53），只是需 >10,000 次迭代：收益主要在**样本效率**。
- SimpleDoorKey 未反超教师（0.81 vs 0.87）。
- 只有 4 个 MiniGrid 与 1 个 Habitat 仿真任务，无真机；options 需预训练；没有计入教师查询成本的等算力对照。

来源：Z. Zhou 等，“Large Language Model as a Policy Teacher for Training Reinforcement Learning Agents”，arXiv 2311.13373v6。所有数字为论文报告，本项目未复现。数字出处见 SOURCE.md。画报：Opus 5.5 原文核对后制作，2026-10-22。