别只看成功率：把 LLM 具身规划的失败拆到具体模块与错误类型

作者用**对象中心状态 + LTL 目标**为四类 LLM 决策模块定下统一输入输出；每次只让 LLM 担任一个模块，其余用真值或工具顶替，失败由模拟器按固定规则归类。覆盖 VirtualHome 338 条指令、BEHAVIOR 100 个任务、18 个 LLM。

问题 已有工作输入输出各异、只报最终成功率：同样失败，分不清是目标读错、子目标拆错、动作漏步，还是动作模型写错。

关键研究动作：一条接口总线，四个可替换模块，一棵错误分类树

示意 · 本刊自绘

共享接口总线
四个模块读写同一种表示

状态 s = ⟨U, F⟩：一组对象 + 对象间布尔关系，如 `is-open(cabinet1)`、`ontop(rag0, window3)`
目标 / 子目标 / 动作序列 = 有限轨迹 LTL 片段（∧ ∨ ¬ ⇒ ∀ ∃ $\exists^{=n}$；时序连接词只实现了 then）

原文子目标例（browse Internet）：
`ontop(character, chair) then holds_rh(character, mouse) ∧ holds_lh(character, keyboard) then facing(character, computer)`

读 s_0, l_g / 写 $\hat{g}$

G 目标解释
LLM 只占这一格

输入
初始状态 s_0 + 自然语言指令 l_g

输出
LTL 目标 $\hat{g}$
（限“动作 then 命题合取”）

评测：与真值目标集合求 F1；真值可落地成多种目标，取最高。BEHAVIOR 平均每任务 6.7 个落地目标、约 4,164 种目标选项

失败流向 c

读 s_0, g / 写 $\hat{\phi}$

Φ 子目标分解
LLM 只占这一格

输入
s_0 + **真值**目标 g

输出
LTL 子目标序列 ϕ_1 then ϕ_2 ⋯

工具落地：BFS 把每个子目标展开成动作，接到模拟器执行；子目标可落地成多条动作序列，取最高分。
指标：同 Q

失败流向 a b

读 s_0, g, M / 写 $\hat{a}$

Q 动作序列
LLM 只占这一格

输入
s_0 + **真值** g + 模拟器转移 M

输出
动作序列 $\hat{a} = a_1 \cdots a_n$

评测：模拟器从 s_0 逐步执行，到第一个不可执行动作停止；记**执行成功**、**任务成功**与部分目标满足

失败流向 a b

读 s_0, g, o / 写 pre/eff

T 转移建模
LLM 只占这一格

输入
s_0 + **真值** g + 算子名与参数 o

输出
PDDL 前置 pre / 效果 eff
（注意：此格输出不是 LTL）

评测：与专家标注做逻辑形式 F1；再交给 PDDL 规划器，看能否求出计划（只看状态目标）

失败流向 d

组合实验：把 G 接到 Q 前面
附录 G · 用于下方结果

M 模块化　真值 LTL 目标 g → **LLM 担任 Q** → 模拟器执行

P 流水线　自然语言 l_g → **同一 LLM 担任 G** → $\hat{g}$ → **LLM 担任 Q** → 模拟器执行

两行只差一处：Q 拿到的是真值目标，还是同一 LLM 自己解释出的目标。
单模块评测时其余输入全用真值/工具（原文图 4），所以每个模块的分数不混入上下游误差；组合后才看误差是否传递。

执行 / 比对结果下行到分诊

失败分诊树
每个失败落到一个模块、一种类型

右列计数：GPT-4o · BEHAVIOR · 动作序列 100 个任务，百分比即件数（原文表 6）

- a **轨迹不可执行** Φ / Q — 47
  - **语法错误** 格式 / 词表层面 — 1
    - 解析错误 输出不合格式 — 0
    - 幻觉 动作名或对象名不在词表 — 1
    - 谓词 / 参数个数不符 — 0
  - **运行时错误** 模拟器按序判定 — 46
    - 1 可供性 对象不支持，如 open(shelf) — 1
    - 2 多余步 效果已成立仍执行 — 0
    - 3 缺步 前置条件历史上从未成立 — 36
    - 4 顺序错 前置条件曾成立过 — 9
- b **可执行但目标未满足** Φ / Q — 6
  - 按状态 / 关系 / 动作目标分别统计满足率
- c **目标解释偏差** G
  - 状态・关系・动作目标各算 P / R / F1 多写→精确率降，漏写→召回降
- d **转移模型偏差** T
  - 前置 / 效果逻辑 F1 递归二分图匹配
  - PDDL 规划器能否求解
  - 敏感性 每次只把一个真值动作换成 LLM 版

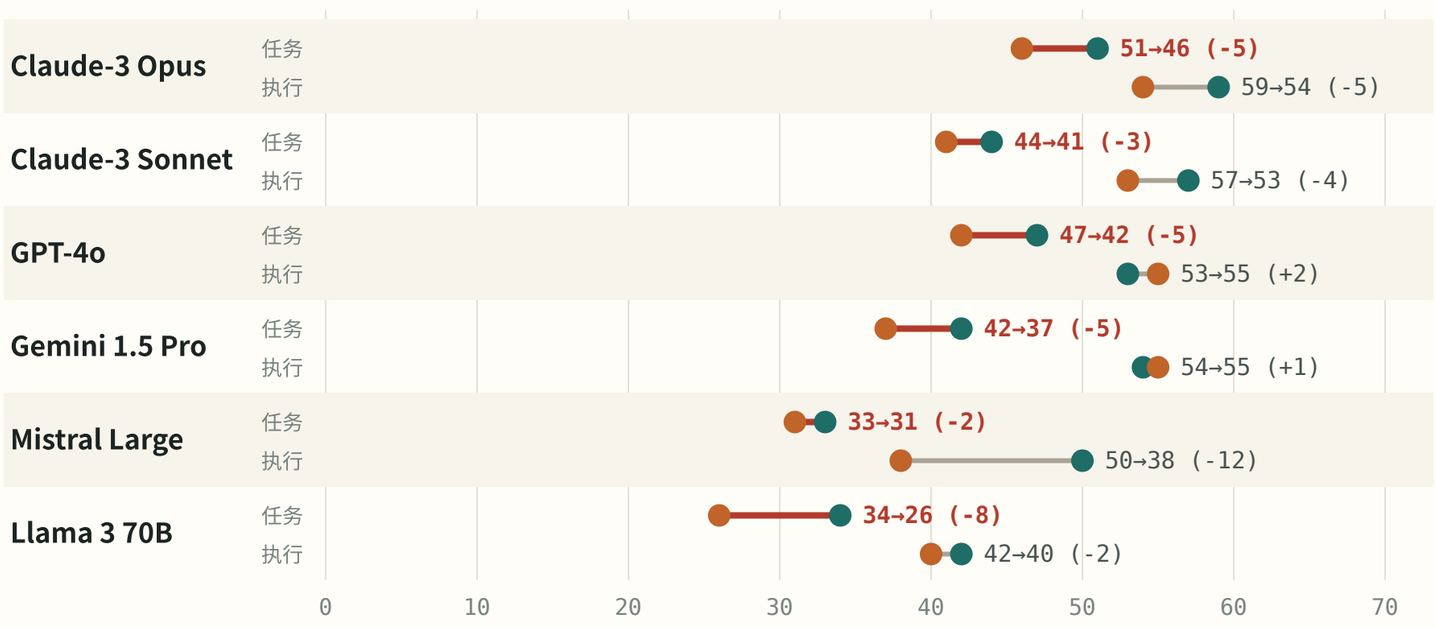
同一 100 个任务的去向（GPT-4o · BEHAVIOR · 动作序列；黄 6 = 可执行但目标未满足）

一个完整对照：同一模型，只把“真值目标”换成“自己解释的目标”

原文表 16 重绘

条件：BEHAVIOR 100 个任务 · 动作序列 · temperature 0 单次运行 · ● M = 给真值 LTL 目标 ● P = 同一 LLM 先做 G 再做 Q · 单位 %（原表 15 个模型，此处选 6 个）

每行上：任务成功（红线）　下：执行成功（灰线）　圆点颜色同上方条件说明



15 / 15 个模型任务成功下降

换成自己解释的目标后，任务成功**全部下降**，幅度 1–12 点（GPT-4o 47→42，Llama 3 70B 34→26）。

执行成功则**方向不一**：10/15 个模型相差 ≤5 点，但 Mistral Large −12、GPT-3.5 +12。

读法：上游目标误读会传到下游，使动作“能执行但做错事”；作者据此称模块可组合但有误差累积。表中没有 o1 系列。

明确限制

按原文 §6、附录 S.2、O.1 与本刊核对

只在符号世界里成立
环境被抽象为对象关系图，无感知与低层控制；BEHAVIOR 的动作转移层是作者自写的符号层。原文自认：规划器能解出的计划，在真实环境中可能不可行。

“统一接口”是部分的
LTL 只实现了 then；T 模块输出 PDDL 而非 LTL；Φ 需 BFS 落地并取最好的一条才能打分。共享的是状态词汇与目标语言，评测管线仍是四条定制通道。

统计与归因粒度有限
每个模型 temperature 0 单次运行，无方差或置信区间；执行在首个不可执行动作处停止，每条失败轨迹只记一个错误类型，缺步/顺序错的区分是规则化归因。