多智能体评测 · arXiv 2411.00081v1 · PARTNR（Habitat 3.0 仿真）

多了一个 LLM 伙伴，人做家务反而更慢？

PARTNR：10 万条家务协作任务，同一规划框架下逐项切换控制方式、技能、观测与感知，再把真人放进回路

反直觉结果 **完成任务所需仿真步数（越短越好）**

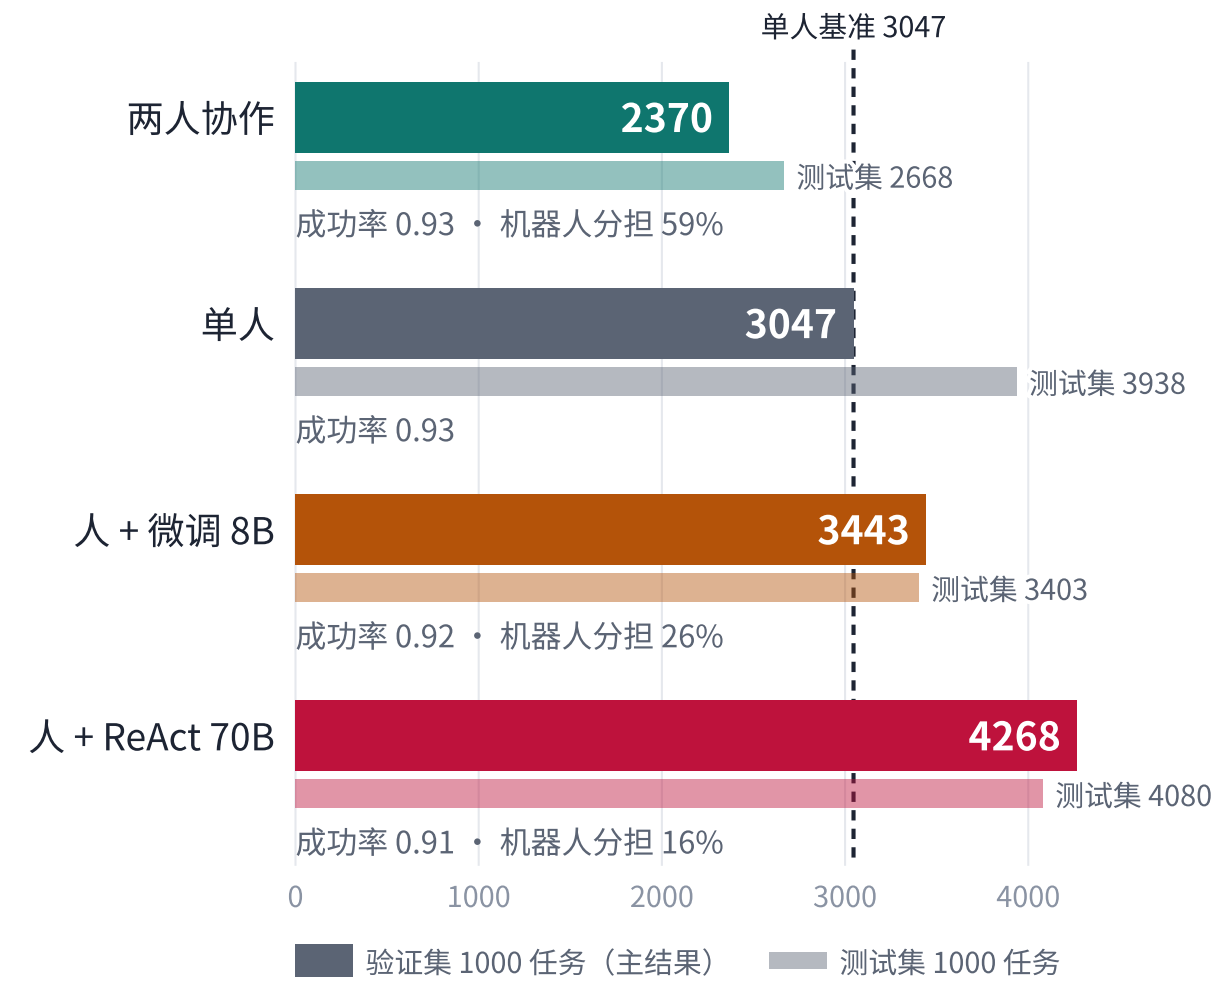


Table 3 / 附录 Table 14，真人在 Habitat 仿真中以键鼠操作。验证集：两种 LLM 伙伴都比单人慢；测试集：ReAct 仍略慢（4080 vs 3938），微调 8B 反而更快（3403）。

问题 **协作真的省力吗？**

家务任务带空间、时序与“只有人能做”（如洗碗）的约束。LLM 伙伴能否分工、跟踪对方进度、从感知与技能错误中恢复，而不是给人添负担？

真人实验同时给两条参照：**单人独做**（协作值不值得）与**两人协作**（协作能快多少）。

§1、§3、§4.3

关键动作 **一次只换一格**

10 万任务（60 栋房屋、5,819 种物体，1,000 条人工核验种子）配自动评测函数。规划器统一用 Llama3.1-70B ReAct，规划调用上限 50 次；依次切换**单体/集中/分散、全/部分观测、oracle/学习技能、特权/ConceptGraph 感知**。

§3.2–3.3、§4.1；自动评测中的“人”是 LLM 模拟人

受控对照：每块只改一个维度（自动评测，Table 2）

橙色格为本次改变的维度

① 多一个伙伴，会更快吗？

	控制	技能	观测	步数 · 成功率
(a)	**单体**	oracle	部分	**2519** · 0.73
(e)	**分散双体**	oracle	部分	**3295** · 0.73

成功率不变，步数 **×1.31**；无效动作比例增加 300%（Table 12）

② 不知道伙伴在做什么，代价多大？

	控制	技能	观测	步数 · 成功率
(d)	**集中**	oracle	部分	**2298** · 0.74
(e)	**分散**	oracle	部分	**3295** · 0.73

两个 LLM 各自决策，步数 **+43%**：协调本身是瓶颈

③ 技能会失败时，能恢复吗？

	控制	技能	观测	步数 · 成功率
(e)	分散	**oracle**	部分	**3295** · 0.73
(h)	分散	**学习技能**	部分	**6495** · 0.57

成功率 **0.73 → 0.57**：拾取失败、探索不全后难以重规划

④ 感知不再特权，还剩多少？

	控制	技能	感知	步数 · 成功率
(h)	分散	学习技能	**特权图**	**6495** · 0.57
(i)	分散	学习技能	**ConceptGraph**	**12491** · 0.30

全非特权只剩 **0.30**，对比真人单独 0.93（验证集）

限制 **读这些数字前要知道**

- “真人”是 129 名非专家在仿真里用键鼠操作；每个任务最多尝试 3 次直到成功，成功率含重试。
- “伙伴拖慢人”在验证集对两种模型都成立；测试集只对 ReAct 微弱成立（+4%）。原文称测试集“同样成立”，与其 Table 14 不完全一致。
- 自动评测里的伙伴人类也是 LLM；错误类别来自逐项替换对照与观察，不是对每次失败的因果分解。
- 微调 8B 同时改变模型规模与训练数据；附录 A.13.4 另报 3275 vs 4484 步，与表不符，本画报用表值。只在仿真家居中评测，无真机。

来源：M. Chang 等，“PARTNR: A Benchmark for Planning and Reasoning in Embodied Multi-agent Tasks”，arXiv 2411.00081v1（2024-10-31）。所有数字为论文报告，本项目未复现；出处见 SOURCE.md。画报：Opus 5.5 原文核对后制作，2026-10-22。