单体 MLLM 闭环评测 · arXiv 2501.11858v2 · EmbodiedEval

同一套眼睛和按钮：人 97.26%，GPT-4o 25.00%

静态图文基准上表现很强的多模态大模型，放进需要**边走边看、动手、和人互动**的 3D 场景里，还剩多少能力？EmbodiedEval 让模型和非专家人类使用**完全相同的观测与动作选项**，把差距留给“能力”本身。

同一接口（§3.1、§4.1）

输入：任务文字＋第一人称图像历史（448×448，视场 90°），无额外状态信息

↓

非专家人类
经模拟器界面操作

19 个 MLLM
温度 0，先写思考

↓

选一个选项：沿导航图前进/转向/俯仰；开放词表交互（拿起、递给、解锁…）；8 选 1 作答

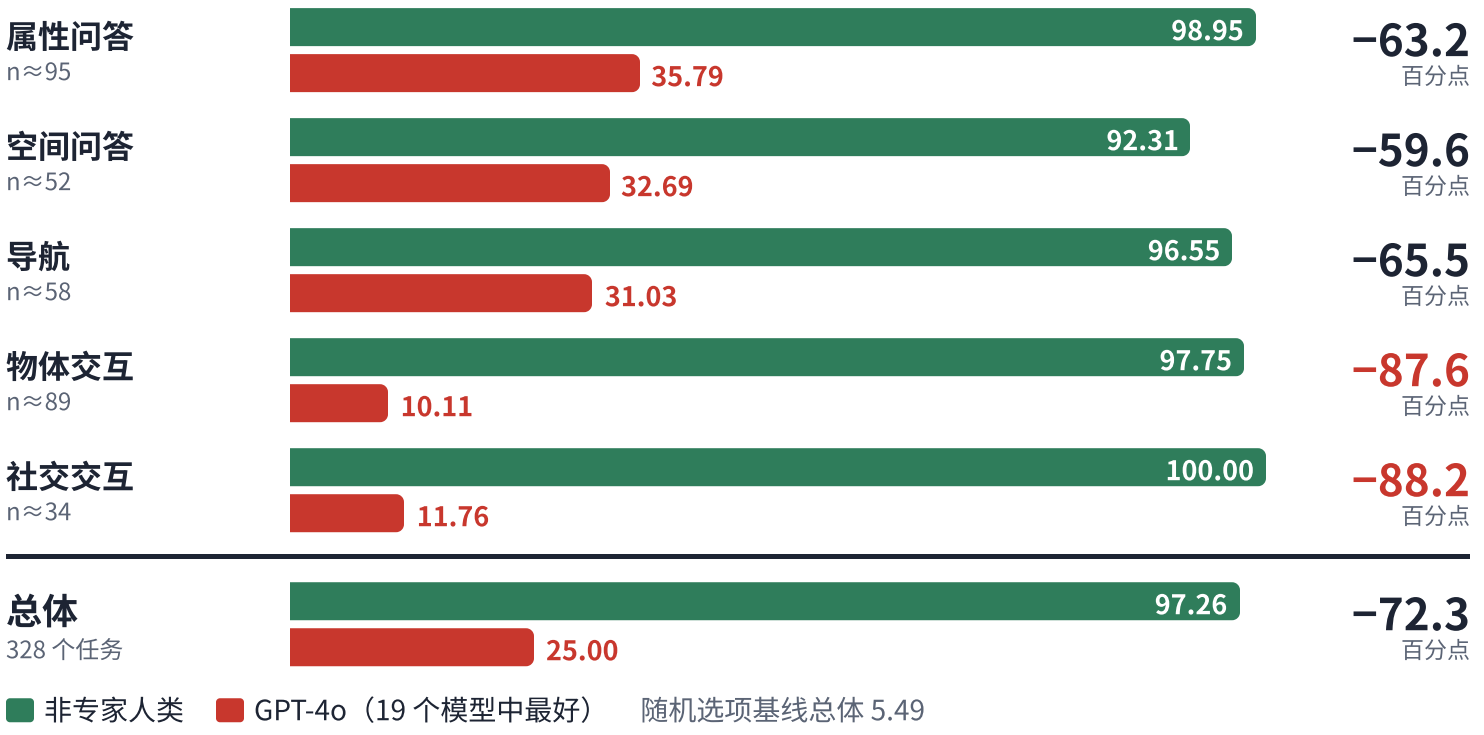
↓

判定：LEGENT 模拟器执行，谓词函数自动判成败；最多 24 步，答错即失败

328 个任务、125 个场景、5 类。低层运动由导航图与离散交互代劳，测的是看、找、选和规划。

五类任务成功率：同接口下的差距

成功率 %（原文 Table 2）· 括号内任务数为本画报由百分比反推，合计 328



不只是 GPT-4o：19 个模型总体成功率全部挤在 6–25%

每个点一个模型，横轴 0–100%（原文 Table 2 “Overall Succ.”）



交互动作：做得不少，做对的很少

交互任务统计（原文 Table 3）。有效率＝交互动作在满足执行条件时被调用的比例（看得到、离得够近、手里有对象…）

	交互频率	交互有效率
人类	**19.44**	**96.81**
GPT-4o	**40.46**	**9.56**
GPT-4o-Mini	26.02	11.34
Gemini-Pro-1.5	11.46	10.03
Qwen-VL-Max	26.33	8.89
Gemini-Flash-1.5	11.03	8.6
随机	41.06	2.79

GPT-4o 的交互频率（40.46%）和随机基线（41.06%）相当、是人类的两倍，但只有约 1/10 的交互在满足条件时发出。差距不只是“执行器做不到”：人类用同一组选项几乎都做对了。

反例注记：多给历史图像，反而变差

固定 Gemini-Flash-1.5，只改输入的历史图像张数（§4.3 / Fig. 5 右）



示意：只画原文文字给出的变化方向（“除空间问答外性能下降”），Fig. 5 的具体数值正文未给出，本画报不重绘曲线。

同节：允许步数从 1 增到 25，交互任务成功率先升后饱和。

这是固定模型的受控干预：更多上下文不等于更好的具身决策。只测了一个模型，不能推到所有 MLLM。

边界

- 每个模型温度 0、只跑一次，无重复与置信区间；附录 E 说所有模型在温度 1 下“略好”。
- 移动在预建导航图上、交互是高层离散选项：测的是感知—选择—规划，不含低层控制。
- 人类参与人数与分配方式正文未说明；结果对应论文评测时的模型版本。
- 摘要与 §3.4 称 328 个任务，§6 局限写 327 个测试例；按 Table 2 百分比反推为 328。
- 四类错误（定位幻觉、探索不足、空间推理、规划错误）来自案例归纳，未做全量标注；历史图像干预只做了 Gemini-Flash。
- 场景与任务由 LLM 生成候选、人工筛选标注，全部在 LEGENT 仿真中。

来源：EmbodiedEval: Evaluate Multimodal LLMs as Embodied Agents，arXiv 2501.11858v2。数字取自原文 Table 2、Table 3、§3–§4、§6、附录 B/E；各类任务数为本画报由百分比反推。右下方向图为示意，非原论文图。我们未运行评测、未复现实验。