分层归因诊断 · arXiv 2506.06677v2 · RoboCerebra: A Large-scale Benchmark for Long-horizon Robotic Manipulation Evaluation

直接给它正确的计划，成功率也只有 25%

长程操作失败，到底卡在**高层**（看画面、记状态、做计划），还是**低层执行**？固定同一个低层 VLA、统一子目标切换时刻，只替换高层规划器，能把两者分开到什么程度？

固定低层 System 1
在 100 个训练任务上微调的 OpenVLA（OpenVLA*），所有高层共用

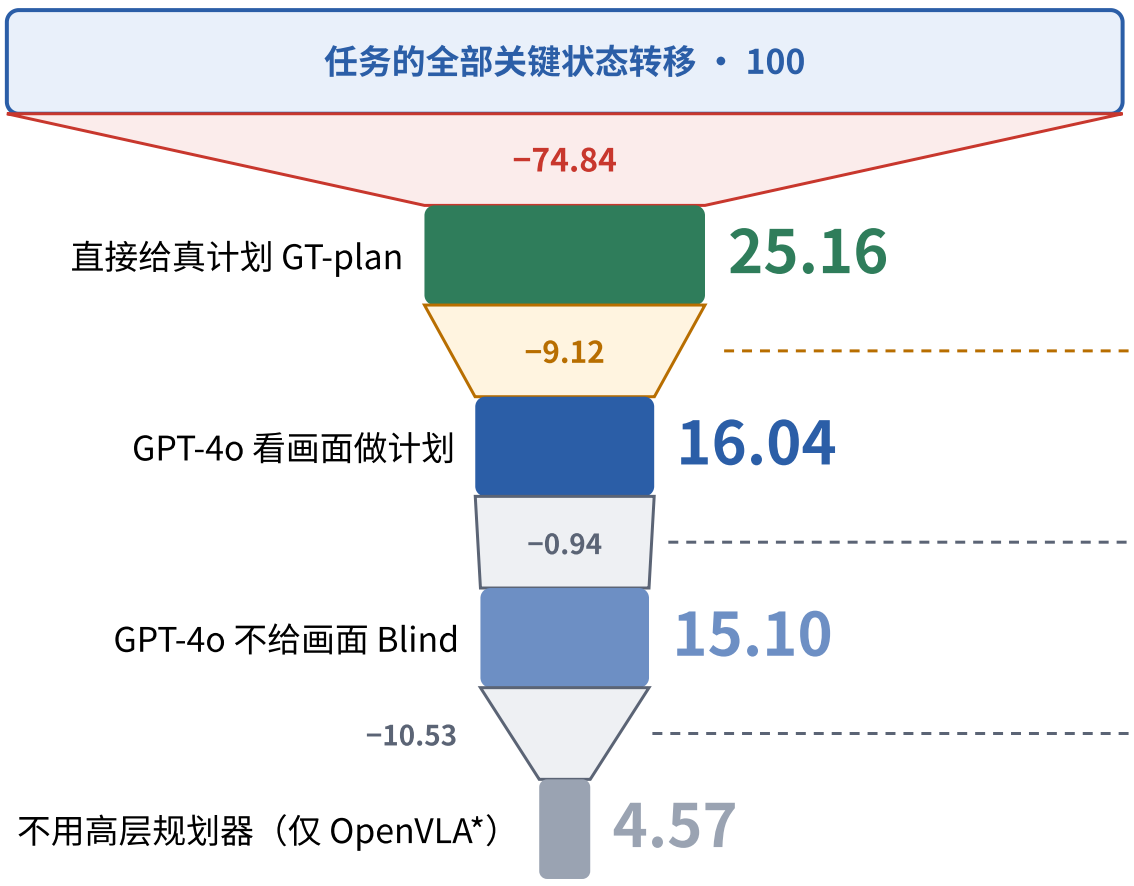
统一切换时刻
子目标何时切换由 anchor 点决定，与高层模型无关

只换高层 System 2
GPT-4o 看画面 / 不给画面（Blind）/ 直接给人工标注真计划（GT-plan）

600 次 rollout
60 个 LIBERO 仿真长程任务 × 每法 10 次；SR＝关键状态转移完成比例

瓶颈漏斗：从“任务全部完成”往下，每一层丢掉多少

条宽按原文平均 SR 等比例绘制（Table 3 / Table 4，%）；漏斗外形为本画报示意



最大的一层：真计划也补不回
高层已完全正确，固定的低层仍完成不了约 3/4 的状态转移

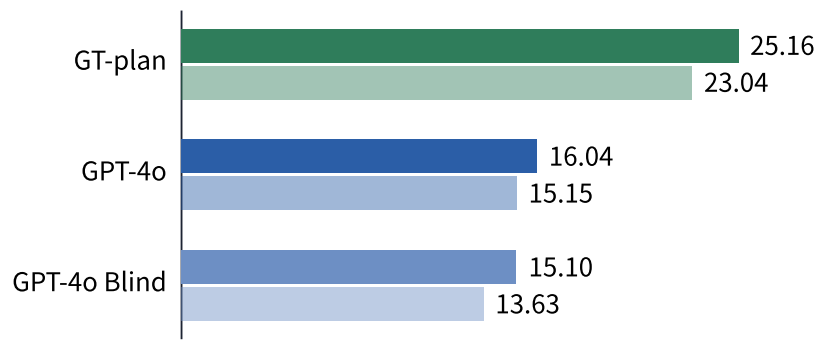
计划质量：GPT-4o 比真计划少 9.12
作者归因于缺少与环境的交互和视觉域差

去掉画面：只少 0.94
看不看图几乎一样；Qwen 的 Blind 反而更高（11.87＞11.19）

高层规划本身有用：+10.53
低层直接跑整条长指令只有 4.57；加文字计划即到 15.10

差值为本画报按原文均值相减；原文未报方差或置信区间

换一个低层（π0-fast），漏斗形状不变



两种低层下都是：真计划明显最高，看画面与不看画面只差约 1–1.5。闭环监控＋记忆的分层框架 16.55，也只比一次性规划 16.04 高 0.51。

“看懂画面”分数高，成功率并不跟着高

高层模型（同一 OpenVLA*）	计划匹配 Acc_P	观察判断 Acc_C	SR
GPT-4o	68.33	32.66	**16.04**
GPT-4o Blind	61.37	0.00	**15.10**
LLaVA-Next-Video-7B	40.00	37.19	11.37
Qwen2.5-VL-7B	44.67	47.74	11.19
Qwen2.5-VL-7B 微调	30.00	**66.83**	**9.33**

原文 Table 5。观察判断最高的微调 Qwen 成功率最低；不给画面的 Blind 观察分为 0，成功率仍居第二。**我们的阅读**：五个点里 SR 的排序更接近计划匹配率，但微调 Qwen 的计划匹配也最低，这是描述性对照，不是因果检验。

关键研究动作

把低层执行器和子目标切换时刻都**固定**，只替换高层；再补两条参照：**拿掉画面**（Blind）测视觉的贡献，**直接给真计划**（GT-plan）测“高层完美”时的上限。于是高层指标（计划匹配、观察判断）和闭环 SR 可以放在同一组 600 次 rollout 上对照。

结论：在这个基准上，**高层看得更准不等于任务更成功；固定低层的执行能力先卡住了上限**。

边界

- SR 是每个任务关键状态转移的**完成比例**（式 1），不是二元成功；只报均值，无方差/区间，0.94 这类小差不宜当显著。
- GT-plan 只有 25.16 主要指向低层，但其中也混有 anchor 切换、观测等因素，**不是对低层的完全隔离**。
- 子目标切换由 anchor 决定，不测模型自己判断何时完成、何时停止。
- 全部在 LIBERO 仿真、GPT 生成的任务上；无真机结果。

数字均出自原文 v2：§5.1（设置、600 rollouts、anchor）；Table 3（OpenVLA* 4.57、分层框架 16.55）；Table 4（GT-plan 25.16、GPT-4o 16.04、Blind 15.10、Qwen 11.87/11.19）；Table 5（Acc_P/Acc_C/SR）；附录 A.2 Table 6（π0-fast）；§3.4 式 1（SR 定义）。漏斗外形与差值为本画报绘制/计算，不是论文原图。逐项映射见 SOURCE.md。本画报未复现实验。