MemER：不把整段历史塞给模型，让高层 VLM 自己挑要记住的帧

作者把记忆放在分层策略的**高层**：微调 Qwen2.5-VL-7B，每一步同时输出**下一条子任务**和**值得记住的候选关键帧**；候选帧按时间聚类、每簇留一帧，组成紧凑的视觉记忆回喂高层。低层 π0.5 只管照子任务执行，两层异步运行。

一个具体问题

三个真机任务都要记住几分钟前看到或做过的事（§1、§4）

只看当前 / 最近 8 帧
看不到“哪个箱子查过、已经舀了几勺、哪层擦过”，部分可观测下无从判断进度。

直接拉长到 32 帧
2 Hz 下仅约 16 s 记忆，推理已要约 1 s，逼近闭环可承受上限；长历史还易在协变量偏移下学到捷径。

MemER 的做法
上下文仍只给最近 8 帧，另加至多约 8 张**由模型挑选、聚类去重**的旧关键帧，可覆盖整段数分钟的任务。

机制：三层上下堆叠，右侧是记忆窗

示意 · 依 §3.2–3.3、附录 D/E 自绘，非论文插图

层间异步：子任务下发 · 低层只用最新一条；2 Hz 图像入队 · 推完再整批送

① 高层 π_h · Qwen2.5-VL-7B 微调 + 与原权重合并 α=0.8 — ≈ 1 Hz

输入 · 任务指令 l_t + 最近 N=8 帧（×2 相机）+ 已选关键帧 K_t

最近窗口 R_t（≈4 s）：1 2 3 4 5 6 **7** 8

K_t: □ □ □ ← 来自右侧记忆窗

VLM
视觉编码器冻结
LLM 主干训练

输出 a · 子任务 l'_t
“look inside the center bin”

输出 b · 候选关键帧 J_t
R_t 内的帧号，如 [7]，可为空

每步的提名累积成序列 J'_0:t

② 关键帧过滤 · 时间聚类记忆条（无额外模型，不训练）

示意：横轴为 2 Hz 帧号，三个簇与提名次数为虚构例子



原文例：{1,3,3,4,10}, d=5 → {1,3,3,4} 与 {10}
柱高 = 提名次数（含重复）
◆ = 每簇取**中位帧**进记忆

R_t 仍在窗内 · 新提名

早于 t−N+1−d 的簇不再重算；聚类为附录 D 的 1D 单链接

中位帧

③ 低层 π_l · π0.5（DROID 检查点微调，三任务共用一个） — ≈ 2 Hz

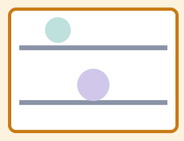
输入（无历史，马尔可夫）
- 最新子任务 l'_t
- 当前图像 I_t
- 关节与夹爪状态 q_t

动作块
15 步关节速度 @15 Hz
开环执行 8 步后重规划

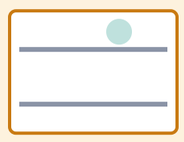
真机 Franka
第三人称 ZED + 腕部 miniZED
320×180 @15 Hz 采集
下采样 2 Hz 喂给高层

记忆窗 K_t — 只增不删 · 实际 ≤8

例：除尘&放回任务（示意）



K1 · 移走下层物体
记住：下层原来放的是哪件



K2 · 移走上层物体
记住：上层原来放的是哪件



K3 · 擦完下层
记住：哪层已擦（掸子放回后看不出）

下一个空位：擦完上层…
高层每轮都把整组 K_t 一并读入

训练标签从哪来（附录 E）
人看少量示范，给每类子任务定一条规则：取首帧 / 末帧 / 不取

- 物体检索：“看某箱”的末帧
- 计数：每勺倒入碗的末帧
- 除尘放回：移物/擦层/放回的末帧

训练预算（附录 A）
每任务 50 条示范 + 10–15 条干预
高层 4500 步 · 96 H200 GPU·h
低层 18000 步 · 48 H200 GPU·h
三任务共用一个高层、一个低层

结果：同一低层，只换高层看到什么

表 1 / 表 3 原始计数重绘

对照条件：真机 Franka · 每任务每法 20 次 · 所有方法共用同一低层 π0.5，只改高层输入上下文 · 所有高层同做 α=0.8 合并。颜色越深越好；“错勺”为 20 次合计的 |要求−实际| 勺数，越少越好。

高层看到什么	物体检索（/60 个目标） 取回	物体检索（/60 个目标） 最优路径	计数 错勺 ↓	除尘 & 放回（/20 次） 擦下层	擦上层	放回下层	放回上层
MemER 8 帧 + 关键帧	59	57	1	20	19	18	20
长历史 32 帧	47	41	12	11	11	12	12
短历史 8 帧	38	31	26	14	14	11	12
无历史（仅当前帧）	32	25	61	5	4	5	7
人给子任务（近似上限）	58	58	0	19	19	18	17
记忆换成文字（8 帧+子任务史）	40	28	10	16	16	7	10
MemER + 文字记忆	59	49	13	20	18	17	20

虚线下为模态消融（表 3）：加入文字记忆后计数错勺从 1 升到 13，作者归因于模型过度依赖最近一条文字子任务。

换成 API 大模型当高层？

10–15 s GPT-5 与 Gemini Robotics-ER 1.5 的调用延迟，闭环部署**全部失败**（需 <1 s）。

只能改做**离线**比较：低层按真值子任务执行的留出轨迹上，逐步子任务预测准确率（表 2）：

高层	检索	计数	除尘
MemER 7B	**0.80**	**0.67**	**0.87**
GPT-5	0.15	0.43	0.67
Gemini-ER 1.5	0.21	0.13	0.19

离线准确率，不是闭环成功率；API 模型同样给 8 帧 + 关键帧和完整动作清单提示，主要失误是提名过多无用关键帧。

一个明确限制

闭环对照全是同一系统的高层上下文变体，未与其他已发表记忆方法比较；只有一台 Franka，测试物体都在训练集内。

- 物体检索训练/测试同一批 15 个物体；除尘测试 9 个取自训练的 17 个（低层抓不动的被剔除）。
- 记忆只增不删，作者自认小时级任务会积累过多关键帧；1 Hz / 2 Hz 调度限制对快速变化的反应。
- 每格 20 次、无置信区间；图 5 的“各任务 >90%”“长历史平均差 34%”材料无柱值，本刊未采用。
- 关键帧标签依赖人为每类子任务定的首/末帧规则；附录 C 跨任务换物体只有图注、无数值。

来源：arXiv 2510.20328v1（2025-10-23）§1、§3.2–3.3、§4、§5、表 1–4、附录 A/D/E。机制图为本刊依原文文字自绘的示意，簇与提名次数为虚构例子；结果表数字为原表重绘；无原论文插图。
初筛：Sol 记录 batch b038（screen 88.75，G4/M4/X4/E3）· Opus 5.5 原文核对通过 2026-10-22 · 本刊未运行论文代码 · Embodied-Harness-Daily Reel