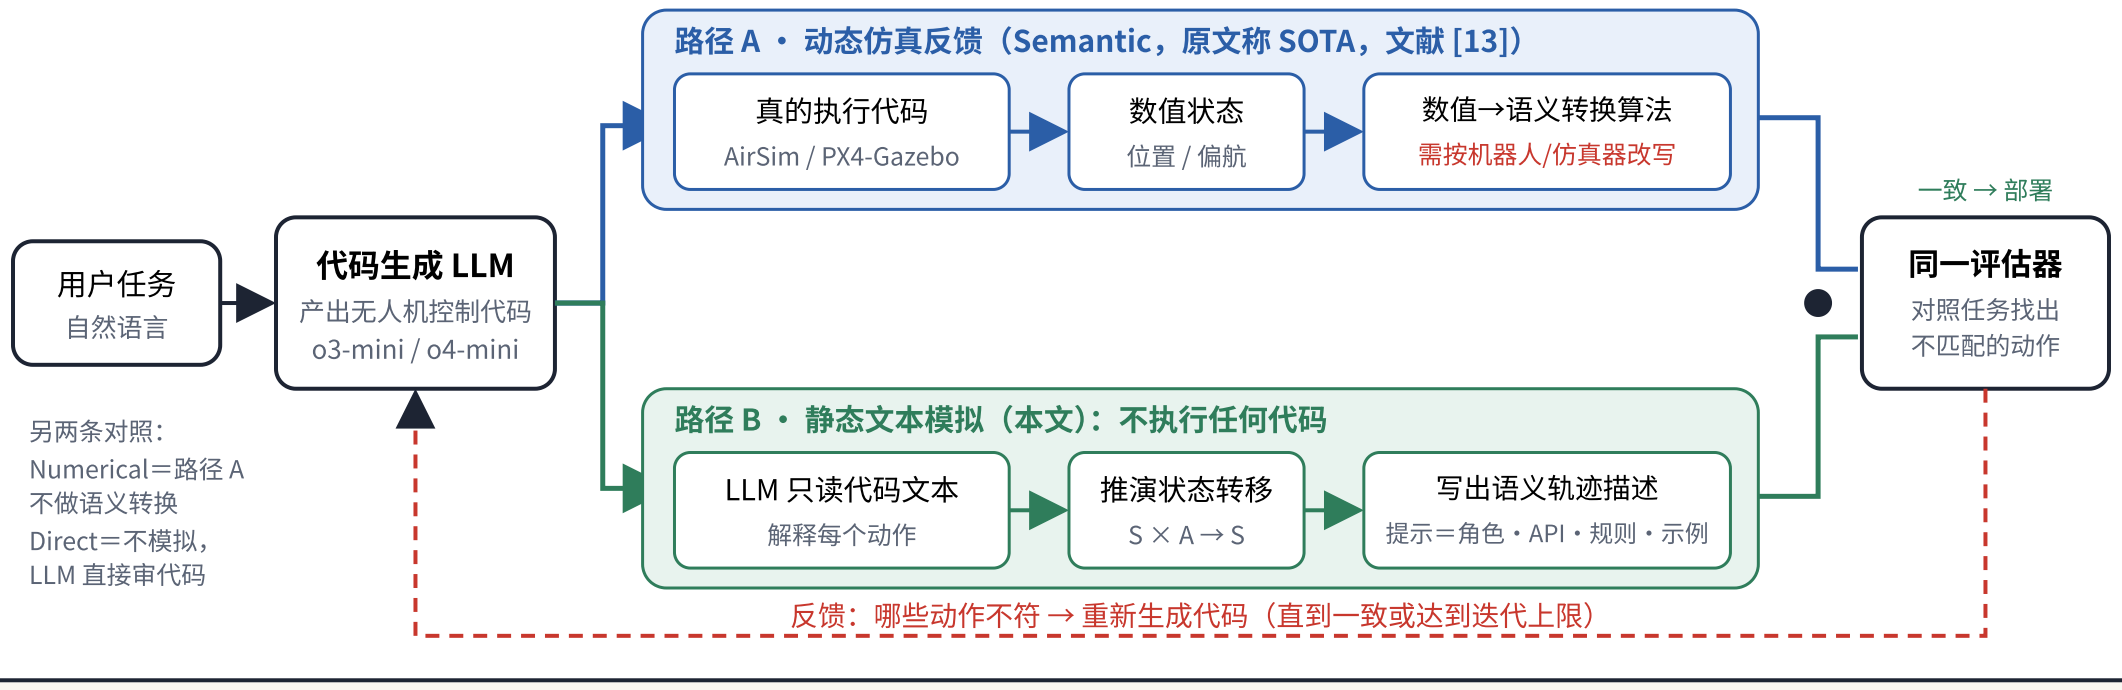
修机器人代码，不跑仿真器：LLM 读代码“推演”轨迹，与真仿真反馈持平

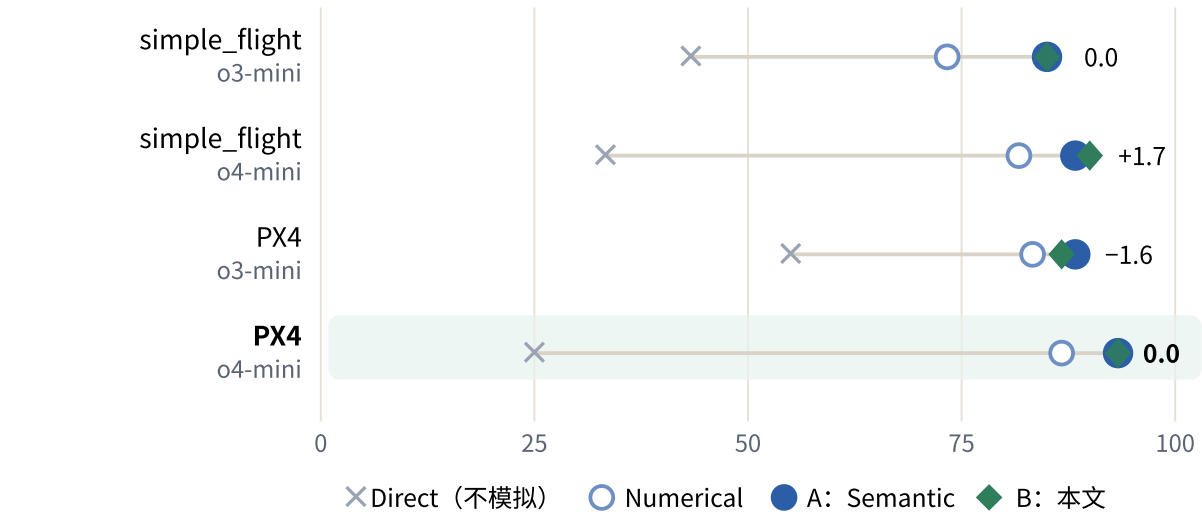
LLM 写的机器人代码靠“执行—观察—修改”环来纠错，但执行要么上真机、要么搭专用仿真器，**配置费工、跑得慢**。在有明确运动 API 与执行规则的任务上，改用 LLM 对代码做静态文字模拟，纠错效果还能保住吗？

两条反馈路径，汇入同一个评估器

示意（本画报依据原文 §III、§IV-A3 与 Fig. 1–2 文字自绘）；评估器、代码生成器、任务集与重复次数两条路径相同



汇合点：四种设置下的任务成功率 SR（%）



差值＝本文 − Semantic。四格差在 −1.6 至 +1.7 之间；不做任何模拟的 Direct 只有 25.0–55.0。每格为 20 个任务 × 3 次重复的平均（Table I–II）。

最强设置 PX4 · o4-mini

93.3 = 93.3

文本模拟（B）与动态仿真（A）任务成功率相同；动作完成度 96.9 vs 98.6

同一批代码上的中间检查	B 本文	A 仿真
轨迹描述准确率（正确代码）	97.5 / 100	100
评估器判对率（对/错代码均值）	91.7	92.1

Table III（o3-mini / o4-mini）、Table IV。作者解释 A 略高：LLM 对同一动作的描述措辞会变，确定性转换没有这种歧义。

文本模拟靠什么：去掉提示里的“执行规则”或“示例”就会掉（Table V，SR %）

骨干	完整（角色＋API＋规则＋示例）	去规则	去示例	两者都去
o3-mini	85.0	83.3	81.7	**71.7**
o4-mini	91.7	83.3	83.3	**68.3**

规则＝坐标系、偏航正负、初始朝向等原文附录 VI-A 的 5 条约定。真机：Holybro X500 无人机与 ROSMASTER X3 地面车各 8 个任务，SR 87.5–91.7%（Table VI）。

关键研究动作

在已有的“生成—执行—评估”修码环里，**只把“执行”换掉**：评估器、代码生成器、20 个任务和 3 次重复都不变，用 LLM 读代码、推演状态、写轨迹描述，替代在 AirSim / PX4-Gazebo 中真跑代码再转成语义描述。同时保留 Numerical 与 Direct 两条参照，区分“语义描述”和“有无模拟”各自的作用。

边界

- 任务只用起降、fly_to、偏航等运动学 API 的**规则化航迹**（每题 6–19 个动作），不涉及接触、障碍或动力学。
- “不跑仿真器”只指修码环；最终 SR 仍由仿真器/真机状态测量。
- 方法 A 来自文献 [13]，实验中为适配不同仿真器改写了其转换算法；配置与时延的节省**未量化**。
- 只报 3 次重复均值，无方差；真机每平台 8 题。不是安全认证，也不等于通用物理世界模型。

数字均出自原文 v3：§IV-A（20 个 Advanced 任务、6–19 个动作、3 次重复、o3-mini/o4-mini、AirSim simple_flight 与 PX4-Gazebo）；Table I–II（SR）；Table III–IV（模拟/评估准确率）；Table V（提示消融；o4-mini 完整版 91.7 与 Table I/II 各格不同，原文未说明对应控制器）；§V Table VI（真机）；附录 VI-A（提示与规则）。流程图为本画报自绘示意。逐项映射见 SOURCE.md。本画报未复现实验。