在线蒸馏目标 · arXiv 2603.26666v1（2026-03-27）· VLA-OPD

在学生自己走到的状态上蒸馏：用哪种目标才不会训崩？

学生 VLA 只用 1 条示范微调，跑起来很快偏离示范轨迹。让冻结的教师在**学生实际访问的状态**上给出逐 token 的动作分布，再拿什么目标去对齐——前向 KL、硬标签交叉熵，还是反向 KL？

① 学生采样（on-policy）
学生自己跑 G 条轨迹
状态来自学生的访问分布，包括偏离示范的“出错状态”

→

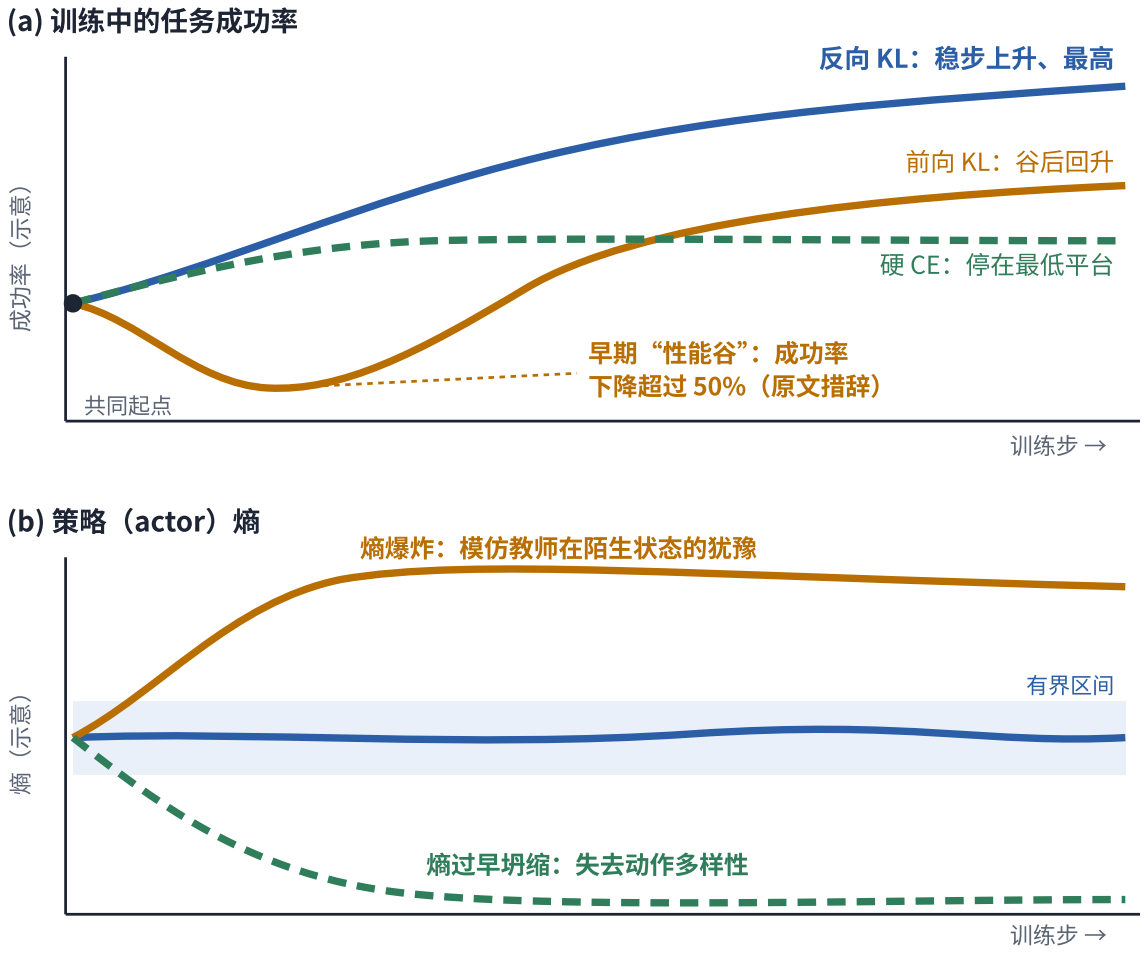
② 教师逐步标注
冻结教师只给 logits
在同一状态读教师动作分布，**教师动作不执行**；需白盒、同一动作词表

→

③ 优化（本文选择）
反向 KL 作为稠密奖励
$r_t = -(\log \pi_\theta(a_t|s_t) - \log \pi_{tea}(a_t|s_t))$，组内平均做策略梯度，不用环境成败奖励

同一设置只换对齐目标：成功率与策略熵如何分岔 示意

RoboTwin2.0 Beat Block Hammer 单任务 · 批大小 32 · 原文 §4.4 / Fig. 4。曲线形状按原文文字重绘，**不是原始数据，纵轴无刻度**



前向 KL　`D(π_tea ‖ π_θ)`

覆盖教师全部概率质量（mode-covering）。学生到了陌生状态，教师自己也拿不准、分布变平，学生被迫连这份犹豫一起学。

→ 熵爆炸，早期成功率掉进深谷

硬标签 CE　`CE(argmax π_tea)`

即常见 DAgger 做法：只追教师 top-1 动作，丢掉软概率。教师 argmax 在多峰边界来回跳时，学生被硬拉着走。

→ 熵过早坍缩，停在最低平台

反向 KL（本文）　`D(π_θ ‖ π_tea)`

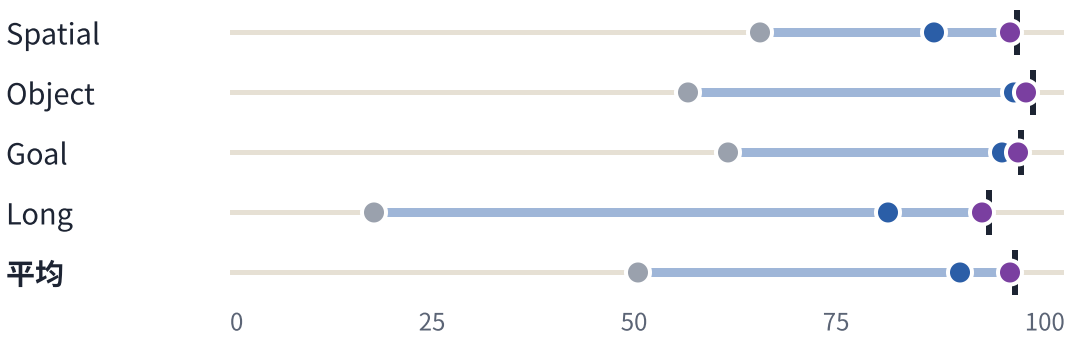
零强迫性质：学生选的动作只要落在教师认可的质量内就不受罚，可以忽略教师长尾的不确定，同时在有效模式内保留随机性。

→ 熵保持有界，成功率最高、最稳

机制解释为作者的分析（§3.4）；实验证据是左图这一组单任务曲线，原文未给出曲线的具体数值、种子数或置信区间。

LIBERO：学生只用 1 条示范/任务初始化

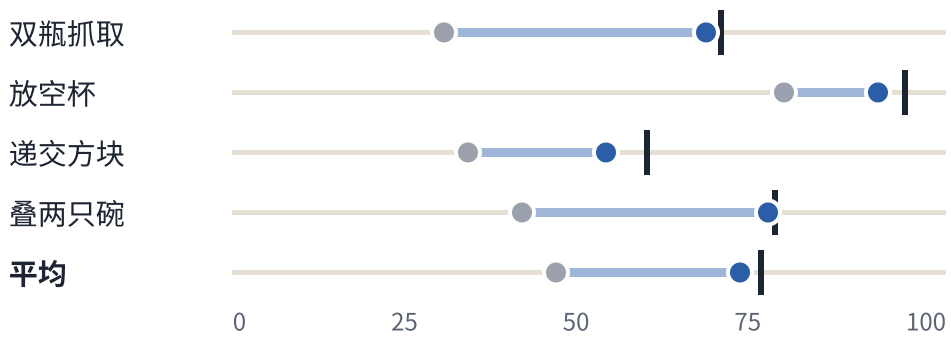
OpenVLA-OFT 学生 · 教师 SimpleVLA-RL · 批 64、G=8 · 成功率 %（原文 Table 2）



同表 50 条示范/任务的全量基线：Octo 75.1、OpenVLA 76.5、π0+FAST 85.5、Nora 87.9（不同训练设置，非同条件对照）。效率：LIBERO-Long 约 50 步达近 80%，GRPO 需 150 步以上（Fig. 2）。

RoboTwin2.0 双臂：学生已用 1000 条示范/任务

四个代表任务 · 成功率 %（原文 Table 3）· 只报“只蒸馏”



学生被教师上限封顶：四项均未超过教师。同表 π0 50.5、RDT 32.0。

遗忘（§4.3 / Fig. 3）：在 4 个留出任务（2 Object＋2 Spatial）上，离线 SFT 越学越好时留出任务成功率坍塌（Object 接近 0），OPD 与 RL 大体保持。只有散点图，**原文未给数值**。

边界：这张图能说明什么、不能说明什么

- 目标对比只有**一个任务**（Beat Block Hammer）、一种批大小的训练曲线，无数值、种子数或区间；“反向 KL 最优”是这一组曲线上的结论。
- “1 条示范”只是学生的初始化；教师 SimpleVLA-RL 本身已用 RL 训练，其成本不计在内。学生成绩受教师上限约束。
- 需要**白盒教师 logits**，师生同一动作词表；不适用于只返回动作的黑盒 API 教师。
- 全部为仿真（LIBERO、RoboTwin2.0），无真机；遗忘只在 4 个留出任务上以散点图呈现。

来源：Bridging Offline SFT and Online RL for Vision-Language-Action Models via On-Policy Distillation，arXiv 2603.26666v1。数字取自原文 Table 2、Table 3、§4.2–4.4；上方成功率/熵曲线为本画报依据 §3.4 与 §4.4 文字绘制的示意，非原论文图。我们未运行代码、未复现实验。