agent 说“完成了”，物理终态不一定同意

通用多模态模型只拿 **RGB 图像 + 标定几何 API**，自己挑像素、估 3D、定抓取位姿、写代码闭环操作——**它对“做没做成”的自我判断，能不能当成绩用？** CodeActionBench 把这句自报和一个**不回传结果的隐藏物理验证器**分成两条账分别记录。

动作 固定一切可固定的，只把“看、估、做、判”留给 agent

所有配置共享

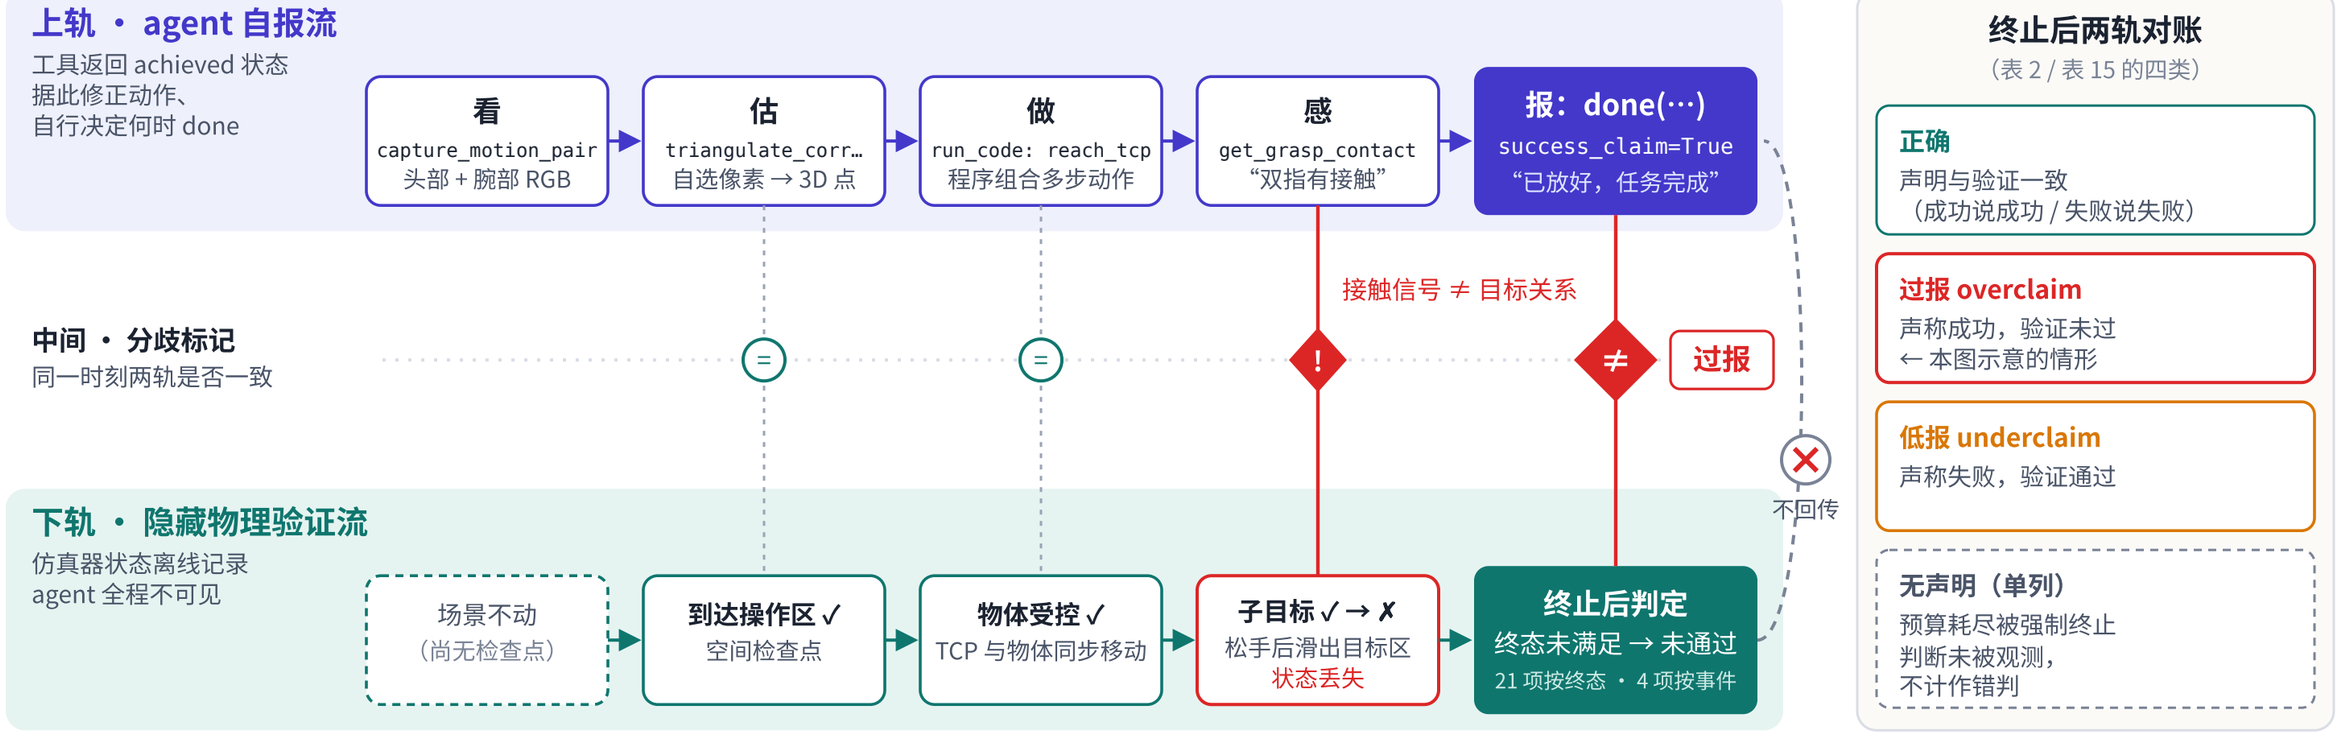
- **25** 个任务 · 每任务**固定场景种子**
- 29 个机器人工具 + **run_code** + **done**
- 每任务**工具调用**与**仿真时长**双预算
- 验证器结果**从不回传**
- 特权参考解经同一公共 API 在预算内解完 25 例（不给 agent）

刻意不给 agent

~~深度图~~ ~~物体位姿~~ ~~专家感知/抓取模块~~ ~~任务专用抓取/放置目标~~ ~~预设技能与演示~~ ~~验证器状态~~

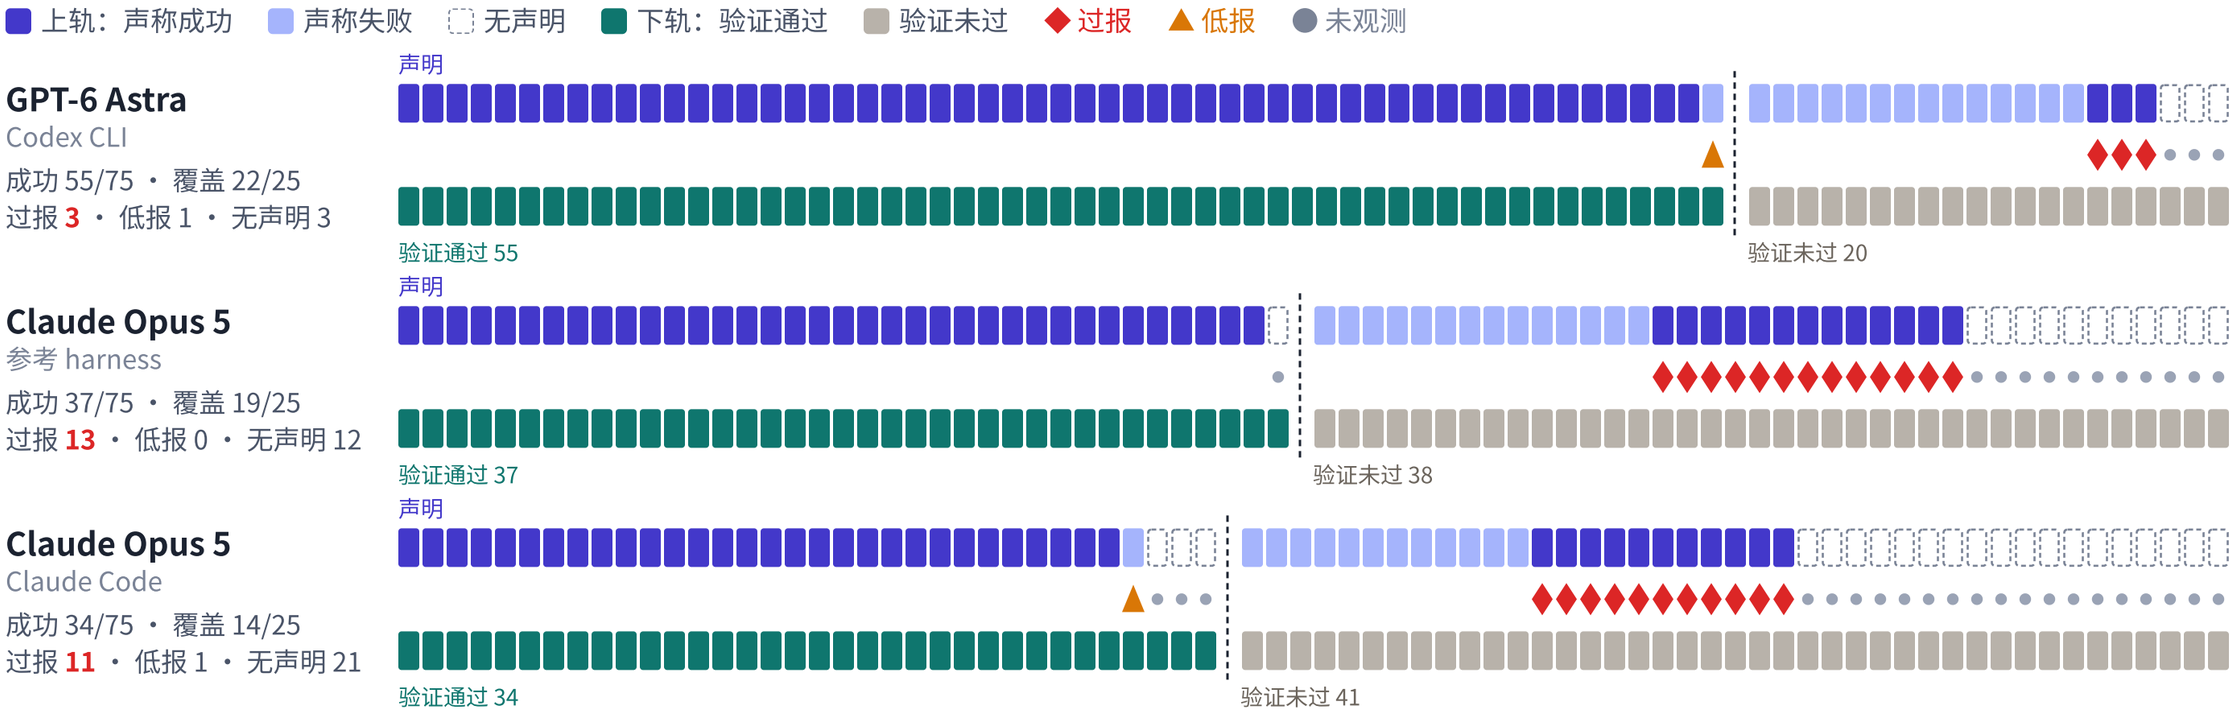
几何工具只按 agent 选的像素与假设计算（射线、三角化、平面求交），**不替它选对应点、不检查假设**。

机制 一次尝试里的两条轨：上面是 agent 看得见的，下面它看不见 示意



示意：节点为原文接口与检查点概念的自绘串联，不是某次真实轨迹；“子目标得而复失”对应附录 F 的状态丢失类。

结果 75 次尝试逐格对账：差距主要出在“失败时能否承认没做成” 表 2、表 10、表 15 重绘



每格 = 一次尝试（同 25 个固定实例 × 3 次），按“验证通过 | 未过”分组、组内按声明类型排序；格子顺序为重排，不代表时间。成功率差距之外，**失败中正确承认失败**：14/20（70.0%）· 14/38（36.8%）· 12/41（29.3%）。

harness 控制了多少？——只有一组同模型对照

Claude Opus 5	参考 harness	Claude Code
成功 /75	**37**	**34**
覆盖（≥1 次成功）/25	**19**	**14**
失败中过报	13/38	11/41
无声明	12	21

最强 GPT-6 Astra **只在 Codex CLI 下测**，73.3% 是“模型 + harness”整机成绩，不能拆成模型净效应；作者也把跨 harness 比较定义为整机比较。

其余 6 个配置（同一参考 harness）：多数没留下判断

配置	成功/75	显式声明	其中过报	无声明
Gemini 3.6 Flash	**15**	37	19	38
GPT-5.6 Sol	**12**	21	9	54
Qwen 3.8 Max	**11**	29	6	46
Grok 4.6	**9**	20	5	55
Kimi K3	**9**	20	7	55
Claude Sonnet 5	**2**	5	1	70

参考 harness 内推理档与输出上限也不全同（Qwen 为 Medium，Grok 输出 8,192 token），只算近似等条件。

限制 这张账能说明什么、不能说明什么

只有一个固定场景
单一仿真双臂（RoboTwin 2.0 / SAPIEN），每任务一个场景种子、3 次；覆盖 22/25 不是跨场景泛化，真机未测。

大量判断未被观测
491 次失败中 345 次（70.3%）没有声明，多为预算耗尽；过报率只在说了话的失败里可见。

harness 未完全交叉
9 个配置里仅 Opus 5 换过 harness；榜首成绩混入 Codex CLI 的上下文管理与计算环境差异。

诊断不是因果
失败按最早有证据阶段归类（481/491 回放全程验证，6 条未决），不认定唯一原因；代码与日志仅“计划发布”。