子任务都会做，长程却只成 19%：先找“最早没修好的那个错”，再在那里加工具

作者没有去训练更强的策略，而是**冻结同一个子任务 VLA**，把 81 个失败集逐个追溯到最早未恢复的错误，再在规划、底盘交接、末端接触三个断点上分别注入干预。

80% 子任务 VLA 原子任务成功率 → **19%** 组合成 20 个长程移动操作任务（RoboCasa365，100 集）　参照 **41%** 按子任务独立 0.8 连乘的粗略期望，实际明显更低

一个失败集的时序信息路径

示意 · 本刊据原文自绘

1 执行中

错误发生 规划器每步派一条子任务指令，VLA 执行 350 控制步后交回

S1 走到台面 ✓ → S2 抓面包 ✗ 空抓 → 重规划 ① ② ③ 仍未抓到 → S3 放置 ✗

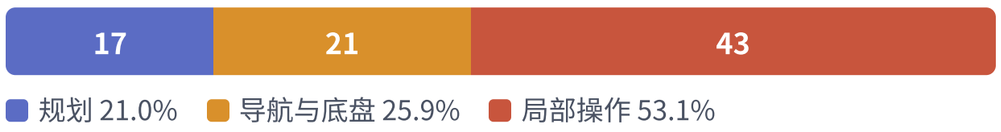
检查窗口：错误后 **3 次重规划**内若补完该子任务，记为“已恢复”，不计主因。基线 100 集：**成功 19，失败 81**。

2 离线复盘

定位 t*：最早未恢复错误 仿真器状态仅离线可见，在线 Agent 拿不到

在仍阻断完成的错误里取**最早**的那个，标在“源头”而非后果上：上例中放置失败归因于**抓取**。3 次 Codex 给候选，3 名人工按规则复核；随机 30 集粗类一致 26 集，**Fleiss κ=0.86**。

81 个基线失败集的主因分布



3 在线执行

在出错的那一段注入干预 按执行顺序，各管一个断点

规划：丢了进度

`skill card + recall_memory(q)`

训练集示范 → 技能卡（子任务顺序、关键帧、完成判据），评测前固定；规划器按需提问，从 ≤256 帧**过去**观测中取回 16 帧。

交接：到了但站位不对

`check_stance → approach_xy / goto_stance`

目标距离 d（掩膜深度反投影）

d ≤ 0.75m 可达	边缘	d > 1.00m
直接交给 VLA	平移 ≤0.25m，朝向不变	重选站位 + A* 障碍膨胀 0.10m

接触：差一点没对准

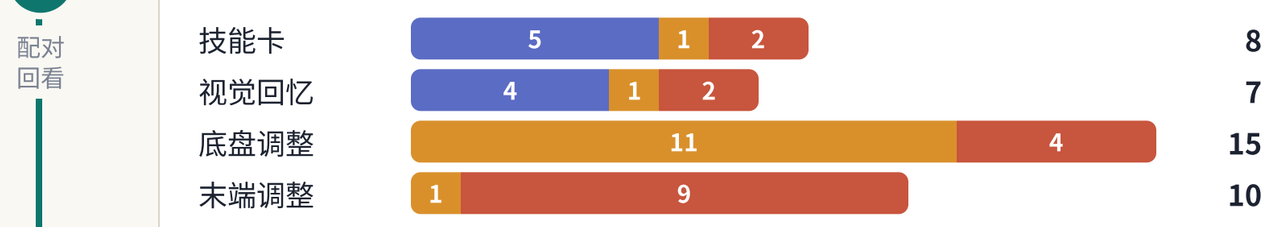
`EEF adjust`

Grounding DINO+SAM 掩膜点云取**中位数**定目标、估表面法向，沿法向做一次有界修正，单次 ≤0.30m，再交回 VLA 重试。

子任务 VLA 全程**冻结、同一 checkpoint**；干预只改“下一步说什么、看什么、从哪站、末端在哪”

4 配对回看

恢复：谁修好了哪类失败 同 100 个开发集配对，按“加入前的主因”统计



对应关系基本吻合；作者注明这是 episode 级观察，不是一一因果分解。

瓶颈后移：剩余失败集中到接触阶段



其中 12 集是前段被修好后、走到接触阶段才失败。

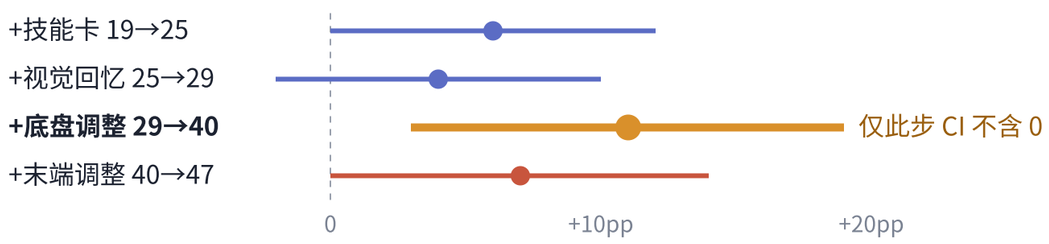
结果：同一 VLA、同一规划器下的对照

RoboCasa365 留出 episode（设计冻结后才测）

18% Harness VLA 改编基线 → **49%** 完整系统　配对差 **+31pp**，95%CI [21, 41]，p<0.001

- 20 任务 × 5 个留出 seed = 100 集，场景布局与物体初值不同于开发集
- 同一子任务 VLA checkpoint，规划器均为 Kimi K3，planner 与 retry 预算匹配
- 官方 RoboCasa365 评测器；配对 McNemar + 按任务分层 bootstrap

逐步加入（开发集，配对差与 95%CI）



迁移：同一干预设计，低层策略换成本域训练

BEHAVIOR-1K · 5 任务 × 20 匹配集 = 100

低层 VLA 用 BEHAVIOR-1K 训练数据**重训**；5 个任务均提升，未报告配对检验。

真机 Astribot-S1 · 2 任务 × 10 次 = 20

π0.5 在 500 / 300 条真机示范上微调后作子任务 VLA；两任务分别 2→6、3→7 次成功；样本小，无显著性检验。**迁移的是干预设计，不是零样本策略迁移。**

边界与限制

check_stance 只按距离分级，**不检查关节限位、IK 与全身碰撞**；剩余 47 个操作失败多为错放、搬运掉落、碰撞扰动，现有几何修正管不到。

诊断与组件开发用的是同一批 100 个开发集；干净证据是留出集 18%→49%。视觉回忆、末端调整等单组件效应 CI 含 0 或贴近 0。

额外调用 Gemini 3.5 Flash、Qwen3.8-27B、Grounding DINO+SAM 的开销与时延未报告；只证明本系统干预有效，不证明“诊断驱动”优于其他设计流程。