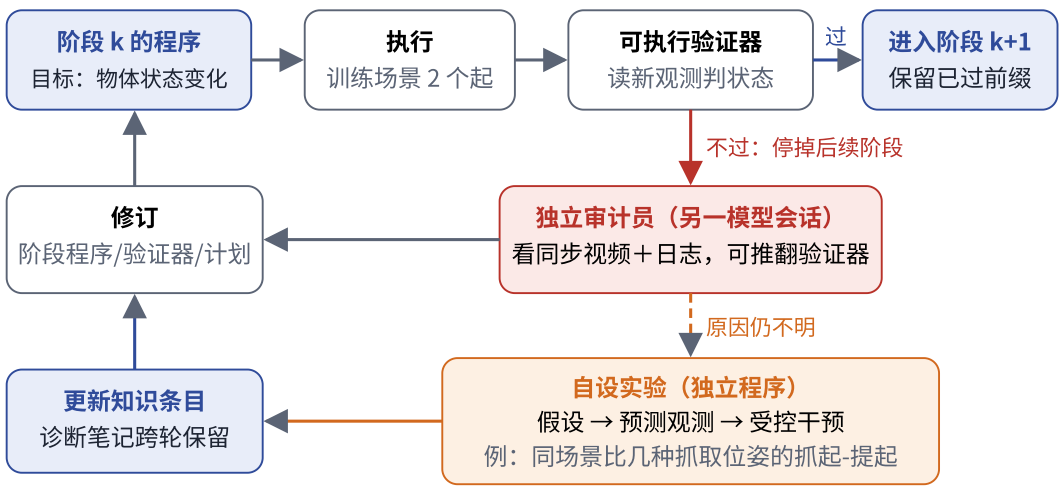
改机器人程序，先测量、分阶段验收、做实验（真机仍需人重置与判分）

编码智能体写“感知＋控制原语”程序、执行、看失败再改。作者在基线运行里看到三类反复出现的卡点：**不该用的抓法一直在改参数**、**照搬别处的数值抓空**、**前一步没成就接着做下一步**。问题：程序搜索缺的是更多改写次数，还是可迁移的物理理解与当前场景的实测？

	a · 抓法本身不适用	b · 数值照搬	c · 中间效果没核实
基线里的失败（Fig. 3，作者案例）	CaP-Agent0 对书反复用自上而下的抓取，只改参数，不换策略	ASPIRE 把另一只杯子的抓取高度硬编码过来，夹爪在空中闭合	灶没点着，仍继续放锅；失败后也不知道旋钮该转多远
对应组件（§3.1–3.3）	**分层知识库** 按物体类存“可供性 / 空间关系 / 动作效果与前提”，写明适用条件和要现场测哪些量、怎么测，不存数值；另存已验证程序作技能	**场景落地** 按任务挑相关物体，用 Molmo2 指点＋SAM 3 分割＋深度测出抓取点、尺寸、朝向；看不清可移动手臂换视角	**分阶段验收＋自设实验** 每阶段带一个读新观测的验证器，不过就停；独立审计员看视频改判；原因不明时另写实验程序检验假设

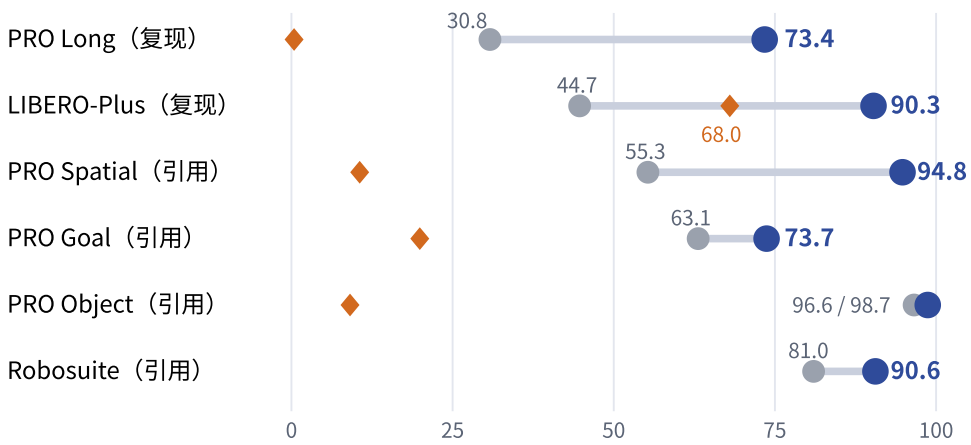
一次搜索里发生什么（据 §3.3、附录 C.3 重绘）



换视角与实验的执行都计入同一 rollout 预算；任务级成功仍以环境判定为准。
审计员和验证器的准确率原文未报告。

同一组原语，对比最强编码基线 ASPIRE

按套件平均成功率 %；搜索用 15 个训练场景，冻结后在 50 个不相交测试场景评（Robosuite 100）。● RoboAuto ● ASPIRE ◆ π0.5（官方 LIBERO 微调）



“复现”：作者用相同 Claude Opus 4.6（1M）跑 ASPIRE 等基线；
“引用”：基线数取自原论文，编码模型与协议未必相同。

不是处处领先：LIBERO-Plus 的布局扰动上 π0.5 为 98.0、RoboAuto 96.0；Robosuite 双臂交接 75 vs ASPIRE 92；83 个设置中 **18 个低于 ASPIRE**（附录 B.2）。螺母装配 74 vs 基线均 <10。

逐个加组件（5 个任务，累加）

最终程序测试成功率 %（附录 Table 12）；每列在前一列基础上加组件，单次搜索

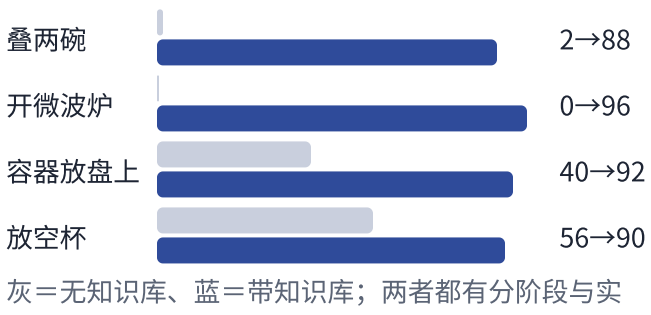
	基础循环	＋分阶段与实验	＋知识库	＋场景落地（全系统）
点灶＋放摩卡壶	8	82	84	92
放杯子＋布丁	4	4	78	94
拿小碗旁物体（布局）	14	10	30	94
从柜顶抽屉取碗	0	0	0	78
碗放到灶上	0	0	0	98
平均	5.2	**19.2**	**38.4**	**91.2**

没有知识条目时“场景落地”无物可测，二者不能单独拆开；审计员与实验也未单独消融。知识库只给一半条目：65.2（同预算）。

知识库能不能带走

同一份 LIBERO-90 知识库（每个源任务一段示范视频构建，与评测任务不相交）

RoboTwin 2.0：换仿真器＋双臂本体（11 次搜索预算）



灰＝无知识库、蓝＝带知识库；两者都有分阶段与实验。均值 24.5 → 91.5，token 9.3M → 23.6M/任务。

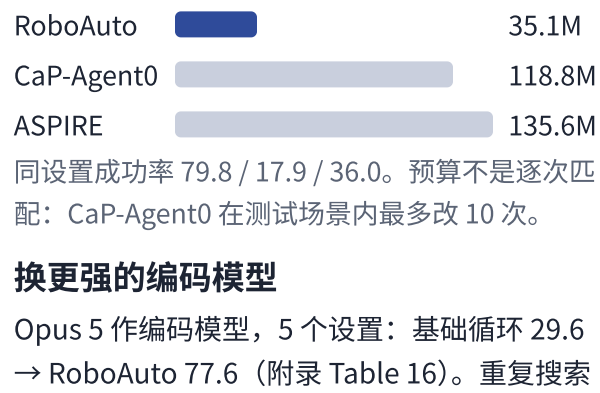
真机 WidowX AI · 3 个未见长任务 · 每任务 20 次



阶段完成分（不是整任务成功率），由人评分；搜索 10 次，每次成败由人判定、由人重置。

花了多少

16 个 LIBERO-PRO Long / Plus 设置，各方法原生配置，每任务 token 几何均值（附录 B.8）



同设置成功率 79.8 / 17.9 / 36.0。预算不是逐次匹配：CaP-Agent0 在测试场景内最多改 10 次。

换更强的编码模型

Opus 5 作编码模型，5 个设置：基础循环 29.6 → RoboAuto 77.6（附录 Table 16）。重复搜索 3 次，3 个任务标准差 3.1–4.0 点。

限制与读法

1. 每个任务仍要单独搜索：在 15 个训练场景上用**环境成功判定**反馈、45–55 次 rollout；泛化指同任务换场景，不是零样本新任务。
2. LIBERO-PRO 短任务与 Robosuite 的基线数取自原论文，只有 Long / Plus 两套在相同编码模型下复现；主比较的完整预算没有逐次对齐。
3. 消融只在 5 个任务、累加一次；“场景落地”与知识库耦合，审计员、实验各自的贡献与验证器误判率未报告。
4. 自主搜索只在仿真；真机由人判定搜索成败、重置场景、负责安全，结果是阶段完成分。

关键研究动作

把“这个物体该怎么动、要测哪些量”从一次次程序改写中抽出来，作为跨任务保留的条目，再在每个新场景里实测并逐阶段核验；同一知识库换仿真器和双臂本体后，无知识库 24.5 → 有 91.5。

数字出处：§1、§3.1–3.3、§4.1–4.4（Fig. 3、5–7、Table 1）；附录 A.2（Table 2 预算）、A.4（基线来源）、B.1.5–B.1.6（Tables 3、13）、B.2（Tables 4、11）、B.3–B.8（Tables 12、14–20）、C.3、F。机制图为据文字重绘；条形图按原表重绘。未运行论文代码，未复现。档位为问题评价，不是审稿结论。