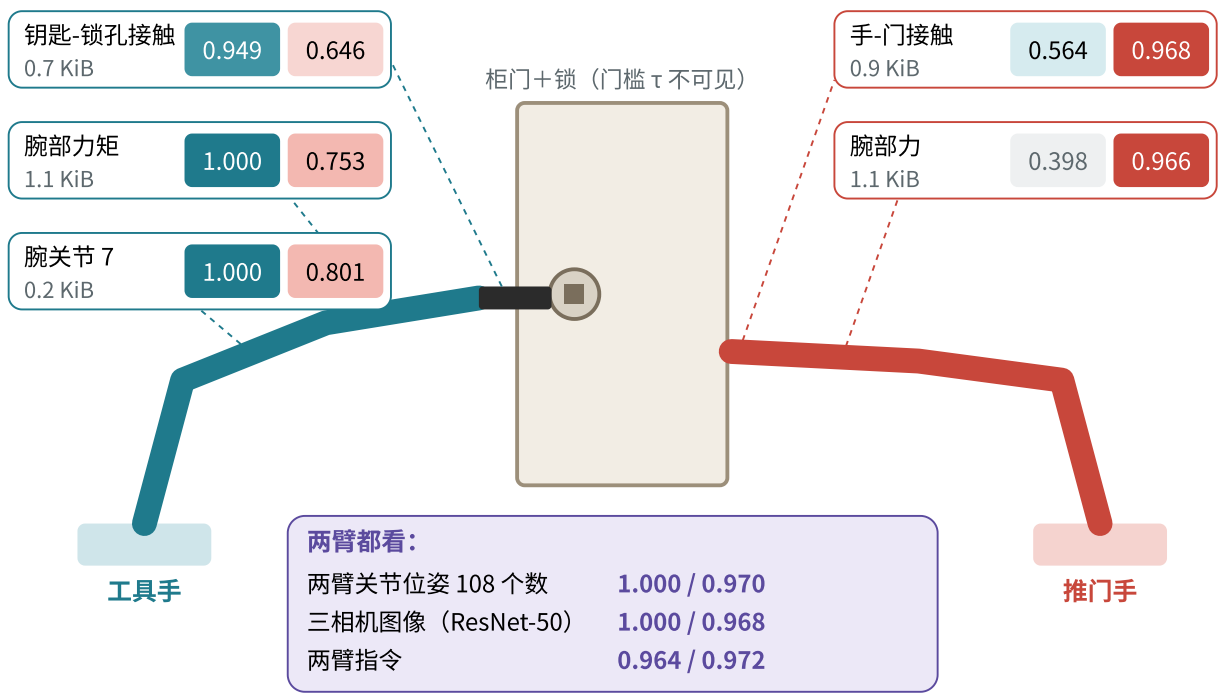
门没开：是拿钥匙的手晚了，还是推门的手晚了？（仿真 · 单一锁具）

一只手把方头钥匙插进锁芯并拧住，另一只手推门；钥匙一松就回弹，**两只手必须同时到位**，推力还要超过每次随机抽取、任何观测里都没有的门槛 τ。现有 VLM 失败诊断器多在单臂、扰动成功示范得到的失败上训练和评测。问题：诊断器要**看到什么**才能说出是哪只手的问题？VLM 看到了，会不会说？

传感器装在哪，就读到哪只手（Table 1，组内 AUC）

同一个 L2 线性探针逐通道拟合，按门五折留出。每个标签两格：**工具手晚** / **推门手晚**（各自对“推力不够”区分；0.5＝瞎猜）



单手传感器主要读**自己这只手**的延迟（交互效应：力矩 vs 推门手力 +0.811 [+0.573, +1.072]）。工具手晚时推门手每次推得一样，**推门手的传感器会把它当成“推力不够”**，据此修复就会去加力。只问“两只手有没有重叠”，关节位姿 0.986，单手通道 0.631–0.863。

三类原因，各在哪里可读

758 次尝试、17 扇门；每次失败的类别由录得的机构轨迹判定，不靠人看视频

① 工具滑脱（cam-out）→ 工具手

钥匙插得不够深，拧时从锁孔里转出来，但手仍握着。工具手腕力矩 0.972、接触 0.986；推门手的力 0.519、接触 0.512（≈瞎猜）。前相机单独 0.768。

② 哪只手晚 → 需要覆盖两臂

两臂通道两半都 ⩾0.96（左图）。但这依赖脚本的延迟时间表：两臂随机起动时，位姿 / 指令 / 图像都 ⩽0.65，只有“相对起动时刻”仍可分（1.000 / 0.990）。

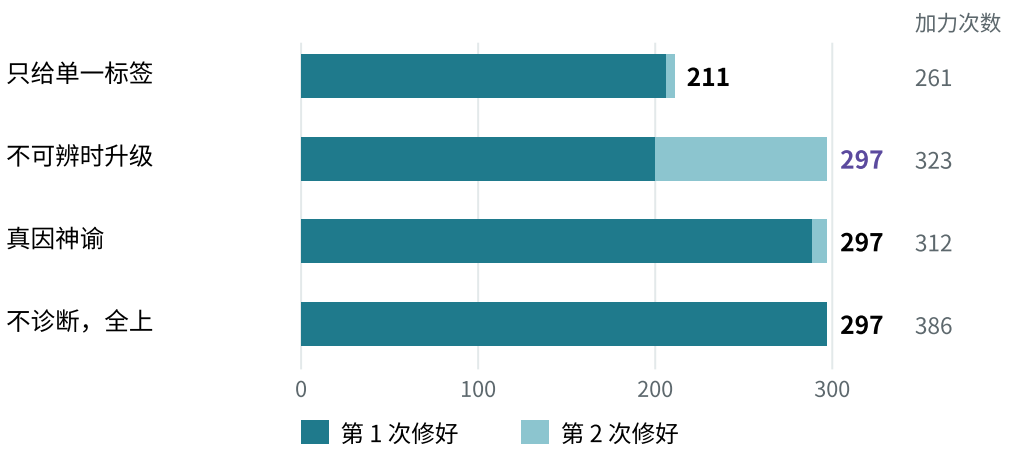
③ 既晚又推力不足 → 没有被动传感器能读

119 次双因失败：同一世界回放，只改时序成功 3 次、只降门槛 0 次、两者都改 119 次。工具手晚时，任何被动读数的理论上限 **恰为 0.500**（同一扇门推门手每次给的力相同，成败只取决于 τ）；所有通道 ⩽0.554，含 τ 的门闩真值 1.000。

推门手晚时有两个通道超过上限（0.731、0.616），作者承认上限假设可能失效；计入 24 次比较后与偶然一致（p＝0.12、0.65）。

诊断决定修复：386 次受阻尝试，最多两次

每次都在同一世界回放各种修正：重新对时、加力推（3 倍深度）、或两者都做（附录 Table 2）



“升级”只问两只手有没有重叠（位姿探针 0.992），先做对应修正，不成再两者都做：两次内修好 297，比单一标签多 +0.223 [0.169, 0.268]，与神谕持平。**但不诊断、两种修正一次全上也是 297**——诊断在这里省下的是不必要的加力（386 → 323），神谕的优势在第一次（289 vs 200）。双因失败两者都做也只修好 81/119。

VLM 状态里有，答案里没说

Qwen3-VL 8B，给前相机首尾两帧，问是/否题（每半 3 种措辞），分数＝首个答案 token 的 log P(是)−log P(否)



AUC（工具手晚 / 推门手晚）

状态探针（第 4 层起）	⩾0.956
答案（3 种措辞中位）	0.497 / 0.604
措辞间范围	0.468–0.976 / 0.368–0.973
先给一次成功作参照	0.971 / 0.793
但 cos 仍 0.011 / 0.027；删去探针方向，答案 AUC 只变	+0.002 / +0.009

同一模型同一对帧，问“第二帧门开了吗”得 0.865；问 cam-out 为 0.475。两个方向夹角为示意；数字来自 §6 与 Fig. 5。按成本：两臂位姿 108 个数，一次 VLM 调用约 3,056 GFLOPs。

限制与读法

1. 开环脚本控制器、仿真、一种钥匙锁机构、17 扇门；“两臂通道读出哪只手晚”只在脚本的延迟时间表下成立，随机起动时降到 ⩽0.65。
2. 修复是在同一世界（同一 τ）的回放，不是真实的第二次尝试；“升级”与“不诊断全上”两次内修好数相同。
3. VLM 部分只测一个模型、两帧前相机、是/否首 token 分数；不是学习型策略或真机上的诊断。

关键研究动作

先用机构轨迹给每次失败定因，再对每个传感通道和 VLM 的内部状态 / 答案套同一个探针，并在拟合任何探针之前算出被动观测的可辨识上限——把“诊断器能说什么”拆成“传感器看得到什么”和“模型说不说出来”两件事。

数字出处：摘要；§1；§3.1–3.3（Fig. 3）；§4（Table 1，Fig. 4）；§4.1–4.3；§5；§6（Fig. 5）；§7；附录 A（Table 2，任务与类别定义）、附录 B（窗口、上限、随机起动第二批 400 次）。机械臂与门的场景图、两向量夹角均为示意；其余数值与图表按原文重绘。未运行论文代码，未复现。档位为问题评价，不是审稿结论。