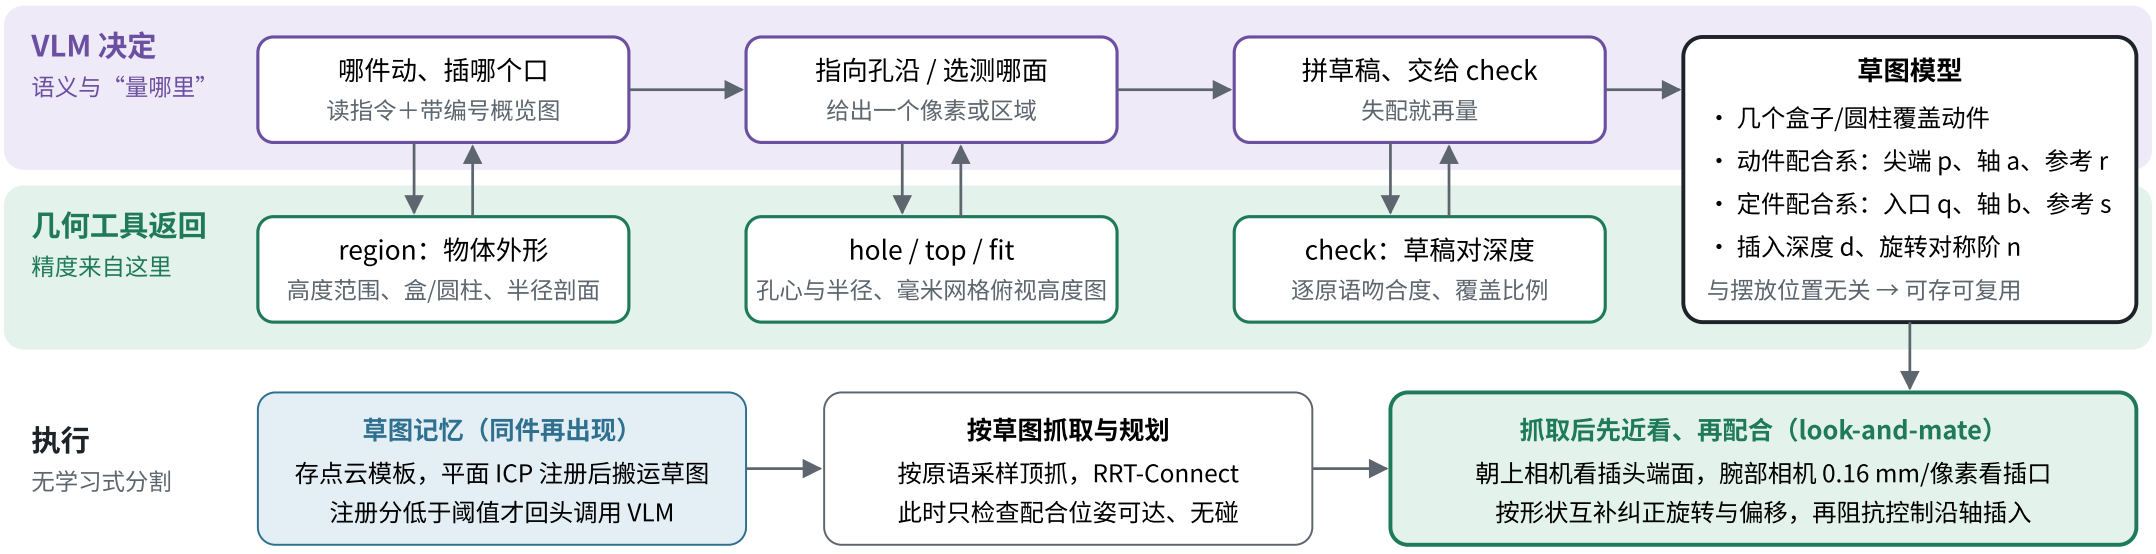
零样本精密插接 · VLM 智能体＋几何工具（多视角 RGB-D）· GPT-6.1-Sol · Franka 仿真（Isaac Lab 物理）· arXiv 2610.41844v1

VLM 决定量什么，几何负责量准：未见零件亚毫米插接 仿真 · 无噪声深度

插头、网口、销钉的间隙只有每侧 0.12–0.3 mm，许多零件还带键、只有一个方向插得进。现有零样本 VLM 操作把空间落在图像标记、关键点或体素值图上，分辨率是几毫米，还要 VLM 从图像里猜“哪一点对哪一点”。问题：不给 CAD、示范和任务训练，能否让 **VLM 只做语义决定、把测量与形状配准交给几何**，做到亚毫米、键向正确的插入？

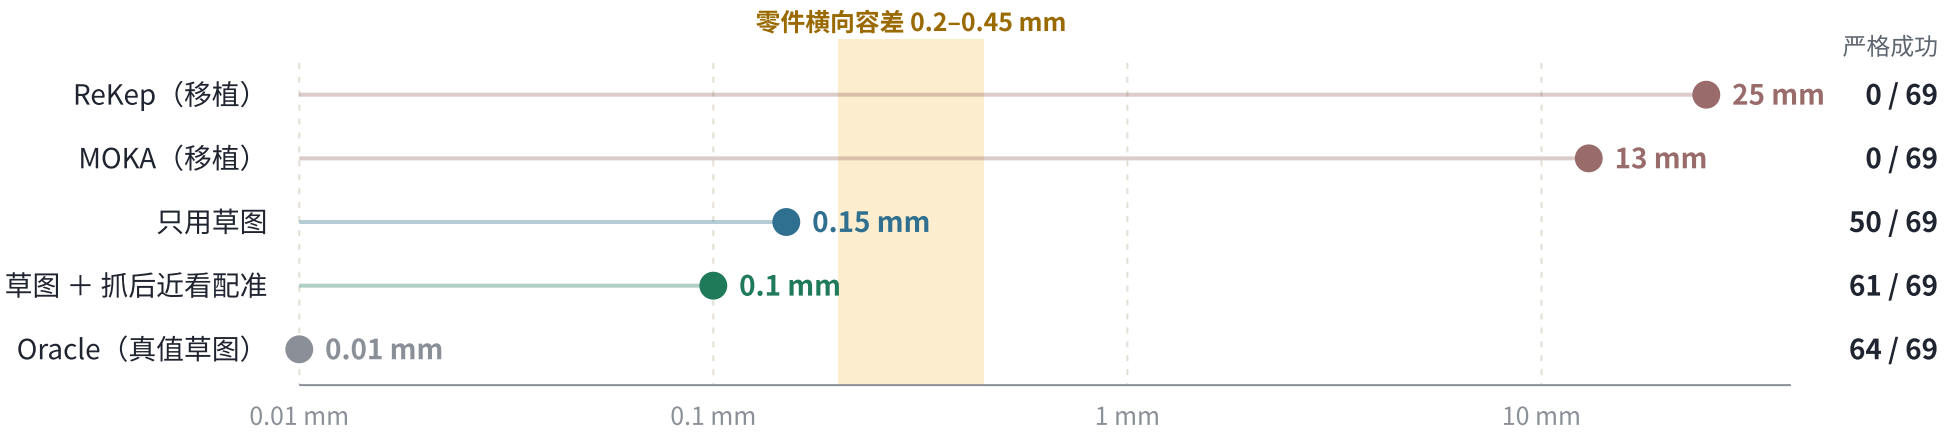
机制：一份“草图模型”，两条分工泳道

示意（据原文 Fig. 1–2、§3 与附录 A Fig. 5 重绘）。工具在融合点云上回答单一几何问题，返回以毫米计的 JSON；系统提示要求 VLM 数字取自工具而非图像。中位一次运行 17 次工具调用、约 90 s。



同一 VLM、同一规划器与控制器：误差差了两个数量级

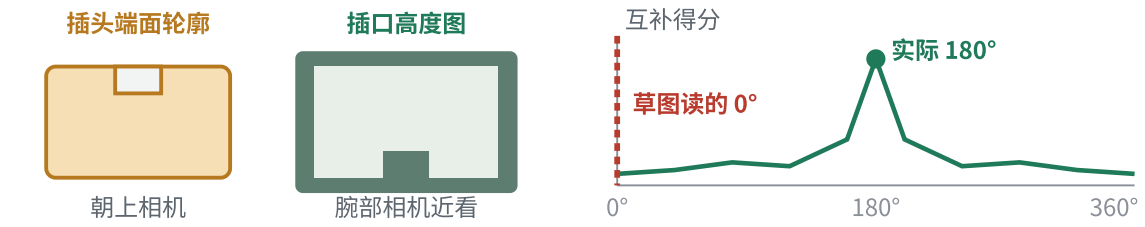
所有方法共用 GPT-6.1-Sol（medium）、规划器与柔顺控制器。ReKep、MOKA 为作者按原代码移植：两者原为厘米级容差的家居抓放设计，移植时还拿到仿真器实例掩码。它们最终位姿离开口中位 25 / 13 mm，常常还转错，失败发生在精度起作用之前。



横轴为对数刻度：开发集 69 回合最终位姿的横向误差中位数（Table 3）；右列为运动学严格测试成功数（Table 2）

键向读错，靠近看的几何纠回来

示意：一只单键插头的旋转打分（据 §3.6 与 Fig. 4 思路绘制，非原文数据）。



打分：轮廓边贴住墙且不穿透的格子加分、穿进实体的格子减分；
草图给出开口、轴、深度与搜索窗，几何给出旋转与亚毫米位置。
只靠形状匹配不行：整块板上它在 10 个任务中 3 次选到更松的插口。

57 → 83 / 86
键控零件的旋转落在容差内（全部 86 个带键回合）

36 → 82
其严格成功：增 46、失 0（精确 McNemar $p<10^{-13}$）

读错集中在少数零件：NEMA 5-15 插头 8 次摆放错 7 次、XLR 三次全错——VLM 对它们持有一致但错误的认识。场景相机高度图（约 0.4 mm/像素）也能纠旋转，但会把原本放准的零件挪偏：对真值草图做“近看”时，场景图丢 9/66，近看图只丢 2。

结果（运动学严格测试，计数）

方法	开发 69	留出 18	物理 66
ReKep / MOKA	0 / 0	–	0/10 · 0/12*
只用草图	50	6	54
草图＋近看配准	**61**	**18**	**60**
Oracle 真值草图	64	18	61/65 †

留出＝方法定型后才建的 6 种连接器（USB-C、HDMI、DP、XLR、Europlug、DC 圆口）各 3 摆放，物理测试同为 18/18（只用草图 10）。物理分母 66 排除动前已倒的起点；*基线只抽测部分回合；† 两者都有效的起点。

同件再出现：存一次，免再推理

草图来源（8 任务 × 4 新摆放）	严格	物理	出草图
每回合调用 VLM 智能体	30/32	28/32	90 s
记忆中 1 次运行（k=1）	**30/32**	**32/32**	**3.4 s**
k=4 次运行取平均	29/32	–	3.4 s

搬运过来的草图单独只成功 **9/32**（平均后只有 4），近看配准把它拉到 30：它同时纠正了草图继承的旋转与注册误差。失败都在近乎对称的 SFP、SC 上（翻面也插得进）。8 个任务按智能体的典型失败挑选。

限制与适用边界

1. 全部在仿真中，深度为精确无噪声渲染；真实深度传感器可能把毫米级开口糊掉，论文没有真机实验。
2. 需要额外两路相机（桌面朝上相机、腕部相机），并假设近看之后抓取保持刚性。
3. 只覆盖沿单一轴直线插入；螺旋运动、多步装配不在范围内。
4. 低于相机分辨率的键（如双工 SC）仍取决于 VLM 读到的方向；间隙约一像素时近看也会偏（RJ45 偏 0.23 mm）。
5. 基线是移植版、原为厘米级任务设计，“0 成功”说明其表示不适合插接，不说明原方法在原任务上失效。
6. 记忆只对见过的任务有效；复用评测的 8 个任务与开发集零件重叠。

来源：SketchMate: Agentic Geometric Reasoning for Zero-Shot Precision Insertion，arXiv 2610.41844v1（2026-10-30）正文 §1–5 与附录 A–E。数字的原文位置见同目录 SOURCE.md。泳道图与旋转打分为示意，非原论文实验图；未运行论文代码，未复现。入选依据为问题评价（problem-core-v1.1），不是审稿结论。