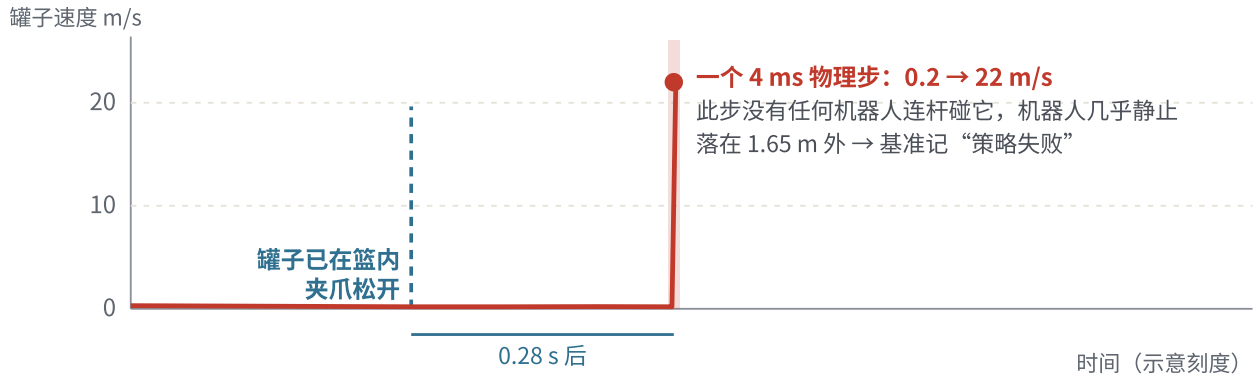
评测方法学（B 类）· 仿真基准审计插件 SimuGuard · RoboTwin 2.0 / LIBERO / RoboCasa / RoboDojo · 受审策略为 VLA 与世界动作模型 · arXiv 2610.41857v1

物体已经放好了，是物理引擎把它弹了出去（RoboTwin 2.0 · PhysX 5.3.1）

仿真基准只记录哪一回合失败，不记录为什么。引擎的接触处理造成的失败，和策略造成的失败进同一个分母。问题：能否把**一次接触报告追到这一回合的结局**、找出原因并修掉；修不了引擎时，又该**报告什么样的成功率**？

一回合的取证：Place Can Basket，LingBot-VA

示意（据原文 Fig. 1 与 §1 数值重绘，时间轴不按比例）。此步报告的“穿透”为 2.75 cm，而两块碰撞几何实际相距 2.1 cm；罐子获得的约 2.4 J 能量在记录中找不到来源。



SimuGuard 做三件事

挂在基准自己的评测脚本上，不改评测、策略与基准代码。

逐物理步记录：驱动、物体状态、接触（含冲量与穿透深度）；监控开/关时 59 条物体轨迹逐位相同。

逐位重放：从种子重建场景、从第一步回放记录的驱动；RoboTwin 273 条重跑的切换前前缀全部逐位一致。

单参数重跑：只改一个仿真参数（或引擎代码），驱动与成功检查不变，看结局是否改变。

检测规则：接触后突然加速、且重力下落与机器人经他物“带动”都解释不了，才标为**接触伪影**；5 位工程师盲审，40 段被标片段中 37 段判为物理上不可能（仅此一任务测过）。

根因：一个不随尺度缩放的常数

RoboTwin 把容器拆成 1–2 cm 大小的凸块

↓

PhysX 5.3.1 的 GJK 在 $|ab \times ac|^2 \leqslant 2^{-23}$ 时把三角形当退化丢弃；该阈值以米计、固定不变，厘米级的正常三角形也会落到它下面

↓

迭代提前结束，拿到的不是最近点；生成接触时选到背向对方的面

↓

把“间隙＋块厚”报告成穿透深度（中位差 <0.01 mm）

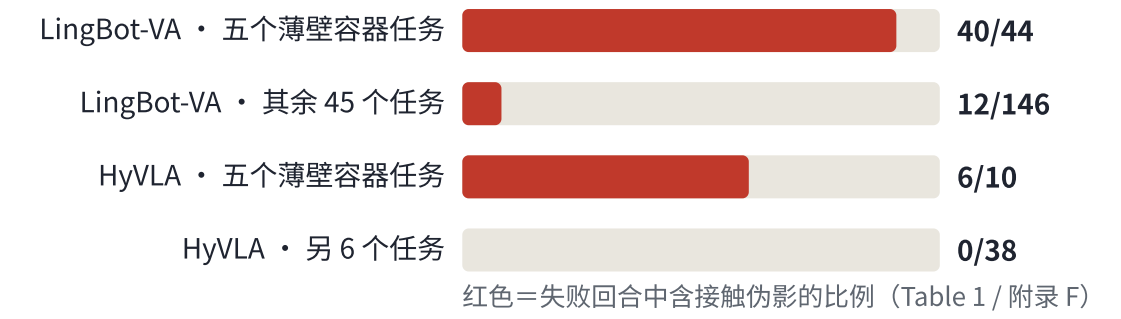
↓

求解器在一步内移除这段“深度”，10 g 的罐子被高速抛出

在引擎外用记录位姿单独调用 PhysX 接触生成，20 个假接触逐位复现；换成 **PhysX 5.4.0 的阈值（平方后）**，20 个全部消失，4 个真实穿透保留深度。这一修法 5.4.0 已有，本文的贡献是把它追到基准结局。

另有三项设置把假接触“放大”成弹出，但不是原因：每个形状 10 mm 外就生成接触（偏移降到 1 mm 后 37 个 Can 回合仍有 4 个留有伪影）；引擎以任意速度移除深度（限 1 m/s 后 37 个中仍有 26 个）；物体只有 10 g。

失败里有多少是引擎造成的



红色＝失败回合中含接触伪影的比例（Table 1 / 附录 F）

另有 17 个 LingBot-VA 成功回合也含伪影（16 个在 Place Can Basket，罐子弹回篮内）。伪影也发生在**计分之前**：该任务因脚本示范失败而跳过的 22 个种子里 16 个含伪影。

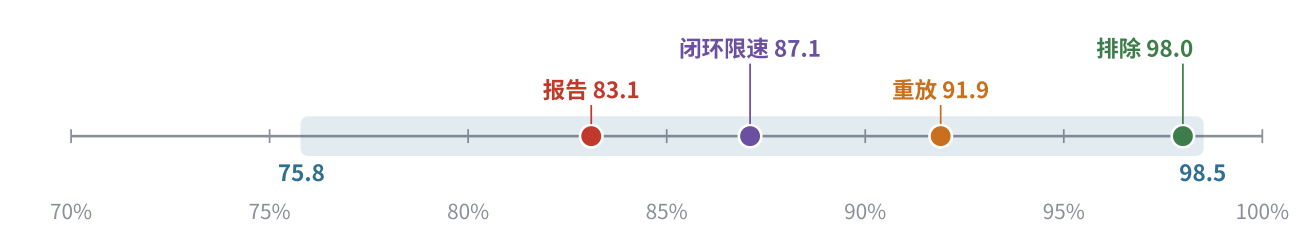
只改这一个常数，其余不变

对象（分母）	指标	原引擎	修复后
脚本示范 · Can（60 种子）	含伪影回合	18	1
脚本示范 · Bowls Three（60）	含伪影回合	6	0
LingBot-VA 闭环（5 任务×20）	成功（含伪影）	89（12）	98（0）
HyVLA 闭环（5 任务×20）	成功（含伪影）	90（10）	94（1）

两臂计分的种子不完全相同（脚本示范决定哪些种子计分）。LingBot-VA 两臂共有 83 个种子：只在修复后成功 8 个、只在原引擎成功 2 个，符号检验 p=0.11——**成功率差单看不显著，伪影数之差是清楚的**。

引擎改不了时：报一个区间，而不是一个点

LingBot-VA，五个容器任务的已审计运行（Table 1）。若只有被标记回合可能改变：全部算失败 → 75.8%，全部算成功 → 98.5%。区间内四个点各多带一条假设。



报告
每次弹出都算策略的错

闭环限速
整回合开去穿透限速不改变任务

重放
伪影前 0.1 s 开限速，记录的动作仍是策略的选择

排除
被标记回合和其余回合一样难

压慢弹出速度 ≠ 修复

把 PhysX 的最大去穿透速度整回合限在 1 m/s，Place Object Basket（LingBot-VA）：

90% → 50%

同一任务在修复引擎中仍为 20/20。限速改变了任务本身需要的物理；“修复”指去掉假接触的来源。

无机器人的压力测试（罐子在篮内 300 个随机位姿上静置起步，288 个起始嵌入 ≥5 mm）：RoboTwin 设置下 **91%** 被抛出；改罐子质量或求解器迭代次数仍约 90%，只有去穿透限速改变这一比例；MuJoCo 默认接触为 5%。

其他平台（规模较小）

基准 · 引擎	含伪影/回合	备注
RoboDojo · Isaac Sim（PhysX GPU）	7/40	全是失败回合；追到又一个假接触，原因未定位
LIBERO · MuJoCo	2/400	都慢（<1.6 m/s）
RoboCasa · MuJoCo	5/300	都慢（<1.6 m/s）

作者建议：PhysX 5.3.1 及更早的基准在修复引擎中重跑；改不了引擎就在成功率旁报告上述区间。

限制与适用边界

1. 修复引擎的闭环测量只覆盖 2 个策略 × 5 个任务 × 每任务 20 个计分种子；LingBot-VA 成功率差 p=0.11。
2. 检测器精度只在 Place Can Basket 一项测过（37/40，硬负例 0/20），没有总体召回；区间假设“未标记回合不变”，漏检时不成立。
3. 只改了 PhysX 5.3.1 的一个常数，未在完整新版 PhysX 上跑 RoboTwin；RoboDojo 的假接触原因未找到。单次评测本身也不稳：Place Can Basket 三次重复为 74.4±6.9%。
4. 受审的是 VLA 与世界动作模型，论文没有测 LLM/VLM harness。缺陷在引擎、与策略类型无关（RoboTwin 的脚本示范同样被弹出），因此对在这些基准上报数的 harness 同样相关——这是我们的阅读判断。

来源：When the Simulator Fails, Not the Policy，arXiv 2610.41857v1（2026-10-30）正文 §1–6 与附录 A–D。数字与图表的原文位置见同目录 SOURCE.md。取证图与根因链为据原文重绘的示意；未运行论文代码，未复现。入选依据为问题评价（problem-core-v1.1），不是审稿结论。