arXiv 2611.01560v2（首版 v1 2026-11-01）· 机器人使用代理 · RoboDojo 仿真 42 任务

# 同一个开放模型，换一套 harness，RoboDojo 得分从 1.9 到 31.4：说“开放模型不会用机器人”之前，先排除接口

以往开放权重代理要么读模拟器深度与任务判定器，要么依赖任务专用技能；部署时这些都拿不到。uni-robot-agent 只给 RGB、相机标定、本体状态与指令，把工具、反馈与执行调度做扎实，再看 Qwen3.8-Flash-Next 等开放模型还剩多少能力。

## 固定模型，只换 harness（RoboDojo Score，0–100）

同 42 个任务、每任务 3 种子 × 2 布局 = 252 回合；无模拟器深度、无判定器反馈。基线 harness 用各自默认配置；GAP 混合版内含 π0.5。右侧灰柱为 GPT-6 Astra 的参照。

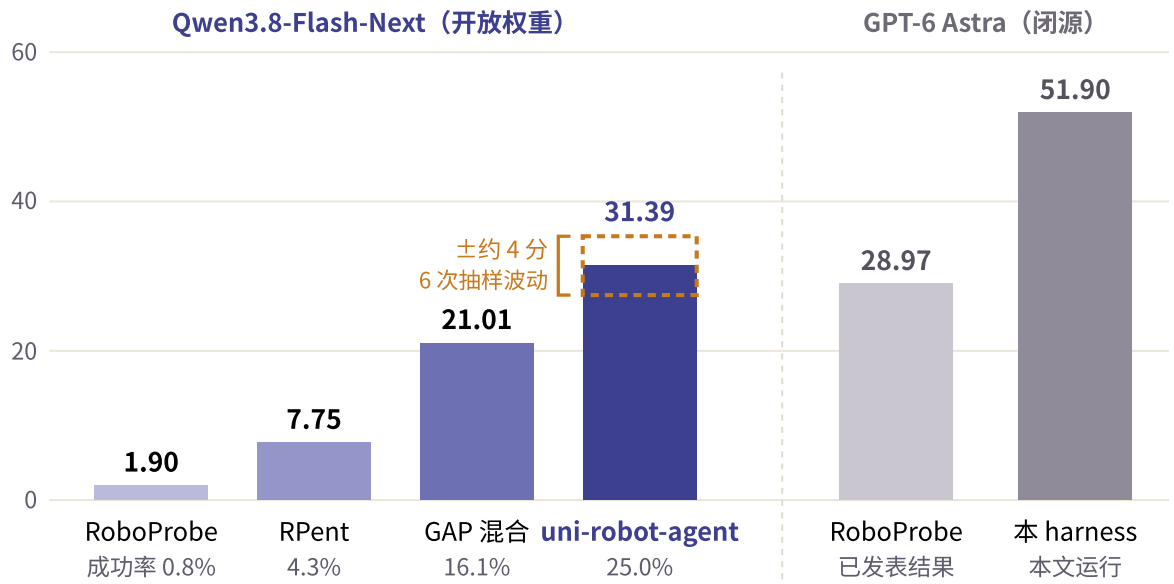


橙框：附录 G 深度版配置 6 次抽样的 95% 范围约 ±4 分，仅作量级参照，非本柱置信区间。

## harness 做了什么

§ 2.2–2.5。共用工具 + 环境适配器，仿真与真机同一套调用语义。

1. **图像、标定、机器人状态绑成不可变快照**，避免用新位姿解释旧像素
2. **请求带身份与执行状态**，通信丢回复时不重复执行；结果不明则阻塞后续动作
3. **move 同时带夹爪开度**，按实测位姿逐步生成中间目标，到位、发散、停滞时停下
4. **反馈给数**：位姿误差、停止原因，外加结果图像
5. **旧图像换成文字占位**，成批淘汰以保住前缀缓存
6. **推理与执行流水化**：后台调用 + 按资源排队，可取消未开始的动作

> 技能库不是收益来源：关掉技能库与技能编写，Qwen 仍得 30.31（31.39 的 96.6%），成功率只差 0.42 个百分点。

## 拿到什么几何信息，就能做到多少

§ 5.1，同一 harness、开技能。Qwen 3 种子 × 2 布局；Astra 因费用只跑 1 种子 × 1 布局。

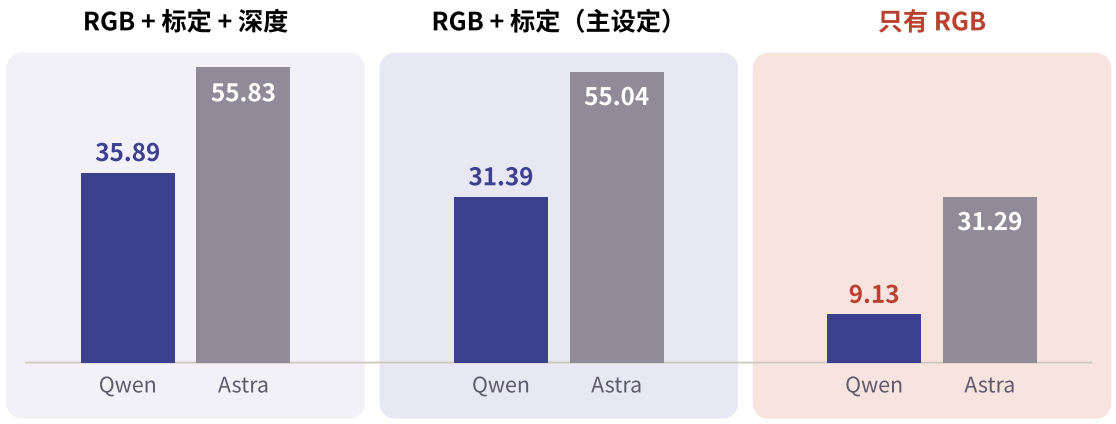


> 去掉深度几乎不伤（Astra 保留 98.6%、Qwen 87.5%，后者落差在抽样波动量级内）；去掉标定 Qwen 从 31.39 跌到 9.13。部署可得的标定，而不是模拟器深度，承载了几何。

### 换模型时，错在哪里（§ 4.2 轨迹分析）

| 失败类型 | 早期 Qwen 3.5–3.7 | 较强模型 |
|---|---|---|
| 看错（把 0 看成 9、杯子正倒） | **12.2–23.8%** | Qwen3.8-27B 3.2%；Flash、GPT-5.6 Sol 0 |
| 几何代码出错（坐标变换、四元数约定） | **47.3–81.8%** | Qwen3.8-Flash 8.2%；GPT-6.1 Sol 0 |
| 多视角对应点不一致被三角化拒绝 | — | 最低的 GPT-6.1 Sol 仍有 31.5% |
| 抓取姿态不合理且未纠正 | — | GLM-5.3 Flash 26.2% |

比例口径各异（试验、计算、工具调用）；抓取姿态由 GPT-6 Astra 评判。只说明相关，不是因果。

## “开放模型超过 Astra”要打折

摘要头条：Qwen + 本 harness 对 Astra + RoboProbe 的已发表结果。

**31.39**
Qwen · uni-robot-agent

vs

**28.97**
Astra · RoboProbe（发表值）

- 模型与 harness 同时变了；同 harness 下 Astra 为 51.90。
- 差 2.4 分，小于同配置 6 次抽样约 ±4 分的波动。
- v2 披露：为两个说明含糊的任务（按钮计数、搭塔）补写了规则说明；未说明基线 harness 是否同样获得。每回合墙钟上限 3 小时。

| $1.09 | $21.29 | 42.6 vs 95.5 |
|---|---|---|
| Qwen 每回合 API 价 | Astra 每回合 API 价 | 到 25 分所需分钟（Astra vs Qwen） |

费用按公开单价折算，只含模型 API，不是系统总成本；到 25 分 Astra 用 7.4M token，Qwen 23.5M，DeepSeek 49.9M。

§ 4.1 同一 harness 下的模型对比；新增模型只跑 1 种子 × 1 布局。

## 限制与边界

1. 跨 harness 对比用的是各基线默认配置，是否给了同样的规则说明、时间上限未写明；收益不能全归到某一项设计。
2. 各条件每任务只有 6 回合，Score 的抽样波动约 ±4 分；Astra 的几何信息消融只有 1 种子 × 1 布局。
3. 真机 19 任务为评分细则累计分，非整任务成功率；代理另用深度，π0.5 每任务微调 10 小时、Dream-1 只用 RGB。
4. 真机分数 v1→v2 被改（Qwen 49.50→53.50、Dream-1 35.50→43.50，主要在瓶子交接一项），正文未说明原因；画报不据真机下结论。
5. “为后续训练打基础”是动机，本文没有任何训练实验。
6. 失败模式与通用基准的相关只基于 6–13 个模型，属描述性。

来源：Yuan、Zuo、Huang 等 28 人《Democratizing Robot-Use Agents: A Unified Harness with Open Models》arXiv 2611.01560v2（2026-11-03；v1 2026-11-01），§ 2–6、Table 1–2、附录 A–G（v1 无附录 G，真机表数字与 v2 不同）。柱图与阶梯为按原表重绘，橙框为附录 G 量级参照。未运行论文代码，未复现。问题档位为本项目的阅读评价，非审稿结论。