arXiv 2611.05567v1 · 评测基准（B 类） | 单臂 Franka MESA + 双臂 YAM BiMESA，仿真 | 主体为 VLA 微调基准；LLM harness 只在附录 B.7 一列

成功率之外再数一种失败：做成了，但做的是别的任务

MESA 让每个场景都摆着多组“可行的物体—目的地”，并用 BDDL 谓词枚举出所有干扰任务，于是失败可以分成**选错目标**和**没做成**。五个评测套件各只留出一样东西（位置、实例、类别、组合）。用它看：微调 VLA 遇到没见过的物体类别时，多半是**动作做完了，目标选错了**；附录里一个零样本 LLM harness 正好相反。

1 一次 rollout 的三种结局

示意（自绘）；定义见 §3.3。

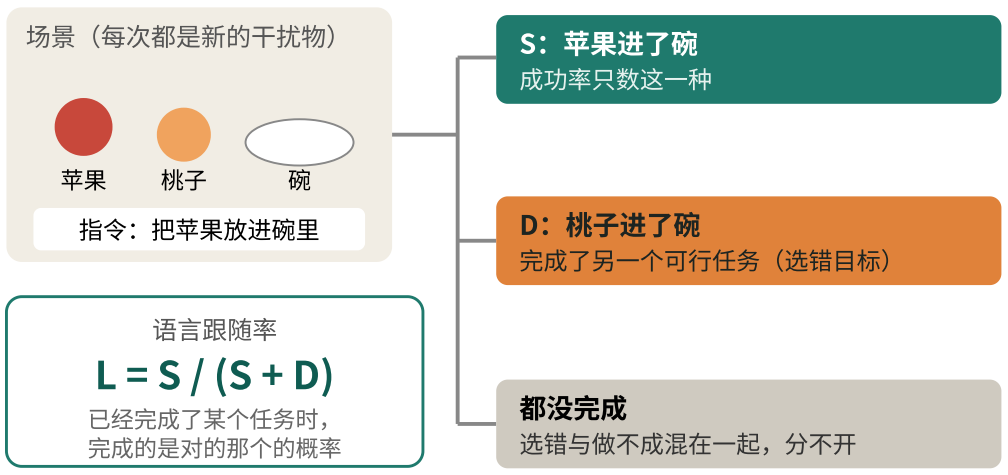

2 五个套件，各只改一样东西

训练集一套：单臂 70 任务 7,000 条示范，双臂 57 任务 6,833 条；每法每任务 50 次，初始状态对各方法相同（§4、附录 E）。

套件	评测时改变了什么	单臂	双臂
ID	不改任务，只换从未见过的干扰物与摆位	**70**	**57**
Spatial	单臂：目标放到训练没用过的半张桌子；双臂：换执行的那只手、反转交接方向	**10**	**38**
Instance	同类物体换成训练集外的另一款模型	**20**	**18**
Composite	见过的子任务拼成没见过的组合或两步任务	**20**	**15**
Category	抓取物（部分连同目的地）属于从未见过的类别	**20**	**17**

Spatial、Instance 在 ID 里有一一对应的任务，可以直接配对比较（§5.2）。打乱指令后 π0.5 成功率大幅下降，只有猜中指令时才成功（附录 B.2）：场景本身不泄露目标。

3 同一批双臂任务、同一批初始状态：失败的成分不一样

BiMESA。VLA 为在 BiMESA-57 上微调；GPT-6.1-Sol 为零样本、RoboDojo 末端位姿工具调用 harness（附录 B.7），每任务只跑 10 次（VLA 50 次）。

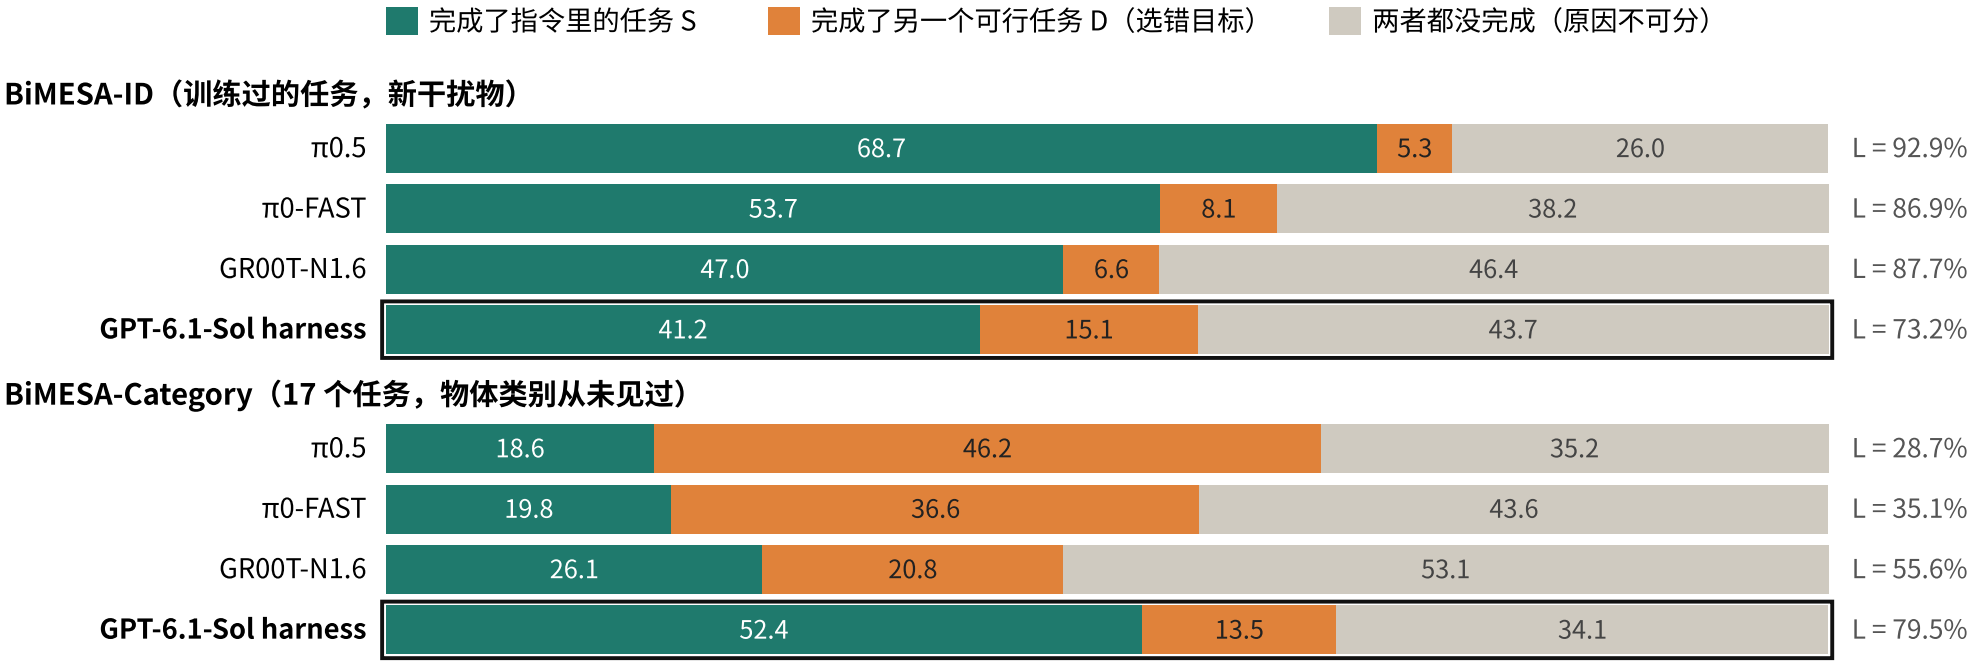

S、L 取自表 2、表 3（附录表 17、19 带区间）；D = S×(1−L)/L 与“都没完成” = 100 − S − D 为我们反推，原文未直接列出。

读法（我们的阅读判断）：未见类别上 π0.5 有 **46.2% 的回合完成了别的任务**，多于做对的 18.6%：动作做得出来，目标认不出来。Sol harness 的失败主要在灰段；但在 ID 上它选错目标的比例（15.1%）高于三个 VLA。

4 从 ID 到未见类别，只有一列往右走

BiMESA 成功率（表 2）；Sol 两端细线为 95% Wilson 区间（附录表 17）。

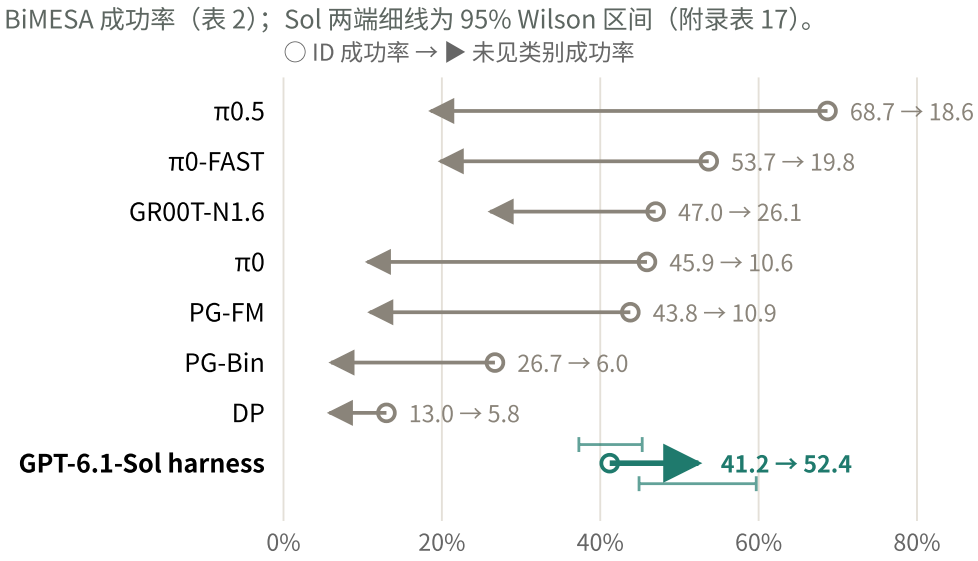

Sol 在 ID 上按任务类型：抓放 64.1%、交接 26.5%、铰接 13.1%（§5.1）。它看到三路 224^2 图像与末端位姿，**没有**物体位姿、深度或检测；每步一次工具调用设末端与夹爪目标，170 次调用上限、500 步上限。

5 同一基准上的另外几条判断

机器人预训练不一定迁移。 π0 与 PG-FM 同骨干同结构，只差机器人预训练：单臂 31.7 vs 22.8，双臂 29.6 vs 30.4（表 2）。

预训练压过数据量。 同一算力下，π0.5 每任务 10 条示范始终胜过 π0 每任务 100 条（§5.4，图 4）。

多加任务种类没用。 翻倍加入 736 个辅助任务共训：π0.5 ID 62.8→59.0（McNemar $p<0.001$）、Category 26.4→23.0（$p=0.04$）；π0 只有 Spatial 42.2→54.4（表 4、附录表 20）。

与真机名次大体一致，但只是方法级。 与 RoboArena Elo 排序相近，PG-FM 与 π0 次序不一致；真机 DROID 检查点直接放进 MESA，中间子任务完成率只有 0.23–1.77%，无法排序（§5.6、附录 B.6）。

区间够窄，名次不全分得开。 单臂 ID 相邻名次 5 对全部显著；OOD 套件 20 对中 5 对、双臂 24 对中 6 对分不开（附录 E.6）。

限制与证据边界

1. 主体是 VLA 微调基准。LLM harness 只是附录 B.7 的一列零样本基线，没有换模型、换 harness 或消融，不能据此比较“harness 与 VLA 谁更好”。
2. harness 每任务 10 次（共 1,450 次）；用不检查碰撞的阻尼最小二乘 IK 替换 CuRobo，改写本体说明、去掉回原位要求；模型延迟中位为仿真时间的 13 倍，并非实时。
3. 跨套件比较受任务组成影响：Sol 在 Category 三个交接任务上 73.3%，ID 交接只有 26.5%（我们按附录表 11、15 计算）。“未见类别不掉分”不能直接读成泛化能力。
4. D 只数完成了另一个可行任务；“都没完成”的回合里选错与做不成混在一起（§5.3、§6），L 不是完整的归因分解。
5. 每个方法只有一个训练检查点；区间只含 rollout 波动，不含训练种子与任务抽样（附录 E.6）。
6. 任务以抓放和简单铰接为主，全部在仿真；RoboArena 对照的模型训练数据不同，不是同一策略的 sim-to-real 验证（§5.6、§6）。

来源：Wilcox 等，“MESA: An Evaluation Framework for Compositional, Semantic, and Spatial Generalization in Robotics”，arXiv 2611.05567v1（2026-11-03）；定位见 SOURCE.md。第 1 区为自绘示意；第 3 区 D 与“都没完成”为我们由表 2、3 反推；第 4 区按表 2 重绘。未运行论文代码，未复现。问题档位不是审稿结论。selection-010