arXiv 2611.06434v1 · 主动具身问答 | ESI-Bench 3,436 题 · OmniGibson 仿真 · 同骨干、同动作接口、同 30 步上限

先写下“要看到什么”，再去看、再决定留什么：不训练的 VLM 代理，问答准确率 +7.1（Qwen）/ +3.7（Gemini）点

主动问答要靠转视角、动手试来取证。看似合理的动作不保证拿到、也不保证留住回答所需的证据。EviSeek 用同一个冻结 VLM，先从问题导出不预设答案的“证据需求”，按需求派采集子任务，只把有用的视图与动作结果连同出处钉到证据板上，答题时只看这块板。

一张证据板上的出处链

自绘示意（以叠放题为例）。各阶段都由同一个冻结 VLM 按提示完成；ESI-Bench 配置中采集计划在回合开始时定下，动作仍随观察调整。

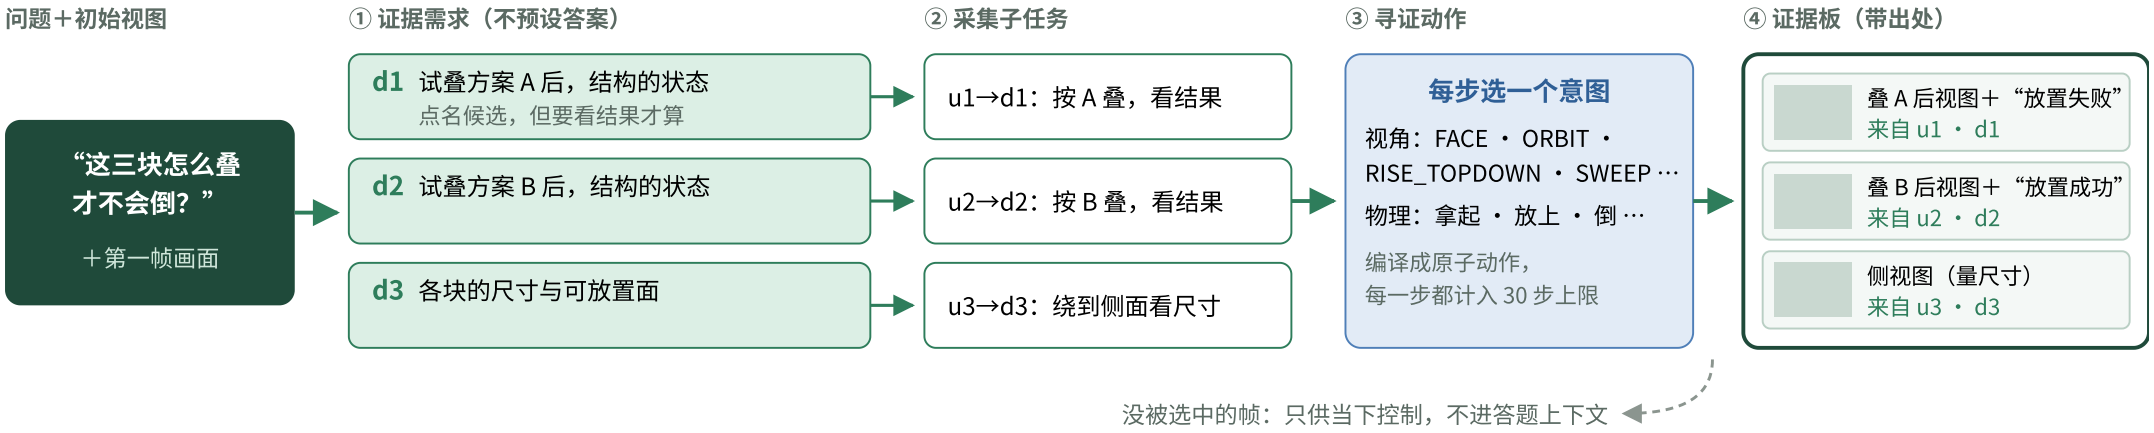

答题时只看：问题＋需求（不带“是否已覆盖”标记）＋证据板；不附采集计划，也不附完整交互历史。

对照 Single-model 基线（ESI-Bench 官方单 VLM 代理）：同骨干、同任务提示与动作；完整文字历史＋最近 5 帧，自报置信度 ≥ 0.80（并过任务检查）才停。

增益从哪几类题来

每类准确率差 × 该类题数 ÷ 3,436 = 它对总增益贡献的点数（我们按表 1 计算；EviSeek 减 Single-model，同骨干）。深色 Qwen3-VL-32B，浅蓝 Gemini 3.1 Pro；红色为拖后腿。

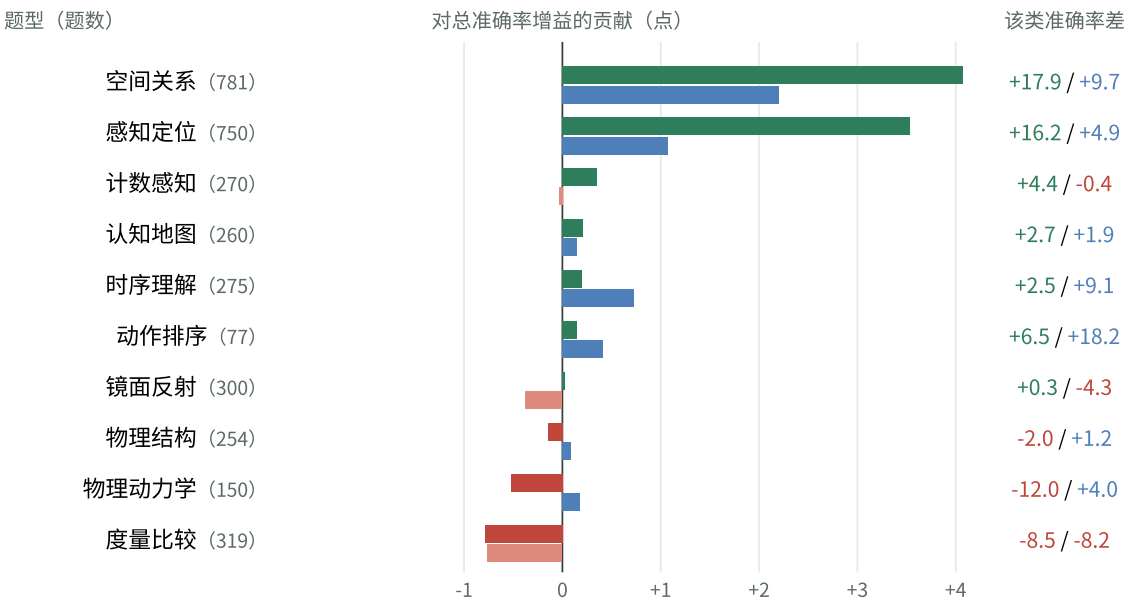

总增益（表 9） ■ Qwen3-VL-32B +7.1 ■ Gemini 3.1 Pro +3.7 按表 1 取整值相加为 7.07 / 3.65

两种骨干的增益都主要来自**空间关系**和**感知定位**；Qwen 这两类合计贡献 7.6 点，超过总增益，其余类别合计略为负。**度量比较**两种骨干都退步，Qwen 的物理动力学 −12.0。

Gemini 起点更高，这两类贡献 3.3 点（共 3.7）；它在时序理解（+9.1）与动作排序（+18.2）上也有增益，后者只有 77 题。增益并非各题型普遍上升。

拆掉一件会怎样（Qwen，全部 3,436 题）

重新在线跑

完整 EviSeek	**52.7**
去掉证据需求 仍留分解、板与停止规则	**46.6** −6.1
Single-model 基线	**45.6**

固定轨迹，只重答

证据板	**52.7**
最近 5 帧＋全文历史	**47.6** −5.1
同 20 帧均匀抽帧	**47.4** −5.3

去掉需求后只比基线高 1.0 点：在线增益主要随“需求”消失。右栏同一批轨迹、同一答题模型，只换答题上下文；两栏降幅不能相加。

每题平均用量

	动作步	VLM 调用	总 token	答题图数
Qwen · 基线	18.79	20.55	139,380	5.91
Qwen · EviSeek	**18.11**	**12.69**	**76,470**	**4.39**
Gemini · 基线	10.71	12.15	86,887	5.24
Gemini · EviSeek	**12.17**	**10.05**	**74,839**	**4.38**

token 降 45.1% / 13.9%（含推理 token）。Gemini 的环境步数反而**增加**：省的是模型调用，不是动作。

换到纯导航：EXPRESS-Bench

2,044 对问题–轨迹、174 个 HM3D 场景；全部用 Gemini 3.1 Flash-Lite、120 步上限，官方 GPT-4o-mini 评分（表 4）。导航版另带覆盖检查与重规划，与上面的 ESI 配置不同。

方法	有据正确 C	只看答案 C*	路径加权	终点距离 m
只看问题（盲答）	—	53.79	—	—
Single-model（RGB）	19.48	40.09	18.66	6.42
EviSeek 导航版（RGB）	**41.60**	**63.09**	**37.77**	**6.37**
Fine-EQA（RGB-D＋3D 地图）	49.92	67.10	33.15	5.60

有据正确率是同输入 RGB 基线的两倍多，但 **Fine-EQA 有据正确率更高**；它多了深度与建图，不是同权限比较。

这篇改变的判断

主动问答里，“动作做得合理”和“证据到手、留住”是两件事。把**采集目标写成可观察的证据需求**，并按需求**有选择地保留**，在同骨干、同动作上限下比堆历史帧与自报置信度停止更有效，且更省调用。

> 配对检验（表 9）：Qwen 只有 EviSeek 答对 673 题、只有基线答对 429 题，+7.10 [+5.24, +8.99]；Gemini 496 / 370，+3.67 [+2.01, +5.36]；Holm 校正后均 $p < 0.001$。

> Flash-Lite 补充实验（附录 H）：把意图换成每次一个原子动作，53.08 → 50.84。

适用范围与限制

1. 主比较同时换了规划、保留、答题上下文和停止方式（基线按自报置信度停）；整体增益不能归给单一部件，只有上方两组消融做了拆分。
2. 增益集中在两类题；度量比较两骨干都退步，作者把精确空间推断留给 VLM 本身。
3. 子任务结束不要求已拿到证据或满足覆盖条件；ESI 配置按初始计划推进。
4. 文中“视觉支持”由 GPT-5.5 评分（看标准答案、不看预测），没有人工校准；本画报未采用该指标。
5. 两个仿真基准、预定义动作接口；动作结果文本含仿真器的放置成功与稳定性检查（两系统共享）。真机、传感噪声未测。
6. 步数与 token 不等于实际耗时；对 GPT-6 Astra 等更强模型是否仍有增益未测。

来源：Li, Cao, Xiao, Bai, Karlsson, *EviSeek: An Evidence-Centric Agentic Framework for Embodied Active Information Seeking*, arXiv 2611.06434v1（2026-11-04）。数字取自 §4–5、表 1–4、附录 A、D–H（含表 9–10）；逐项映射见 SOURCE.md。出处链为自绘示意；“增益从哪来”的贡献值由我们按表 1 计算。未运行论文代码，未复现。