arXiv 2611.06453v1 · 闭环评测方法 | CARLA 7 个驾驶代理 × 7 个场景族 · Isaac Sim 仓储机器人 × 3 族 | 被测对象均非 LLM harness

分数更高，不等于该停的时候会停：把“敢不敢走”和“走不走得过去”拆成两条曲线

CARLA 驾驶分 = 路线完成度 × 违规惩罚，堵死的走廊里硬闯可能比停下得分更高。作者让每个场景族只改一个**可测量因素**，按测量把变体认证为“该走/该停”，沿这条轴分别估计**承诺**（尝试通过的概率）与**能力**（无接触通过的概率）。

边界尺：Charger 走廊（两辆停着的车把路收窄）

每个宽度 3 个交通种子；边界为概率 ½ 的交叉点（拟合或分隔区间，§3.2、§4.3）。蓝条 = 会尝试通过的宽度范围，绿条 = 能无接触通过的范围，橙色 = 会冲但过不去。最窄 4 个宽度（0–2.07 m）被认证为堵死。

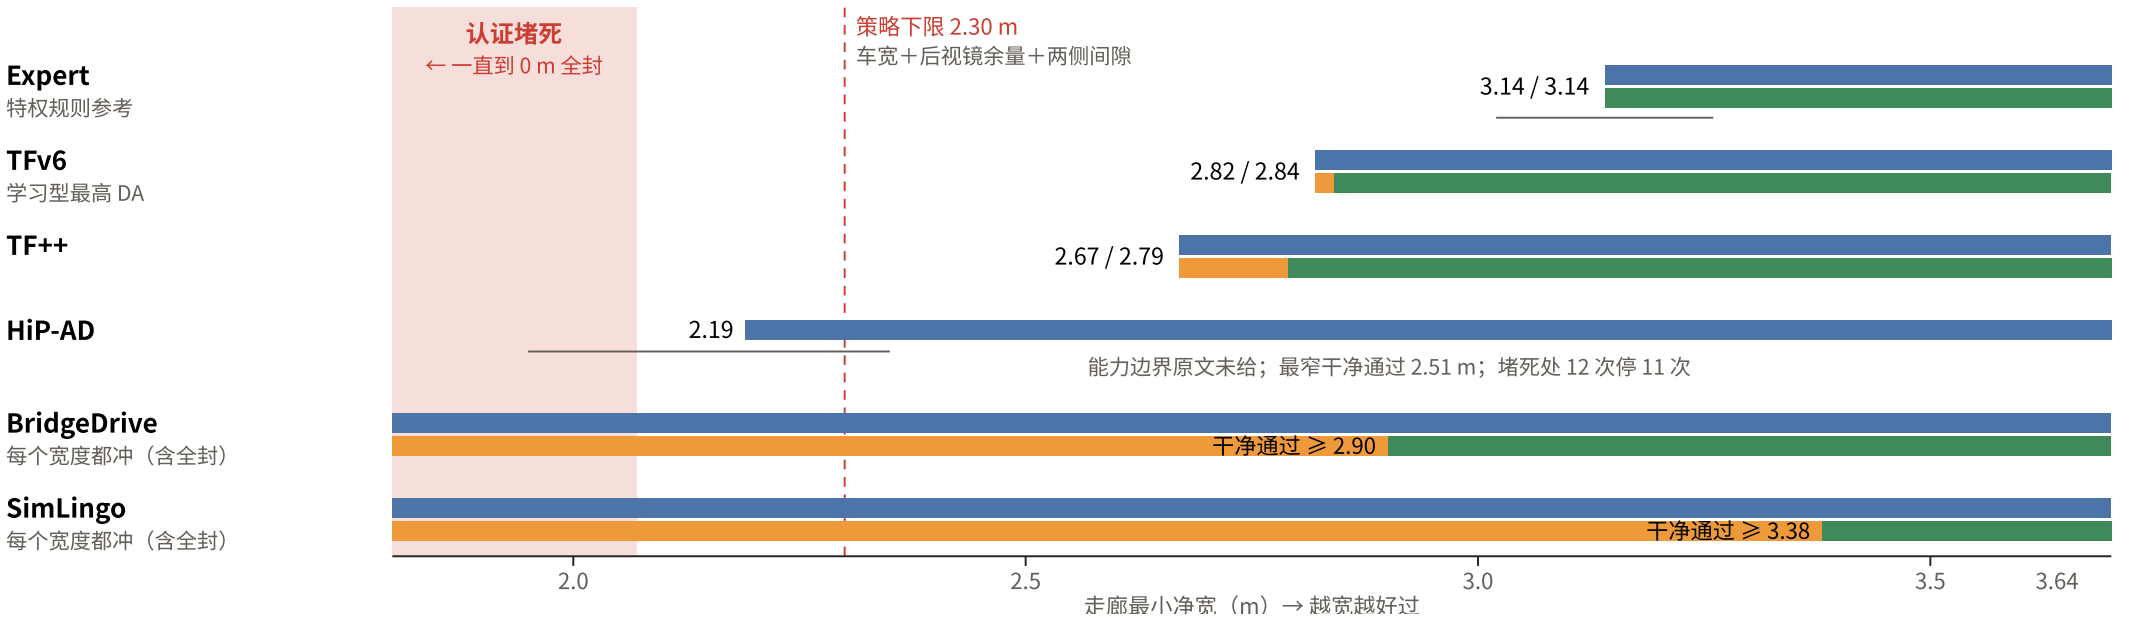

右侧数字为“承诺 / 能力”边界（m）；Expert 下方细线是其分隔区间 [3.02, 3.26]，HiP-AD 下方细线是承诺边界区间 [1.95, 2.35]。TFv6 两条边界只差 2 cm，区间为 [2.59, 3.06] 与 [2.59, 3.14]，相邻代理的边界常有重叠。**BridgeDrive 最多把一辆停着的车推出 55 m。**

堵死的 4 个宽度上：硬闯的得分最高

每个代理 12 次（4 宽度 × 3 种子）；柱长为这些回合的平均驾驶分，右侧 12 格按结局分组计数（表 1）。

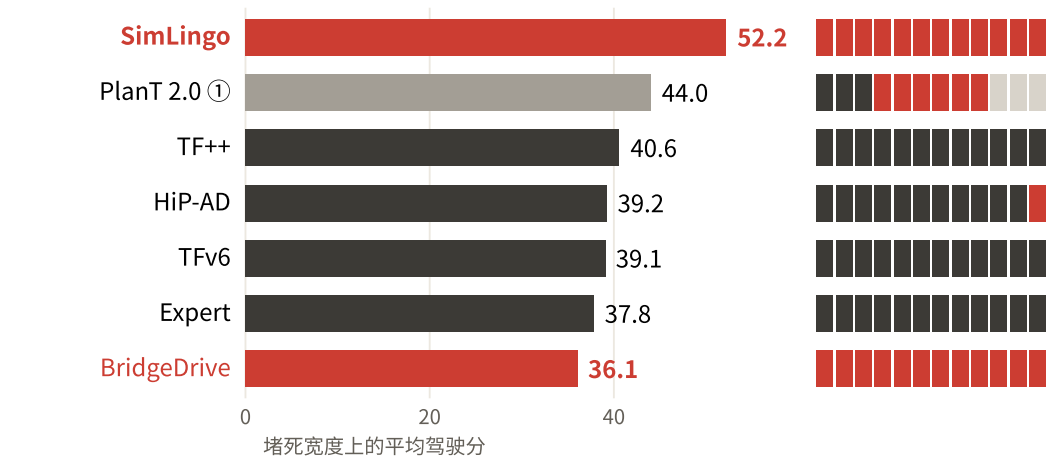

■ 停下 ■ 接触（冲过去或卡住） ■ 无接触穿过 2.07 m（异常，剔除）。同样从不停的 BridgeDrive 反而最低：分数不是按“停没停”排的。

两套分数排出两种名次

左：平均驾驶分；右：决策准确率 DA（可通处干净通过率与堵死／须等处停下率的平均），均只取含“该停”变体的 3 族（表 2）。DA 永远停 = 0.50。

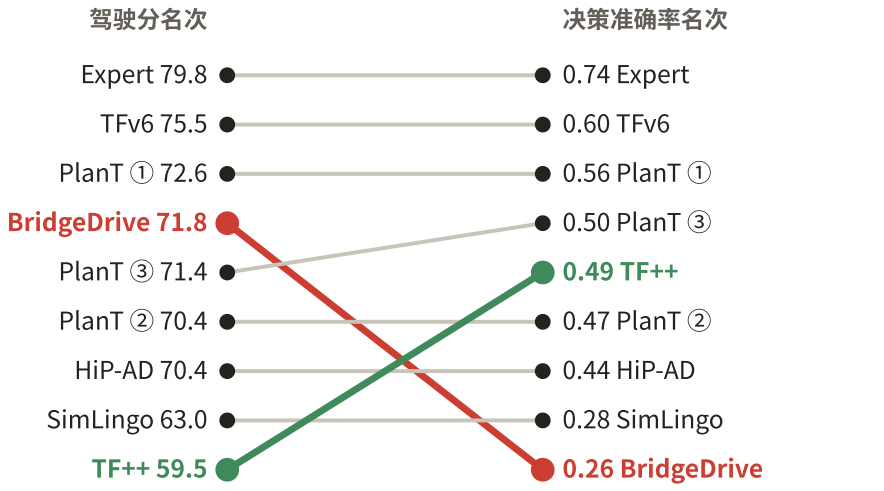

头部区间重叠（Expert 0.74 [0.67, 0.81]，TFv6 0.60 [0.53, 0.68]），只能当点估计读；改认证常数（间隙余量 0–1 s、2.07 m 改判可通）两端名次不变，**中段会换序**。PlanT ②与 HiP-AD 驾驶分并列。

微调后：过得更多，却一次也不停了

Isaac Sim 仓储机器人，X-Mobility 端到端导航策略；两个微调版只用 2 个族的示范训练，“码放纸箱”族留出（§4.4）。相邻通道始终开着，绕行或停下都算合理。

留出族（码放纸箱）	发布版	只调头部	全模型微调
堵死的 15 次里停下	**15**	**0**	**0**
可通的 35 次里干净通过	11	能力边界 1.50 → 1.05 m	**35**
本族决策准确率	0.66	—	0.50
3 族平均决策准确率	0.34	0.22	0.50

只看平均 DA，全模型微调从 0.34 升到 0.50，像是变好了；拆开两侧才看到**干净通过的增加换来了停车能力的全部丧失**。三个版本都从未走过开着的相邻通道。

对向车流：该等的时候几乎没人等

信号灯左转穿越单车道对向车流；按实测车流给每个变体和种子出具间隙证书（可用 / 须等），每个代理 29 个“须等”窗口（§4.3）。

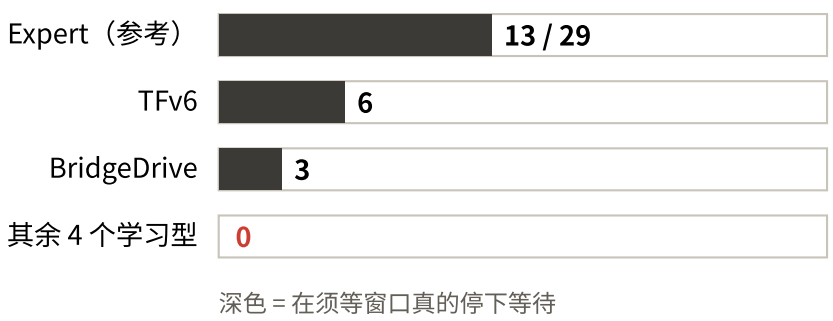

在走廊里会停的 TF++ 与 HiP-AD，在这里也一次不等：“会停”不跨场景族迁移。只容滚动通过的窗口反过来：PlanT 与 HiP-AD 全部抢过，Expert 从静止起步、一次不抢。

适用范围与限制

1. 被测对象**没有 LLM/VLM harness**（SimLingo 为 1B 视觉语言骨干）。按 B 类评测方法收录；用于 harness 停止／交还门控是我们的阅读判断，未经检验。
2. 全部仿真；CARLA 同种子不可复现（同命令两次 53.7 vs 32.2），每变体 3 个种子。
3. “堵死”“须等”是声明的约定（下限 2.30 m、余量 0.5 s），不是无假设的物理事实。
4. 总分 DA 只建在 3 个含“该停”侧的族上；Expert 是脚本规划器，只作参考，不是好驾驶的上限。
5. 仓储部分只有一台机器人、一个策略的三个版本，微调只有 1 个留出族。
6. 两个缺陷变体（售货机倾倒、对向车互撞）已剔除；全部跑完约需单 GPU 220 小时。

来源：Bulat, Ardelean, Kirby, *Beyond Infraction Scores: Failure-Boundary Profiles for Closed-Loop Evaluation of Driving and Robot Navigation Agents*, arXiv 2611.06453v1（2026-11-04）。数字取自 §3.1–3.4、§4.1–4.4、表 1–3 与结论；逐项映射见 SOURCE.md。边界尺按原文边界值重绘（不是原文曲线图），名次连线按表 2 绘制。未运行论文代码，未复现。