arXiv 2611.08209v1 · 评测基准（B 类） | Claude Code / Codex 直接看像素、调用工具控制机械臂 | MuJoCo 仿真 · 单臂 Panda / 双臂 Panda / 双臂 YAM | 22 任务 × 5 种子

代理说“做完了”，三到六成其实没做完：RoboARCade 把“会不会做”和“知不知道做完”分开数

前沿代理**不经任何学习型策略**、直接看图下末端指令；22 个长时程任务（平均 3,343 步）按子任务计分，判分谓词在沙箱外。最强组合只完成 **49.8%** 的子任务；失败少在“看不懂”，多在**方法选错、执行不准、没做完就宣布完成**。更丰富的 3D 界面只多 1.5–6.8 点，花费 1.7–2.3 倍。

① 测量装置：完成与否只有沙箱外的谓词说了算

§3.1、§4.1、附录 A.2.1 · 示意图（自绘）

代理
Claude Code（Opus 5 / Fable 5.1）或 Codex（GPT-5.6 Sol / GPT-6 Astra），最高推理档，原生上下文压缩

→

两种 MCP 界面
VIA：点云＋虚拟目标夹爪，先预览再执行
多视角 RGBD：彩色＋深度＋标定，增量指令立即执行

→

同一仿真与控制器
末端位姿 → 关节目标 → MuJoCo；每个航点 Blender 渲染回传

沙箱外：判分谓词（代理看不到）
回合在代理调用 end_episode、耗尽仿真步数或墙钟时限时结束；场景静止后逐个子任务按仿真状态判定。提示词写明：“end_episode 是唯一会被评分的调用，不能重来，评分前没有任何反馈——先自己检查场景。”

因此“误报完成”可以干净地数：代理自己宣布结束（或转向下一个子任务），沙箱外的谓词却判定没成。物体位姿、任务资产、判分代码与评分结果都不进沙箱。

② 宣布完成的决定里，错的有多少

附录表 5 · 分母为各类决定次数；预算耗尽、代理自称做不到的回合不计（它们没有宣称完成）

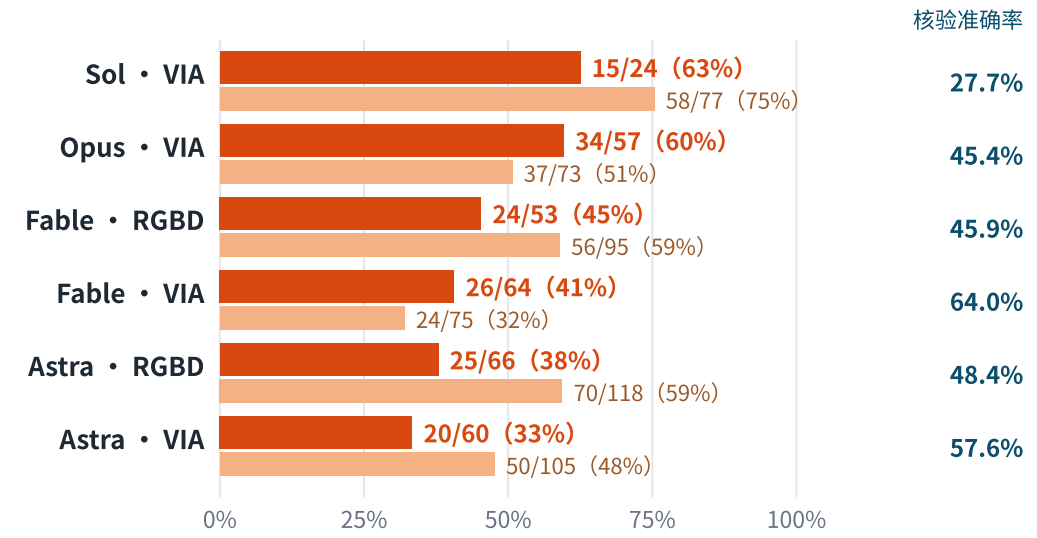

■ 以为整个任务做完、结束回合，但没解决 ■ 撇下一个具名单物体子任务、转去下一个

按尝试过的子任务计，误报完成占 **24%**（Astra · VIA）到 **39%**（Opus · VIA）（§4.2 Q3）。VIA 让误报比 RGBD 少约 4–5 点：这是它带来的主要好处。

③ 更丰富的界面：花费 1.7–2.3 倍，成功只多一点

表 1 · 22 任务 × 5 种子的平均子任务成功率与每次试验花费；空心 = 多视角 RGBD，实心 = VIA；虚线连同一模型

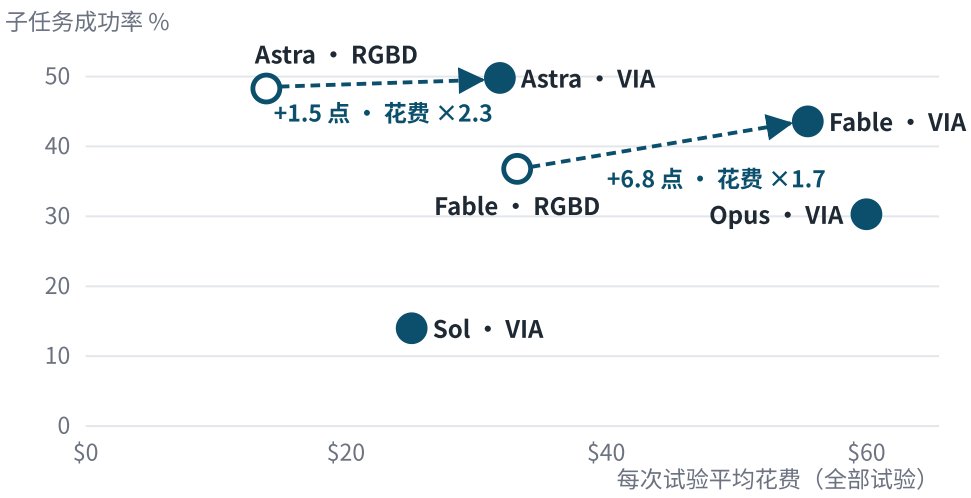

Sol · VIA 14.0% / $25.05 · Opus · VIA 30.3% / $60.00 † · Fable · RGBD 36.8% / $33.16 · Fable · VIA 43.6% / $55.50 · Astra · RGBD 48.3% / $13.89 · Astra · VIA 49.8% / $31.84

VIA 每条末端指令 2.2–4.9 轮模型调用，RGBD 只要 1.0–1.3 轮：多出的花在“动手前先看”。作者据此认为“代理更强后，额外 harness 可能没那么要紧”——**我们的读法**：只有两种界面、两个模型的对照，且模型与运行时捆绑，不能推成“接口普遍无用”。

④ 卡在哪：不是看不懂，是做法和精度

§4.2 Q1–Q2、附录图 4、表 4 · 失败按第一处出错的环节归类（先按位置/角度误差分，再由 VLM 或人工核对）

62–82%
子任务被尝试过；其余因预算耗尽或卡在前一步，根本没轮到

2–6%
已尝试的子任务以“视觉理解”失败告终；首次到第五次尝试，视觉判断正确的比例最多升 1.8 点

34→50%
Astra · VIA 子任务成功：首次 34%，两次内 43%，五次以上 50%

剩下的失败在“方法”（抓法、推法不对）与“精度”（如横梁偏出 0.6 mm 容差）之间分摊：弱代理多卡在方法（Sol · VIA 46% 对精度 29%），强代理两者相当（Astra · VIA 各约 20%）。精度失手后的下一次，VIA 成功 33–37%，RGBD 只有 26–27%。Sol 在方法错后 **76%** 的重试重复同一错误方法，只有 2% 改对。

代理自己的话（原文转录，我们翻译）
- 量得出偏差：“夹爪偏离中心 3–4 mm，偏向 −Y 一端。”（Fable · VIA）
- 认得出方法错：“这个积木没法从正上方取。”（Opus · VIA）
- 却在零件从未放好的试验里宣布：“粉色横梁已套在蓝色立柱上……松手后稳定。”（Astra · VIA）

⑤ 自我改进能消掉超时，消不掉误报：GPT-6 Astra 在 5 个任务上各 10 次

附录表 8 · 每格一次试验，按结局着色；“误报完成” = 代理自己宣布完成而未完成。5 个任务按“基线至少有一次完全成功”挑选；表 2 的 53.5% → 73.0% 是平均评分（子任务部分分），此处是完全成功次数

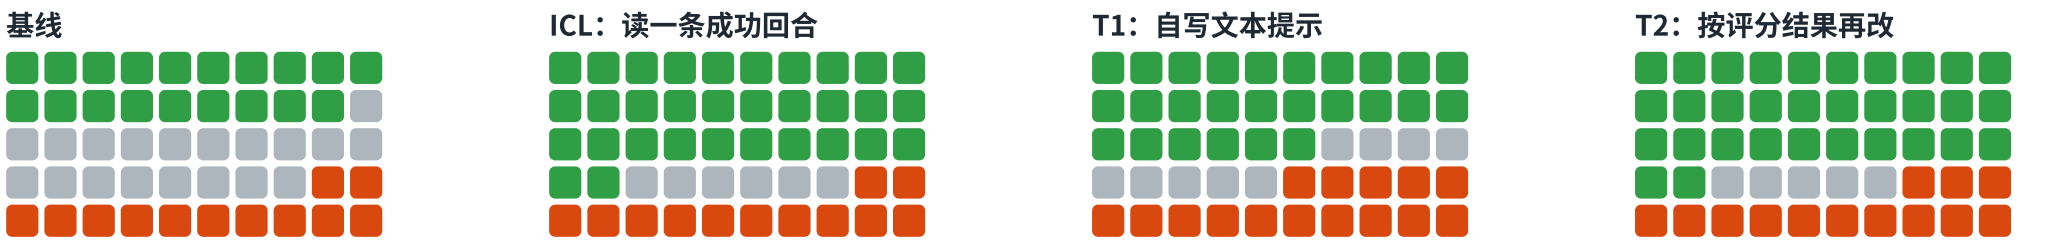

读一条同任务的成功回合（ICL），完全成功从 19/50 升到 32/50，主要是因为卡在错误做法上耗尽预算的回合从 19 降到 6；代理自写、再按 T1 评分结果修改的文本提示（T2）达到同样的 32/50，单次花费最低（$22.75）。但**误报完成始终是 12–15 次**，在剩余失败中的占比从 39% 升到 67–72%。另一个基线 5 次全失败的任务（Gamepad），由失败回合写成的提示 T1 3/5、T2 5/5（每格仅 5 次）。

限制与边界（原文自述或可由原文核对）

1. “成功率”是按子任务计的评分，不是整任务成功率；每组合 22 任务 × 5 种子，未报区间或显著性。
2. 模型与运行时捆绑：Claude 系在 Claude Code、GPT 系在 Codex，跨模型差异不是纯骨干效应；Opus 花费为下界（两次用量记录丢失）。
3. 失败环节标签由误差阈值初分、再经 VLM 或人工核对，文中未报标注一致性。
4. 自我改进只测 Astra、5 个挑选过的任务；ICL 示范来自同一任务；T2 读取了 T1 的评分结果；正文未写明这 10 次评测与示范、T1 回合的种子是否分开。
5. 任务多为准静态桌面操作，界面只支持单条末端指令；全部仿真，未上真机。
6. 作者“额外 harness 可能不那么要紧”只基于 VIA 与 RGBD 两种界面、两个模型的对照。

来源：Sharma、Hu、Kamat、Sadigh、Bohg，RoboARCade: Benchmarking Agentic Robot Control，arXiv 2611.08209v1（2026-11-05），§1、§3–5，附录 A.2–A.7（表 1、4–8，图 3–4）。图 ① 为自绘示意；图 ②③⑤ 按原文表格数值重绘；“我们的读法”为阅读判断。未运行论文代码，未复现实验。Embodied-Harness-Daily · selection-011 · problem-core-v1.1 · Opus 5.5 原文核对。