B 类 · 失败检测器 · arXiv 2611.08425v1 · 冻结 VLA，无 LLM 在环

在出错之前报警，并先说清能保证什么：同时校准误报与漏报，保证不住时先弃权

VLA-Tug 是挂在冻结 VLA 骨干隐层（π0.5 第 18 层 / GR00T-N1.7 第 16 层）上的 6.6M 参数小探针，每个动作块出一个失败分数和失败类型。它针对两件事：已有探针大多只校准误报率、且多不按真实出错时刻评“及时”；本文按 Learn-then-Test 同时认证“误报 ≤ α”和“提前抓到失败 ≥ β”，认证不了就直说。

0.12 ms

探针每步 GPU 开销；四线程 CPU 0.9 ms
GR00T 单次调用 54 ms 的 0.2%
动作块周期 400 ms（§ 6.4）

① 只学“出错之前”的样子 示意，非原图

出错时刻 t_fail：明显犯错、或停滞到需要人接手的时刻（沿用 Gu 等 2025）。

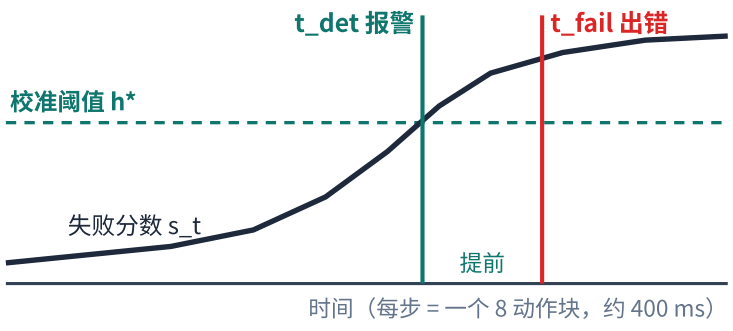

失败回合怎么标正例（四种对照，§ 4.1、附录 D.4）

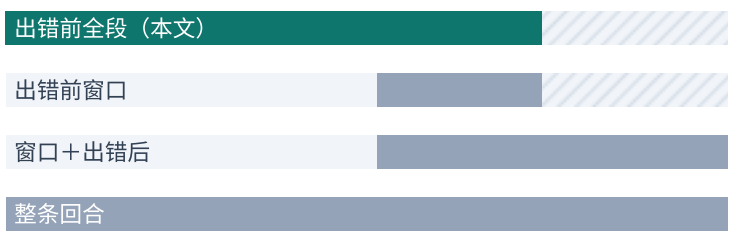

色块＝标为“将失败”的步；斜纹＝出错后的步被丢弃，
不当成功也不当失败；成功回合全部标 0

作者假设出错后的隐层只描述“已经失败”，学了反而不会预测；消融里“出错前全段”在 LIBERO-X 各类留出上都最好，把出错后也标正例最差（附录 D.4）。

② 能承诺多少：误报上限与“提前抓到”下限一起认证 附录表 7，LIBERO-X 14 次运行

柱高：与误报上限 α 一起能认证的“提前抓到失败”下限 β（δ=0.1，至少一半运行可认证的最高值）

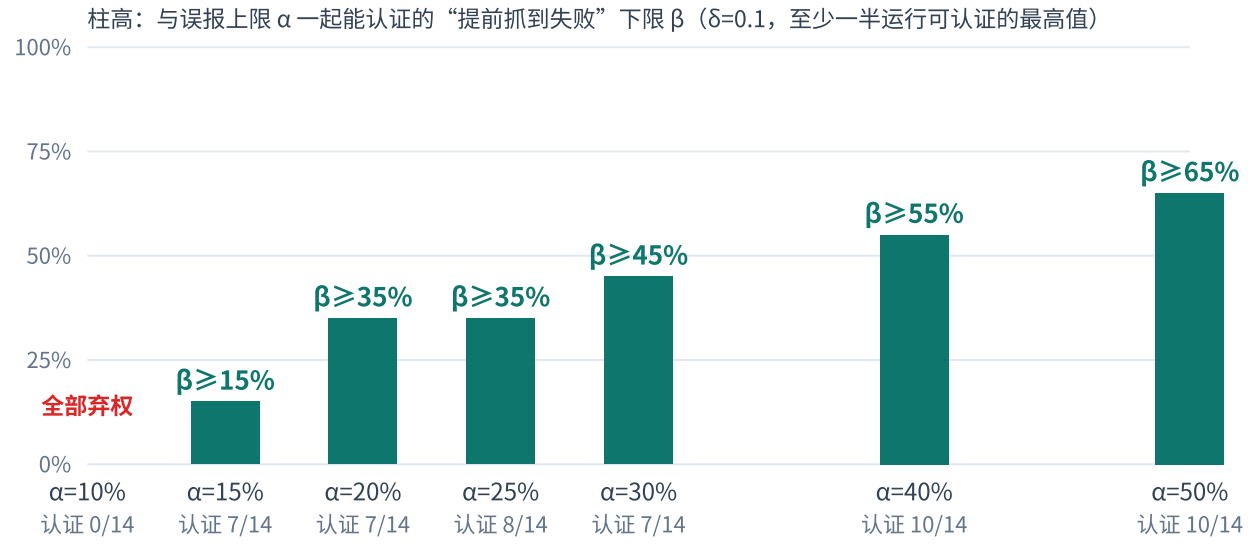

误报上限 α	认证的 β	LTT 可认证	未见任务上 LTT 目标兑现（分母＝已认证运行）		未见任务上误报目标兑现（分母＝全部 14 次）	
			误报	提前抓到	MC	FC
10%	—	0/14	—	—	50%	36%
15%	15%	7/14	86%	71%	14%	29%
20%	35%	7/14	71%	57%	21%	21%
25%	35%	8/14	75%	75%	7%	7%
30%	45%	7/14	86%	57%	0%	7%
40%	55%	10/14	60%	80%	0%	0%
50%	65%	10/14	40%	90%	0%	0%

见过的任务上，已认证运行两项目标**全部兑现**；最大保形（MC）总会给阈值，但误报目标只在 57–71% 的运行兑现。换到未见任务，MC/FC 的误报目标兑现率跌到 0–50%（α≥15% 时只有 0–29%），LTT 仍有 40–86%。代价是：**α=10% 时 14 次全部弃权**，α=20% 只能承诺提前抓到 35% 的失败。两组百分比分母不同（LTT 只算已认证运行），新任务、新组合两类划分的 3 次运行共享同一批未见任务，只能看趋势。

③ 及时性：未见任务上的提前检测面积 表 3，TPR_early–FPR 曲线下面积

（FPR≤40%，%）

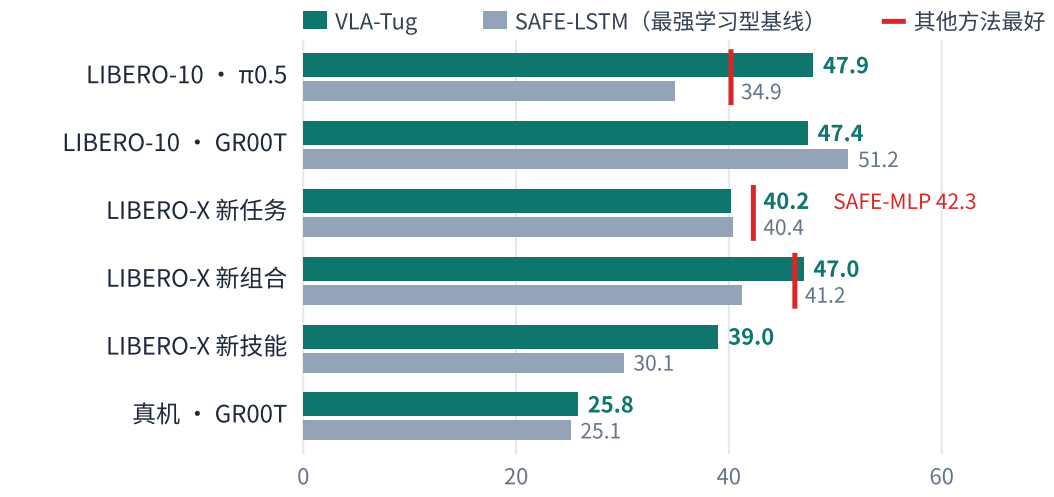

六个设置里四个最好；差距随“离训练任务多远”变大（新组合 +14%、新技能 +30%，相对 SAFE-LSTM）。但 **GR00T 的 LIBERO-10 输给 SAFE-LSTM，新任务划分 SAFE-MLP 更好**；真机只领先 0.7 点，把出错时刻往后挪时 SAFE-LSTM 反超（附录 D.4）。绝对值也要看清：未见任务上面积多在 40–48%。

④ 还给了什么，没给什么

前 3 类
失败类型（10 类）的前三命中，未见任务最多比多数类基线高 44%（相对值，§ 6.3）

6.8 s
单卡训练；校准每对目标 <2 ms，可随任务或要求变化重训重校（§ 6.4）

3,180
条标注回合与嵌入公开；真机 8 任务、399 回合（Kinova＋GR00T，附录 B.1）

0 组
纠正的定量对照：纠偏只有仿真与真机各一例演示，作者明说未评估（§ 6.5、§ 7）

设想中由 VLM 之类的专家模型接到报警与失败类型后调用恢复工具；本文实现的是按类型写的启发式。**能交给 harness 的是“何时、可能哪一类”**，交还之后能救回多少，论文没有回答。摘要“支持轻量纠偏、提高任务成功”应按演示读。

边界与我们的读法

1. **“真值”出错时刻与失败类型由 Gemini 3.5 Flash 看视频标注**（附录 B.2），原文未报告人工一致性；附录 D.4 只检验了把出错时刻整体后移的敏感性。
2. 保证依赖校准集与测试可交换；未见任务上只是经验兑现，14 次运行、不同划分共享未见任务，比例是趋势不是精确率。
3. 真机每次留出一个任务，校准集只有 12–14 个成功回合，LTT 一项都认证不了，表 7 只覆盖仿真 LIBERO-X。
4. 需要读 VLA 隐层，不适用于只给 API 的黑盒策略；0.12 ms 是探针本身，不是整个监控—干预链路的延迟。
5. 收录口径：被监控对象是冻结 VLA，环里没有 LLM/VLM harness；按 EVIDENCE B 类“成功/失败检测器”收录，价值在于给 harness 的交还与门控提供可校准的触发信号。
6. 每条失败回合要先有出错时刻标注；新本体、新任务族需要重新采集失败回合再训练校准。

来源：Podolinsky、Yang、Little 等（UT Austin、Tufts、UT Dallas），Failure Prediction and Classification in Vision-Language-Action Models via Calibrated Latent Probing，arXiv 2611.08425v1（2026-11-05）。阶梯图、条形图为我们按表 3、表 7 重绘；①为示意。数字与原文位置对照见 SOURCE.md。问题档位是选读判断，不是审稿结论；未运行论文代码。Embodied-Harness-Daily · selection-012