EMBODIED FIRST EXAM · 编码代理的机器人第一次考试 · arXiv 2611.12177v1

同一批题，开卷 77%，闭卷 30%：补回“能重置”比补回“看真值”更多

GPT-6 Astra（Codex）在 391 个困难核心任务上：能读整个仿真状态、无限重置时解出 **303** 题；只给机器人传感器、默认不能重置时只解出 **116** 题。受控加回特权：只加物体真值到 45%，只加无限重置与存档到 **53%**，两者都加 68%。

考生 · 8 个编码代理（模型＋自带 harness）

35	47	456	3	1

35 套题 · 47 种机器人 · 456 核心任务 · 3 种考法 · 每题每代理 1 次；判分器在代理容器之外

B 类评测 · 全部仿真

一 三种考法：只改“能看什么、能否重来、世界等不等你”

§ 2.1，附录 C.1–C.2

	特权 Privileged（开卷）	标准 Standard（闭卷）	实时 Realtime
代理看得到	完整仿真状态	相机 RGB-D＋本体读数；物体位姿、成功规则不发	同标准
重置	**无限**	**默认不能（9 套题给 3–50 次）**	**同标准**
代理思考时	—（离线搜索）	世界暂停	**世界照常运行**
怎么判分	另一容器重放提交的动作轨迹	仿真服务在独立容器里判活的回合，只看仿真状态、不看代理自述	

同一任务的各考法共用初始场景、成功规则与时限，所以结果可以逐题配对。代理自选控制方式：直接出动作、写程序、或在仿真里训练策略。

二 391 个两种考法都有的核心任务，GPT-6 Astra 的配对结局

§ 3.2，图 10

实时更难：54 个两种都有的动态任务里，标准 → 实时解出数 Astra 23 → 17、Claude Opus 5.5 10 → 4、Gemini 4 Argon 15 → 5；没有任何代理解出的实时题占 63%（同批标准题 50%）。

三 把特权一项项加回闭卷

表 5，附录 G

同一 GPT-6 Astra / Codex、同推理强度、同时限；每次运行只改接口里的一两项。391 任务的默认测试。

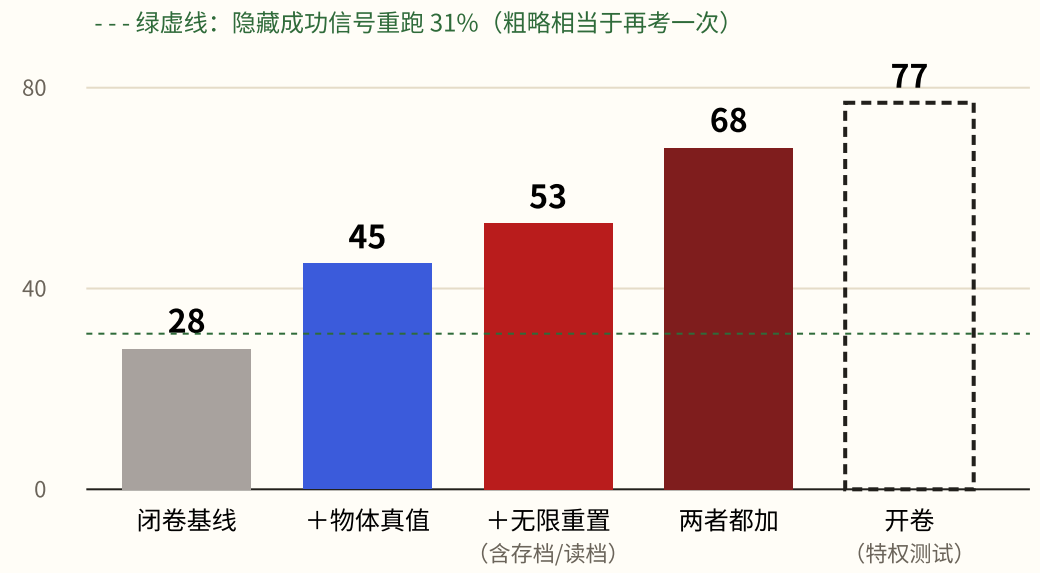

加重置的 206 次成功里 **66%** 出现在从存档开始的回合：代理退回难点前重试，而不是重做整题。基线 28% 用各任务默认测试（53 题为实时），与第二题的 30% 口径不同。

四 差距落在“要精确”的阶段

§ 3.2，图 11b–c，附录 E.1

阶段失败率 = 在该阶段失败数 ÷ 到达该阶段数；八代理，套件内对比后汇总。

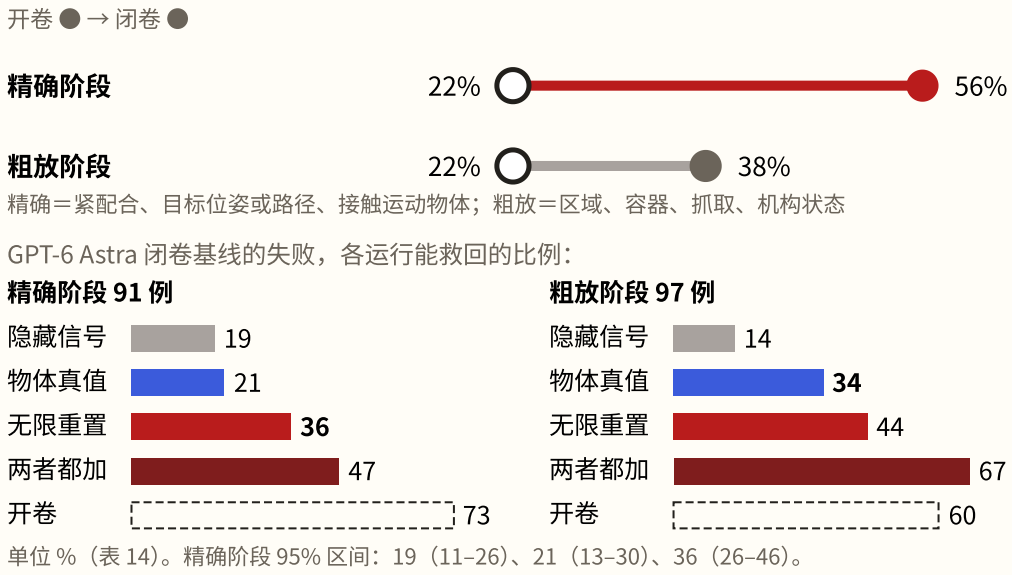

单位 %（表 14）。精确阶段 95% 区间：19（11–26）、21（13–30）、36（26–46）。

例：闭卷装风扇前罩，Claude Opus 5.5 把罩子偏离轴线 36–39°，允许 5°（图 12）。精确阶段上**真值几乎不帮忙，能重来才帮忙**。

五 换 harness 就换分

§ 3.4，表 6

34% vs 22%

同一 GPT-6 Astra、同 456 道闭卷题：Codex 34%，Claude Code 22%（配对检验 p<0.001）。跨厂商运行经适配器，只近似原生设置。

六 考法改变解题方式

§ 3.5，图 17a

61 · 82 · 97 %

1,489 次抽样尝试：闭卷 61% 一步一看地直接控制；开卷 82%、实时 97% 写程序控制。标签由代理打。

七 失败扎堆在同一阶段

§ 3.3，图 13a

56% vs 随机 31%

三强代理同一题的失败对落在同一阶段的比例；最常见失败阶段 65% 是任务第一步。是共同位置，不是共同原因。

阅卷边界

1. 每题每代理只考一次，没有区间；代理之间“解出的题不同”可能部分来自运行波动（作者自述）。
2. 核心集删掉了被 GPT-6 Luna 初筛解出的题；Luna 与 Astra 同族，可能压低该族分数；绝对值不能代表全部 1,156 题。
3. “加回特权”的受控对照只有一个代理（GPT-6 Astra / Codex），每格一次运行。
4. “无限重置”附带存档与读档，不只是多几次重来；开卷还能逐步推进物理、调用原基准规划原语，剩余 68→77 的差距未拆开。
5. 阶段与控制方式标签由 GPT-6.1 Sol 写、Claude Sonnet 5.5 复核，人工只审过早期版本，无独立一致率；Sol 与 Astra 同族。
6. 全部仿真。真机只有附录 I 的蜂鸣线演示（2 代理 × 8 次一串，不计入任何成功率），模拟分数能否预测真机未测。
7. 我们的读法：开卷 77% 更像“能找到解”的上限；评估部署能力应看闭卷与实时，并把是否允许重置写进结果配置。

来源：Embodied First Exam，arXiv 2611.12177v1（2026-11-09），正文 § 1–5 与附录 B–J（同版本 arXiv HTML）。图中数字均出自原文图 10、表 5–6、§ 3 与附录 E.1；条形与表格为我们按原文数值重绘，未运行论文代码、未复现。问题档位为本项目选读判断，不是审稿结论。